

BridgeAI-Site 项目实施与现场交付方案

出版增强版 v2.0

浙江悟联信息科技有限公司

编制人：周仙通

文档定位：企业级智慧工地 AI Agent 平台实施方法、现场部署、试运行、验收移交与持续运营指南

适用产品：BridgeAI-Site 智慧工地 AI Agent 平台

核心视觉引擎：BridgeAI Vision Engine (BVE)

适用阶段：项目启动、现场勘察、方案评审、系统部署、设备接入、AI 标定、Agent 上线、试运行、验收移交、售后运维

版本：v2.0（出版增强版工作稿）

日期：2026 年 7 月

版权与使用说明

本文件由浙江悟联信息科技有限公司编制，用于 BridgeAI-Site 产品研发、项目实施、客户交付、团队培训、招投标技术响应和项目验收。未经授权，不得将其中的产品设计、系统架构、算法方案、Agent 工具定义、部署参数及工程模板用于与 BridgeAI-Site 构成直接竞争的产品。

版本说明

本版在《BridgeAI-Site 项目实施与现场交付方案 v1.0》的基础上重构。v1.0 以执行清单和交付条款为主，v2.0 保留其工程可执行性，同时增加现场叙事、架构取舍、失败案例、质量门禁、标准作业程序、表单模板和复盘方法，使文档同时承担以下角色：

1. BridgeAI 实施团队的项目执行手册；
2. 建设单位、施工单位和监理单位的范围确认与验收依据；
3. 招投标文件中的实施组织、部署交付和售后服务参考；
4. 项目经理、实施工程师、算法工程师、Agent 工程师和运维人员的培训教材；
5. BridgeAI 技术丛中连接“产品设计”与“现场生产系统”的工程卷。

前言：真正困难的不是部署，而是让系统进入生产

智慧工地项目最容易被低估的环节，是“从演示系统到生产系统”的最后一公里。

在实验室中，一路视频可以稳定播放，一个模型可以识别安全帽，一个大模型可以回答安全管理问题；但进入真实施工现场后，系统面对的是持续变化的工序、临时调整的摄像头、弱网、逆光、夜间补光、人员遮挡、账号权限、管理责任边界以及必须形成证据链的验收要求。单个模块能够运行，并不等于项目能够交付；模型在测试集上取得较高指标，也不等于现场能够形成有效的安全管理闭环。

BridgeAI-Site 的项目实施目标，不是把 Web、API、模型和数据库安装到一台服务器，而是把视频、GIS、BVE、事件、风险、工单、Agent、RAG、报表、边缘节点和运维体系组合成一个可长期运行、可审计、可回滚、可验收的生产系统。

本书采用“方法论 + 现场故事 + SOP + 表单”的结构。每一篇首先解释为什么这样做，然后描述项目现场会遇到什么问题，最后给出可以直接执行的流程、门禁和交付物。读者既可以从头阅读，也可以在现场按章节检索。

贯穿本书的示例项目

为避免文档停留在抽象层面，本书设置一个贯穿全文的示例项目：某交通基础设施建设项目拟建设 BridgeAI-Site 智慧工地 AI Agent 平台。示例项目的初始范围如下：

- 1 个在建交通基础设施项目；
- 20 路固定摄像头，含出入口、钢筋加工区、材料区、临边作业区和动火作业面；
- 天地图矢量与卫星底图，叠加项目边界、工区、危险区和摄像头点位；
- 4 个首批 AI 场景：未戴安全帽、未穿反光衣、危险区域入侵、火焰烟雾；
- 1 套 BVE 视觉分析引擎；
- 1 个项目级 Supervisor Agent，以及 Vision、Risk、Workflow、Knowledge、Report 等专业 Agent；
- 1 套基于 PostgreSQL、PostGIS、pgvector 的业务数据与知识检索底座；
- 1 套事件—工单—整改—复核—销项闭环；
- 14 天试运行；
- 后续预留无人机、DJI Manifold 3 和 GPS-Denied 桥下巡检能力。

上述数据属于教学示例。真实项目应以合同、现场勘察和验收指标为准。

全书结构

- 第一篇 实施方法论与交付体系
- 第二篇 项目启动、组织与责任边界
- 第三篇 现场勘察与实施方案确认
- 第四篇 基础环境、平台与数据底座部署
- 第五篇 视频、GIS 与现场设备接入
- 第六篇 BVE 与 AI 场景工程化实施
- 第七篇 Agent、RAG 与业务闭环上线
- 第八篇 联调、培训、试运行与验收
- 第九篇 边缘节点、无人机与 DJI Manifold 3 交付
- 第十篇 案例复盘、SOP、表单与检查清单

第一篇 实施方法论与交付体系

第 1 章 从“安装软件”到“交付生产系统”

1.1 项目实施的本质

BridgeAI-Site 项目实施是一项社会—技术系统工程。它同时包含软件工程、人工智能工程、视频工程、GIS 工程、网络与信息安全、施工现场管理以及多方组织协同。任何单一专业的成功，都不能替代整体系统的成功。

传统软件项目常以“功能是否实现”作为主要判断标准；AI 项目还必须回答四个额外问题：

第一，输入是否稳定。摄像头视角、码率、光照、网络和时间同步是否能够持续满足分析条件。

第二，输出是否可信。模型误报、漏报、置信度、规则和证据是否能够被现场管理人员理解和复核。

第三，动作是否受控。**Agent** 生成建议、创建工单或调用工具时，是否符合权限、审批和审计要求。

第四，系统是否可持续。模型、**Prompt**、规则、知识库和现场配置是否能够版本化、灰度发布和回滚。

因此，实施完成的定义不应是“页面可以打开”，而应是：

现场输入稳定 → 数据链路完整 → **AI** 输出可验证 → 业务动作受控 → 闭环结果可审计 → 系统可运维和可回退。

1.2 五类交付对象

一个完整项目至少交付五类对象。

（1）运行系统。包括 Web、API、BVE、Agent Runtime、Worker、Media、Nginx、Monitoring 及其运行配置。

（2）数据底座。包括 PostgreSQL、PostGIS、pgvector、Redis、MinIO，以及业务数据、空间数据、知识文档、模型元数据和审计记录。

（3）现场配置。包括摄像头清单、视频接入参数、GIS 图层、ROI、规则、阈值、工单流程、通知策略和用户权限。

（4）工程资产。包括模型权重、ONNX、TensorRT Engine、MLX 权重、Prompt、Agent Tool Schema、部署脚本、配置模板、测试集和回滚包。

(5) 组织能力。包括关键用户、管理员、运维人员的培训成果，以及问题处理、变更审批、模型迭代和知识维护机制。

如果项目只交付第一类对象，它仍然只是一个被安装的软件；五类对象全部到位，系统才具备生产属性。

1.3 三条价值链

BridgeAI-Site 的实施应同时打通三条价值链。

视频价值链：摄像头 → 解码与调度 → BVE 推理 → 跟踪与规则 → 事件 → 证据。

业务价值链：事件 → 风险分级 → 工单 → 整改 → 复核 → 销项 → 统计分析。

智能价值链：用户问题或系统事件 → Supervisor Agent → 专业 Agent → 工具/API/RAG → 受控结果 → 审计。

三条价值链必须在联调阶段分别测试，再进行端到端测试。常见错误是只测试“模型有没有框”，却没有验证事件是否保存、工单是否派发、Agent 是否遵守权限、证据是否能够在验收时追溯。

1.4 现场生产系统的七个质量属性

BridgeAI-Site 的质量目标可以归纳为七个属性：

- 可用性：核心服务、视频和 AI 任务持续在线；
- 正确性：GIS 点位、业务状态、权限和统计口径正确；
- 有效性：AI 发现的事件对现场管理具有实际价值；
- 安全性：账号、数据、接口、Agent 工具和远程维护受控；

- 可追踪性：配置、模型、Prompt、事件和操作具备版本与审计；
- 可恢复性：系统、数据库、对象存储和边缘节点可备份、恢复和回滚；
- 可运营性：用户会使用，运维能定位问题，管理者能通过报表持续改进。

第2章 以现场业务闭环为中心的实施方案

2.1 从管理问题出发，而不是从模型清单出发

项目启动时，客户经常直接提出“需要识别安全帽、烟火、反光衣和人员聚集”。实施团队不能立即把这些词转换成模型部署任务，而应继续追问：

- 风险发生在哪个工区、哪个时段、哪个作业阶段？
- 哪个摄像头能够看到完整目标？
- 告警后由谁确认、由谁整改、多久必须完成？
- 重复事件如何合并，夜间或停工时段是否需要停用规则？
- 哪些事件只提示，哪些必须形成工单，哪些需要升级到项目负责人？
- 验收时用什么样本和口径判断场景可用？

模型只是闭环中的一个环节。一个误报率略高、但能够通过 ROI、持续时间和人工复核形成稳定闭环的场景，可能比一个离线精度很高、却无法适配现场流程的模型更有价值。

2.2 场景卡：AI 实施的最小管理单元

每个 AI 场景应建立“场景卡”，至少包含：

场景名称、业务目标、适用工区、摄像头、目标对象、触发条件、排除条件、ROI 类型、模型版本、阈值、持续时间、冷却时间、风险等级、证据要求、处置流程、责任人、验收样本、上线日期和回滚版本。

场景卡将业务语言、算法参数和验收口径放在同一张表中，避免安全负责人、算法工程师和实施工程师使用不同语言讨论同一个问题。

2.3 证据优先原则

智慧工地告警不能只保存一张带框截图。完整证据通常包括：

- 事件发生前后的短视频；
- 原始画面与叠加画面；
- 摄像头、工区和 GIS 位置；
- 模型、规则、阈值和 ROI 版本；
- 首次发现时间、持续时间和合并次数；
- 人工确认、工单、整改照片和复核结论；
- Agent 参与分析或生成建议时的输入、工具调用和输出记录。

证据优先不仅服务验收，也服务误报分析、事故复盘和模型迭代。

2.4 人机协同而不是全自动处置

BridgeAI-Site 的 Agent 可以查询数据、总结风险、生成报告、创建工单草稿和提出处置建议，但高风险动作必须遵循最小权限和人工确认原则。

建议的控制级别如下：

- L0: 只读查询与知识问答, 可自动执行;
- L1: 生成分析、报告和工单草稿, 可自动执行并记录;
- L2: 发送一般通知、更新低风险状态, 需要明确授权;
- L3: 发布高风险工单、升级事件、修改关键规则, 需要人工确认;
- L4: 影响设备控制、飞控、生产系统或安全边界的动作, 必须采用专用审批和紧急停止机制。

第 3 章 实施生命周期与质量门禁

3.1 十四阶段生命周期

BridgeAI-Site 推荐采用以下生命周期:

项目启动 → 现场勘察 → 方案确认 → 环境准备 → 系统部署 → 设备接入 → GIS 标定 → AI 场景上线 → Agent 与 RAG 上线 → 系统联调 → 用户培训 → 试运行 → 初验与整改 → 终验和运维移交。

生命周期不是简单的线性瀑布。现场施工区域、摄像头视角和业务流程会不断变化, 因此每个阶段都允许反馈和迭代; 但迭代不等于无序。任何回退都必须留下变更记录、影响评估和重新验证结果。

3.2 阶段出口条件

每个阶段必须有明确的“出口条件”。例如:

项目启动阶段的出口条件: 项目章程批准、组织和联系人明确、范围基线形成、勘察计划确认。

现场勘察阶段的出口条件: 网络、摄像头、机房、GIS、施工场景和风险条件已记录; 无法确认项已列为问题并指定责任人。

系统部署阶段的出口条件：核心服务健康、日志可查、监控可见、数据库完成首次备份与恢复验证、默认密码已修改。

AI 场景上线阶段的出口条件：场景卡批准、摄像头视角合格、ROI 和参数留档、回放测试与现场测试完成、灰度计划和回滚版本明确。

试运行阶段的出口条件：连续运行周期达到约定要求、核心指标可计算、重大缺陷关闭、用户已真实使用、运维人员能够处理常见问题。

3.3 六类质量门禁

G1 范围门禁：合同范围、交付边界和验收口径未确认，不得启动大规模部署。

G2 现场门禁：网络、摄像头、服务器、电源和进入条件未满足，不得承诺上线日期。

G3 数据门禁：坐标、用户、项目、设备和基础字典未校验，不得进入业务联调。

G4 AI 门禁：场景卡、测试样本、ROI、阈值和回滚版本不完整，不得生产上线。

G5 Agent 门禁：工具权限、Schema、超时、审计和人工确认策略未验证，不得开放写操作。

G6 交付门禁：备份恢复、监控告警、培训、文档和账号移交未完成，不得终验关闭项目。

3.4 上线红线

出现以下任何情况，应停止上线或回退：

- 默认密码未修改；
- PostgreSQL、Redis、MinIO 或管理端口直接暴露公网；
- 无 HTTPS、无日志、无监控或无备份；
- 视频源无法稳定重连；
- 高风险 AI 场景未经过真实现场测试；
- Agent 可绕过权限直接执行高风险操作；
- 模型、Prompt 或规则没有版本和回滚包；
- TensorRT Engine 未在目标设备上完成验证；
- 施工现场缺少紧急联系人或紧急停用机制。

第 4 章 实施指标与验收设计

4.1 指标必须在启动阶段定义

验收指标不能等到试运行结束后再讨论。启动阶段应同时定义功能指标、性能指标、AI 指标、Agent 指标、稳定性指标和交付完整性指标。

建议指标示例：

基础系统：核心服务健康率 100%，关键操作具备审计，备份恢复演练通过。

视频：接入成功率不低于 98%，首帧时间和端到端延迟满足现场约定，断流后能够自动恢复。

GIS：项目边界、工区、设备点位和事件落点经过抽样核验，坐标偏差在项目允许范围内。

AI：按场景分别约定 Precision、Recall、误报事件数、漏报事件数和告警延迟，不使用单一总体准确率替代场景指标。

Agent: 只读查询正确，工具调用符合权限，高风险操作必须确认，回答引用可追溯，无结果时不虚构。

业务闭环：事件可形成工单，工单可分派、整改、复核、销项和统计；关键状态变更具备人员和时间记录。

4.2 验收样本集

每个 AI 场景应在试运行前建立验收样本集，包含正样本、空样本、相似负样本、夜间样本、遮挡样本和边界条件样本。验收样本应尽量来自项目现场，而不是完全使用训练数据或网络素材。

对持续发生的行为类场景，应以“事件”为统计单位，而不是逐帧统计。一个人员连续 30 秒未戴安全帽，通常应视为一个事件，而不是数百个检测框。

4.3 指标与责任边界

AI 指标受模型能力、摄像头视角、光照、目标尺寸、网络 and 现场规则共同影响。合同和实施方案应明确：

- 客户负责提供或允许调整的现场条件；
- BridgeAI 团队负责的模型、规则和参数优化范围；
- 免费迭代次数与超出范围后的变更机制；
- 因施工阶段变化导致摄像头或 ROI 重配时的责任；
- 第三方视频平台、云服务和短信服务的可用性边界。

第 5 章 示例项目：第一次把系统带进现场

5.1 启动前的理想想象

示例项目在售前演示阶段表现顺利：测试视频可以稳定播放，安全帽模型能够识别人员，地图上可以显示摄像头点位，Agent 可以根据制度文档回答“动火作业需要哪些审批”。项目团队最初估计两周即可完成部署并进入试运行。

5.2 第一次进场后的现实

现场勘察发现：20 路摄像头中只有 14 路具备稳定取流条件；3 路使用了不受支持的编码参数；2 路安装角度过高，人员头部目标不足 12 像素；1 路夜间补光导致反光衣区域过曝。施工单位内网与项目服务器之间还存在 VLAN 隔离，第三方视频平台账号仅有观看权限，无法获取长期有效的取流地址。

这些问题说明：售前演示验证的是产品能力，现场勘察验证的是交付条件。两者不能互相替代。

5.3 第一个关键决策

实施团队没有立即开始“调模型”，而是将问题分为四类：

- A 类：网络与账号条件，交由施工单位网络负责人处理；
- B 类：摄像头编码和取流参数，由实施工程师与视频平台联调；
- C 类：摄像头视角和补光问题，由现场机电负责人调整；
- D 类：满足条件的 10 路摄像头先进入首批试点。

项目计划由“大爆炸上线”调整为“小步灰度”：先打通 10 路视频、2 个 AI 场景、1 个工区和完整工单闭环，再扩展到全项目。这个决策使项目能够在现场条件不完美的情况下仍然形成可验证成果。

5.4 方法论结论

现场项目的成熟度，不体现在团队能否隐藏问题，而体现在能否尽早暴露问题、明确责任、控制变更并保留证据。实施计划不是静态时间表，而是基于质量门禁不断更新的工程控制系统。

第二篇 项目启动、组织与责任边界

第 6 章 项目启动条件与项目章程

6.1 启动不是一次会议

项目启动包含授权、范围、组织、资源、计划、风险和验收七项基础工作。启动会只是集中确认这些工作的管理事件。如果基础信息未准备好，会议结束并不代表项目真正启动。

6.2 启动前置条件

至少确认以下内容：

- 合同、任务书或正式项目授权；
- 产品和服务范围；
- 项目地点、施工阶段和预计工期；
- 建设单位、施工单位、监理单位和 BridgeAI 团队负责人；
- 现场进入、安全教育和设备携带要求；
- 初步摄像头、网络、服务器和机房条件；
- 首批 AI 场景和管理痛点；
- 域名、证书、第三方平台和通知渠道；
- 计划窗口、停工窗口和试运行周期；

- 验收组织、预算边界和变更审批人。

6.3 项目章程

项目章程建议包含：

项目背景、建设目标、成功标准、范围、非范围、主要交付物、关键里程碑、项目组织、决策机制、风险、假设、约束、验收方式和批准人。

项目章程的价值在于建立单一事实来源。后续出现“是否包含新增摄像头”“是否需要接入企业微信”“是否交付源码”等争议时，应首先回到章程、合同和经批准的变更单，而不是依赖口头记忆。

6.4 成功标准

成功标准应兼顾技术和业务。例如：

- 指定摄像头和工区稳定接入；
- 首批 AI 场景在现场验收集上达到约定指标；
- 高风险事件能够在规定时间内形成工单并完成闭环；
- 安全负责人能够通过 Agent 查询风险、生成日报并追溯依据；
- 管理员和运维人员能够独立处理账号、摄像头离线、服务重启和备份恢复；
- 试运行期间不存在未关闭的 S1 级缺陷。

第 7 章 范围基线与交付边界

7.1 功能范围

应逐项确认是否包含：

GIS 地图、天地图底图、项目自定义图层、摄像头管理、视频墙、录像、BVE、AI 事件、风险分级、工单、Agent、RAG、报表、通知、运维监控、边缘节点、无人机协同和第三方系统接口。

每一项应标记为“本期交付、预留接口、后续阶段或明确不包含”。

7.2 数据范围

数据范围包括：

项目与组织数据、人员与角色、摄像头、空间点位、施工区域、事件与证据、工单、模型与规则、Agent 会话与工具审计、知识文档、报表和运维日志。

还应明确历史数据是否迁移、数据保留周期、录像保留周期、个人信息处理、数据导出格式和项目结束后的数据处置方式。

7.3 AI 范围

每个 AI 场景必须说明：

是否已有可用模型；是否需要项目专项训练；客户是否提供样本；谁负责标注；迭代次数；验收集；推理位置；性能目标；模型权属；后续新增类别如何计费 and 排期。

禁止只在合同中写“支持多种 AI 识别”，却不列出首批场景、摄像头和验收口径。

7.4 Agent 范围

Agent 的范围不应仅列名称，还应列工具和权限。例如：

Knowledge Agent：检索项目制度、规范和方案，只读。

Risk Agent：查询事件和风险统计，生成分析，只读。

Workflow Agent：生成工单草稿；正式发布需要安全负责人确认。

Report Agent：生成日报、周报和专项报告，可保存草稿，不得自动外发。

Supervisor Agent：负责意图识别和编排，不直接拥有超出专业 Agent 的权限。

7.5 责任边界表

必须明确以下责任：

摄像头、NVR、交换机、机柜、电源和布线由谁提供；

网络、VLAN、防火墙、VPN 和公网出口由谁配置；

服务器、GPU、操作系统和虚拟化由谁采购和维护；

域名、证书、短信、邮件、企业微信、萤石云等账号和费用由谁承担；

现场摄像头角度和补光由谁调整；

AI 样本、标注和专项训练由谁组织；

试运行期间由谁每日确认误报和漏报；

验收文件由谁起草、审核和批准；

运维期的响应、升级、驻场和差旅边界是什么。

第 8 章 项目组织与 RACI

8.1 四方组织

建设单位通常负责项目目标、资金、重大决策和最终验收。

施工单位负责现场资源、网络与设备协调、施工业务流程、整改执行和真实使用。

监理单位负责过程监督、验收见证、问题闭环和合规性检查。

BridgeAI 实施团队负责方案、部署、接入、配置、AI 与 Agent 工程化、联调、培训、试运行支持和技术资料。

8.2 BridgeAI 实施团队角色

项目经理：范围、计划、资源、沟通、风险和验收总负责。

解决方案架构师：总体架构、部署模式、系统边界和关键技术决策。

实施工程师：服务器、网络、摄像头、GIS、账号、配置和现场联调。

算法工程师：场景评估、数据分析、模型、阈值、ROI、规则和效果优化。

Agent 工程师：Agent 编排、Tool Schema、权限、Prompt、评测和审计。

后端与前端工程师：接口、业务流程、页面和第三方集成。

测试工程师：测试计划、缺陷、回归、验收集和证据管理。

运维工程师：监控、日志、备份、恢复、升级、回滚和 SLA。

在小型项目中，一人可以承担多个角色，但责任不能因此消失。项目文档仍应记录每项职责由谁承担。

8.3 RACI 基线

R 表示执行负责人，A 表示最终负责与批准，C 表示协商，I 表示知会。

事项	建设单位	施工单位	监理单位	BridgeAI
需求与目标确认	A	R	C	C
现场勘察	C	R	C	R
网络与电源准备	I	A/R	C	C
摄像头与视频平台协调	I	A/R	C	R
系统部署	I	C	I	A/R
GIS 数据确认	C	A/R	C	R
AI 场景与验收集	C	A/R	C	R
Agent 权限与流程	A	R	C	R
培训与试运行	C	A/R	C	R
初验与终验	A	C	R	C
运维移交	A	R	C	R

RACI 不是为了增加表格，而是为了避免“所有人都参与、却没有人负责”。每个关键事项必须且只能有一个清晰的 A。

8.4 决策分级

现场一般问题由实施工程师与对应责任人处理；

影响 1~3 天计划或单个模块的事项由项目经理决策；

影响合同范围、主要里程碑、预算、验收指标或生产安全的事项必须提交项目委员会或双方授权人审批。

第 9 章 需求基线与验收基线

9.1 两条基线必须同时建立

需求基线回答“系统要做什么”；验收基线回答“如何证明做到了”。只确认需求而不确认验收方式，会把争议推迟到项目末期。

9.2 需求确认方法

建议采用“业务场景—用户角色—输入—处理—输出—异常—权限—证据”的八要素模板。

示例：危险区域入侵。

业务场景：非授权人员进入临边危险区。

用户角色：安全员、班组负责人、项目安全负责人。

输入：指定摄像头实时视频、危险区 ROI、作业时段。

处理：人员检测、跟踪、区域关系、持续时间和重复事件合并。

输出：风险事件、截图、短视频、GIS 位置、通知和工单草稿。

异常：摄像头离线、夜间停工、授权人员进入、ROI 变化。

权限：安全员可确认；班组负责人可整改；安全负责人可销项。

证据：原始视频、规则版本、处理记录和整改前后照片。

9.3 验收基线

验收基线至少包括：

- 验收环境和版本；
- 功能清单；
- 测试账号和权限；
- 摄像头和工区范围；
- AI 验收集与统计口径；
- 性能与稳定性指标；
- 缺陷等级和关闭条件；
- 培训、文档、备份恢复和运维移交要求；
- 初验、整改、复测和终验流程。

9.4 缺陷等级

S1：核心系统不可用、数据严重错误、安全风险或关键业务完全阻断，终验前必须为 0。

S2：关键功能异常但存在临时替代方案，必须在约定期限内关闭。

S3：一般功能或体验问题，不影响核心业务，可纳入整改计划。

S4：优化建议和后续需求，不作为当前版本验收阻断项。

第 10 章 实施计划、沟通、变更与风险

10.1 里程碑计划

一个典型的十周项目可以参考：

第 1 周：启动、勘察、范围和验收基线；

第 2 周：环境、网络、服务器和账号准备；

第 3 周：平台、数据库、对象存储和网关部署；

第 4 周：摄像头、GIS 和视频接入；

第 5 周：BVE、AI 场景、ROI、规则和阈值；

第 6 周：Agent、RAG、工单、报表和通知；

第 7 周：端到端联调、性能与安全测试、用户培训；

第 8~9 周：试运行、问题整改和参数优化；

第 10 周：初验、复测、终验和运维移交。

该计划是模板，不是承诺。现场网络、摄像头改造、服务器到货和第三方接口未就绪时，应更新关键路径，而不是通过压缩测试和试运行时间“追回进度”。

10.2 每日与每周机制

现场实施期建议每日 15 分钟站会，内容只包括：昨日完成、今日计划、阻塞问题、需要谁决策。

每周项目例会包括：里程碑状态、质量指标、问题和缺陷、风险、变更、下周计划和需要管理层支持的事项。

重大安全、数据或范围问题应即时沟通，不等待周会。

10.3 单一问题清单

所有问题统一进入问题清单，字段包括：编号、日期、模块、问题描述、影响、等级、责任人、计划完成时间、当前状态、验证人和证据链接。

禁止通过多个微信群、口头通知和个人笔记分别维护问题。分散的问题记录会在验收前形成大量“已经处理但无法证明”的灰色事项。

10.4 变更流程

提出 → 澄清 → 影响评估 → 成本与周期评估 → 审批 → 实施 → 测试 → 发布 → 文档更新 → 关闭。

变更对象包括需求、范围、网络、摄像头、模型、数据、Prompt、Agent 工具、权限、规则、数据库、部署架构和验收标准。

紧急变更也必须留痕。可以先处置再补审批，但必须记录原因、执行人、影响、回滚方案和事后验证。

10.5 风险管理

常见风险包括：

- 服务器、GPU 或网络条件延期；
- 摄像头视角不适合 AI；
- 夜间画质和补光不稳定；
- 视频平台接口或令牌机制变化；
- 训练数据不足或现场类别分布变化；
- 施工区域和工序频繁变化；
- 客户关键用户参与不足；
- 试运行无法持续；

- 验收指标模糊；
- Agent 权限边界不清；
- 现场无人维护账号、证书和备份。

每项风险记录概率、影响、等级、触发条件、预防措施、应急措施、责任人和状态。高风险事项必须在周会上持续跟踪。

10.6 项目文档目录

建议采用统一目录：

project_delivery/	
└─ 01_project_start/	项目章程、启动会、通讯录、计划
└─ 02_site_survey/	勘察表、照片、网络拓扑、设备清单
└─ 03_solution/	实施方案、评审记录、范围基线
└─ 04_deployment/	部署记录、配置、版本、健康检查
└─ 05_camera_gis/	摄像头、视频测试、GIS 点位和图层
└─ 06_bve_ai/	场景卡、模型、ROI、规则、评测
└─ 07_agent_rag/	Agent、工具、Prompt、知识库、评测
└─ 08_integration_test/	联调报告、性能、安全和缺陷
└─ 09_training/	培训材料、签到、录像、考核
└─ 10_trial/	试运行日报、指标和问题
└─ 11_acceptance/	初验、整改、复测、终验
└─ 12_handover/	交付清单、账号、运维和项目总结

附录 A 项目启动会纪要模板

项目名称：

会议时间：

会议地点：

主持人：

参会单位与人员：

一、项目背景与目标

二、本期实施范围

三、明确不包含的范围

四、组织与责任人

五、关键里程碑

六、现场勘察安排

七、首批 AI 场景

八、验收原则与试运行周期

九、风险与前置条件

十、会议决议

十一、遗留问题

编号 | 问题 | 责任单位 | 责任人 | 计划完成日期 | 状态

建设单位确认：

施工单位确认：

监理单位确认：

BridgeAI 项目经理确认：

附录 B 范围与责任边界确认表

事项 | 本期范围 | 提供方 | 实施方 | 验收方式 | 备注

服务器与 GPU | | | | |

网络与防火墙 | | | | |

摄像头与 NVR | | | | |

第三方视频平台 | | | | |

GIS 底图与项目数据 | | | | |

AI 场景与模型 | | | | |

Agent 与工具权限 | | | | |

RAG 文档与版本 | | | | |

通知渠道 | | | | |

试运行 | | | | |

培训与运维 | | | | |

源码与知识产权 | | | | |

附录 C 风险登记表

风险编号：

风险描述：

类别：范围／计划／技术／现场／安全／供应商／数据／组织

发现日期：

概率：低／中／高

影响：低／中／高

风险等级：

触发条件：

预防措施：

应急措施：

责任人：

计划关闭日期：

当前状态：开放／监控／已发生／已关闭

验证证据：

第三篇 现场勘察与实施方案确认

第 11 章 把现场勘察变成工程基线

11.1 勘察不是参观现场

现场勘察的目标不是“看一圈、拍几张照片”，而是建立后续设计、部署、验收和运维共同使用的事实基线。勘察结束后，实施团队必须能够回答：系统部署在哪里、视频从哪里来、网络经过

哪些节点、哪些摄像头适合 AI、GIS 数据采用什么坐标、风险发生在哪些区域、谁负责整改、哪些条件尚未满足，以及这些未满足条件会如何影响工期和验收。

一次合格的勘察应同时完成四类工作：事实采集、可行性验证、风险暴露和责任确认。只记录设备型号而不验证取流，只询问带宽而不做链路测试，只确认有坐标而不核对坐标系，都属于“信息登记”，不能视为工程勘察。

11.2 勘察输入

勘察前至少收集：合同与范围基线、项目总平面图、施工组织设计、危险源清单、摄像头和 NVR 初步清单、网络拓扑、服务器资料、第三方平台账号说明、首批 AI 场景卡草案、项目组织通讯录以及现场安全进入要求。

资料不完整时仍可进场，但必须把缺失项登记为前置问题。实施团队不应把“客户尚未提供”默认为“现场不存在”，也不能以口头描述替代正式参数和可验证证据。

11.3 勘察组织与路线

建议由项目经理、实施工程师和算法工程师共同进场；涉及复杂网络、GIS 或边缘节点时，增加网络工程师、GIS 工程师或运维工程师。施工单位应安排熟悉机房、视频平台、工区和安全管理流程的人员陪同。

勘察路线宜遵循：项目部与机房 → 网络出口与核心交换 → 视频平台或 NVR → 主要摄像头点位 → 高风险工区 → GIS 边界与设备点位 → 边缘节点安装位置 → 运维和值守岗位。这样可以把物理现场、数字系统和管理流程连续起来，避免不同专业各自勘察后留下相互矛盾的结论。

11.4 证据编号与可追溯性

每一项勘察结论都应关联证据。推荐采用统一编号：

SUR-NET-001：网络链路测试；

SUR-CAM-001：摄像头登记与截图；

SUR-GIS-001：坐标与点位校验；

SUR-AI-001：AI 场景与目标尺寸评估；

SUR-ROOM-001：机房、电源和环境条件；

SUR-BIZ-001：业务流程与责任人访谈。

照片、截图、视频、测试日志和访谈纪要应使用相同编号归档。勘察报告中的关键结论必须能够反向定位到原始证据。

11.5 现场安全与数据安全

进入施工区域前应完成安全教育，遵守个人防护、临边、高处、动火和机械作业管理要求。不得为了取得更好的摄像头画面，擅自攀爬、移动设备或进入封闭危险区。

测试账号、RTSP 地址、密码、证书和网络配置不得出现在公开照片、普通聊天群或无权限的共享文档中。勘察设备离场前，应检查本地缓存、临时账号和下载的录像样本，并按项目数据管理要求保存或清除。

第 12 章 网络、服务器与机房勘察

12.1 先画清边界，再测试带宽

网络勘察首先识别信任边界和责任边界。需要明确摄像头网、办公网、服务器区、互联网出口、视频平台、边缘节点、远程维护通道和第三方云服务分别位于哪个网络区域，由谁管理，跨区访问经过哪些防火墙或网闸。

一条视频能够在浏览器中播放，不代表 BVE 节点能够访问；一台服务器能够访问互联网，也不代表第三方平台回调能够进入内网。所有关键链路必须从实际运行节点发起测试。

推荐绘制以下链路：

摄像头／NVR → 视频接入服务 → Media／BVE；

浏览器 → Nginx → Web／API／Agent；

API／Worker → PostgreSQL／Redis／MinIO；

边缘节点 → 中心平台；

运维终端 → VPN／Tailscale／堡垒机 → 服务器与边缘设备。

12.2 网络测试项目

对每条关键链路记录源地址、目标地址、协议、端口、DNS、往返时延、丢包、持续吞吐、峰值吞吐和重连表现。不要只执行一次 ping；视频链路至少应进行持续取流和断开重连测试，平台链路应验证 WebSocket、SSE、大文件上传和反向代理超时。

视频带宽估算不能简单使用“路数 × 标称码率”。还应考虑多码流、录像、AI 抽帧、浏览器并发预览、协议转换、事件回传和峰值冗余。对于弱网或跨公网链路，应评估边缘推理、子码流分析、本地缓存和断网补传。

12.3 端口与访问矩阵

形成端口矩阵，至少包含：服务名称、源区域、目标区域、协议、端口、访问方向、用途、是否公网暴露、认证方式、责任人和验证结果。

原则上 PostgreSQL、Redis、MinIO 管理端、Docker 管理端和内部监控端口不得直接暴露公网。远程维护应通过 VPN、Tailscale、堡垒机或其他受控通道，并记录账号、授权范围和退出机制。

12.4 服务器资源勘察

记录 CPU 架构、核心数、内存、GPU 型号与显存、磁盘类型与容量、RAID、操作系统、内核、容器运行时、GPU 驱动、CUDA/TensorRT 或 Apple Silicon/MLX 环境、网络接口和时间同步状态。

容量评估应基于工作负载，而不是只看设备型号。主要工作负载包括：并发视频解码、AI 推理、事件录像、模型与知识库文件、PostgreSQL 查询、向量检索、Agent 并发、报表生成和监控日志。对于录像和证据存储，应按摄像头码率、保存天数、事件比例和冗余系数估算。

12.5 机房、电源和环境

检查机柜空间、供电回路、UPS、接地、散热、温湿度、防尘、防水、消防和物理访问控制。边缘工控机或 DJI Manifold 3 的安装位置还应考虑振动、雨水、粉尘、天线遮挡和维护便利性。

服务器“能开机”不等于适合长期运行。持续高负载的 AI 节点必须验证温度、降频、风道和电源稳定性。现场无专人值守时，应配置远程开关机、自动拉起、心跳和离线告警。

12.6 远程维护条件

确认 SSH、远程桌面、VPN、Tailscale、堡垒机或厂家远程平台是否可用；确认是否需要双因素认证、审批、固定源地址和操作录像。建立紧急联系人和远程维护窗口，明确施工单位网络调整后由谁通知 BridgeAI 团队。

工程案例：链路通了，视频仍然不稳定

示例项目中，现场网络测试显示服务器到 NVR 的 ping 延迟低于 3 毫秒，实施团队最初判断网络正常。但连续拉取 16 路视频后，部分通道每隔数分钟断流。进一步检查发现，NVR 上行端口被配置为百兆，且主码流、录像回放和项目部预览共享同一链路。

解决方案不是继续调大播放器超时，而是将 NVR 上行升级为千兆、AI 使用独立子码流、限制同时回放路数，并在 Media 服务中配置指数退避重连。这个案例说明，连通性、容量和稳定性是三个不同问题。

第 13 章 摄像头、视频与 AI 适配勘察

13.1 建立摄像头唯一清单

摄像头清单应成为视频、GIS、BVE、事件和运维共同使用的主数据。每个摄像头分配唯一编号，记录项目、工区、名称、品牌、型号、IP、通道、协议、主辅码流、分辨率、帧率、码率、编码格式、安装高度、朝向、焦距、夜视方式、NVR、在线状态、AI 场景和责任人。

摄像头名称不能只使用“通道 01”或“枪机 3”。建议采用“项目—工区—位置—方向—序号”的命名方式，使事件和工单在脱离视频墙后仍然可理解。

13.2 验证真实取流条件

对每路候选摄像头至少验证：地址有效期、认证方式、首帧时间、连续取流、断流重连、编码兼容、时间戳、主辅码流、夜间画面、云台控制、录像获取和多客户端并发。

萤石云或其他第三方平台可能提供短期令牌、播放地址或并发限制。实施方案必须区分“演示可播放”和“生产可持续取流”。无法获得稳定生产流时，应评估 GB28181、ONVIF、NVR 直连、厂商 SDK 或现场网关。

13.3 用目标像素判断 AI 可行性

AI 适配不能只看摄像头分辨率。真正决定识别效果的是目标在画面中的有效像素、遮挡比例、拍摄角度和光照稳定性。

勘察时应截取典型人员、车辆、安全帽、反光衣和火焰烟雾区域，测量目标尺寸。对于安全帽等小目标，如果人员头部在常见作业位置仅占十余像素，即使摄像头为 4K，也可能因视场过大而无法稳定识别。

每个场景应给出结论：适合直接上线、调整参数后可用、需要调整摄像头、需要补光或增设设备、不适合当前场景。禁止把明显不合格的视角交给算法团队长期“调模型”。

13.4 光照、遮挡和场景变化

至少在白天、逆光、阴影、夜间和补光条件下抽样。关注雨雾、粉尘、镜头污渍、塔吊或车辆振动、人员密集遮挡、反光材料过曝和施工围挡变化。

施工现场不是固定数据集。钢筋加工区、材料堆场和临边作业面的布局会随工序变化。勘察报告应指出哪些 ROI 和摄像头需要按施工阶段复核，并把复核频率纳入运维计划。

13.5 摄像头 AI 适配评分

可采用五维评分：

目标可见性：目标尺寸、完整度和关键部位可见；

视角稳定性：抖动、云台巡航和长期遮挡；

光照质量：白天、夜间、逆光和过曝；

取流稳定性：地址、带宽、编码和重连；

业务有效性：画面是否覆盖真实风险和处置区域。

每项 1~5 分。总分较低时，不应直接进入模型验收，而应先完成设备或场景整改。评分用于决策，不应伪装成绝对科学指标；最终仍需结合现场测试。

13.6 现场样本采集

为后续调优和验收采集代表性样本，包括正样本、空样本、相似负样本、遮挡、夜间、雨雾、不同工服和不同施工阶段。视频样本应记录摄像头编号、日期时段、场景、授权范围和采集人。

采集必须遵守项目隐私和数据安全要求。用于模型训练或跨项目复用前，应确认数据权属、脱敏要求和授权范围。

工程案例：模型没有问题，镜头才是瓶颈

示例项目某临边作业区的安全帽识别漏报严重。算法工程师检查发现，原模型在同类近景样本上表现正常。现场镜头安装在 18 米高处，人员头部在主要作业面平均不足 10 像素，且被脚手架频繁遮挡。

项目最终将该摄像头保留用于人员聚集和区域入侵，同时新增一台较低角度摄像头用于安全帽识别。场景重新分工后，两类任务都获得了更稳定的效果。正确的工程决策不是要求一个镜头完成所有任务，而是让设备、模型和业务目标相互匹配。

第 14 章 GIS、施工场景与业务流程勘察

14.1 坐标体系必须明确

现场可能同时存在 WGS84、GCJ-02、CGCS2000、地方坐标和施工工程坐标。天地图底图、无人机航迹、摄像头 GPS、设计图纸和人工测量点位可能来自不同坐标体系。

勘察报告必须记录每类数据的坐标系、单位、精度、转换方法和责任人。转换后的结果应使用现场明显控制点抽样核验。不得通过“看起来差不多”确认坐标正确。

14.2 GIS 对象与更新责任

确认项目边界、标段、工区、危险区、禁入区、出入口、摄像头、塔吊、基坑、材料区、应急点、临时道路和无人机起降点。每类对象应明确几何类型、属性字段、数据来源、更新频率和审核人。

施工区域会变化，GIS 图层必须具备版本和生效时间。危险区边界调整后，应同步检查 BVE 的 ROI、事件落点和 Agent 查询结果，避免地图与 AI 使用不同版本的区域定义。

14.3 施工工序与时间维度

同一摄像头在不同阶段可能承担不同任务。白天是钢筋加工区，夜间可能停工；桥面铺装完成后，原临边危险区可能撤销；动火作业只在审批时段有效。

因此，勘察不仅记录空间，还应记录工序、班次、作业时间、停工规则、临时许可和阶段切换条件。后续规则引擎应支持按项目阶段和时段启停，而不是永久运行同一套规则。

14.4 业务闭环访谈

针对每个风险场景访谈安全负责人、班组负责人和监理：谁接收告警、谁确认、谁整改、允许多长时间、需要什么证据、谁复核、何时升级、哪些误报可以忽略、哪些事件必须形成工单。

如果现场没有明确的整改责任和销项规则，即使 AI 能发现风险，也无法形成生产价值。实施方案应把业务流程缺口作为组织问题提出，而不是由 Agent 或算法自行猜测。

14.5 无人机与移动设备预留

涉及无人机巡检时，勘察起降点、飞行边界、禁飞区、通信覆盖、桥下 GPS-Denied 区域、视觉定位条件、紧急迫降点和地面安全员位置。对于 DJI Manifold 3，应记录安装、供电、网络、散热、固件和远程维护条件。

无人机采集的航迹和事件需映射到 GIS。经纬度航线进入桥下相对坐标环境时，必须单独设计坐标原点、姿态、尺度和坐标转换验证，不得直接沿用地面 GPS 逻辑。

第 15 章 勘察输出、问题分级与方案评审

15.1 勘察交付物

完整勘察包建议包含：

现场勘察报告；

网络拓扑与端口矩阵；

服务器、机房和边缘节点清单；

摄像头主数据和 AI 适配评分；

GIS 数据与坐标说明；

施工场景和业务流程说明；

现场照片、视频和测试日志；

问题、风险和前置条件清单；

实施架构建议；

实施条件确认单。

15.2 问题分级

P0 阻断项：不解决无法部署或存在安全风险，例如无服务器权限、网络完全不通、关键账号缺失、机房无稳定电源。

P1 上线前必改项：可以继续准备，但生产上线前必须关闭，例如关键摄像头无法稳定取流、坐标系未确认、默认密码未修改。

P2 优化项：不阻断首批上线，可在灰度或试运行中优化，例如部分摄像头角度、次要页面性能或报表格式。

P3 后续项：属于下一阶段或范围外需求，通过变更流程管理。

每个问题必须包含影响、责任单位、责任人、计划日期、验证方式和状态。只写“待客户处理”不构成有效管理。

15.3 架构决策记录

关键方案取舍使用 **Architecture Decision Record (ADR)** 记录。内容包括背景、候选方案、约束、决策、理由、影响、风险和回退条件。

典型 ADR 包括：视频接入采用 RTSP 直连还是第三方平台；推理位于中心服务器还是边缘节点；PostgreSQL 使用现场部署还是中心部署；Apple Silicon 环境采用 MLX 原生服务还是 CPU 容器；录像保存于 MinIO 还是现有视频平台；远程维护采用 VPN、Tailscale 还是堡垒机。

15.4 实施方案的最小内容

实施方案至少应覆盖总体架构、部署拓扑、网络与端口、资源容量、视频接入、GIS、BVE 与 AI、Agent 与 RAG、数据存储、安全、监控、备份恢复、实施计划、组织责任、风险、试运行和验收。

每个章节都应区分：已确认事实、设计决策、待办条件和假设。假设必须有验证日期，不能长期作为事实使用。

15.5 方案评审与冻结

评审参与方至少包括建设单位、施工单位、监理和 BridgeAI 项目团队。涉及网络、安全、视频平台或无人机时，应邀请对应专业负责人。

评审结论分为通过、有条件通过和退回修改。有条件通过项必须形成明确关闭条件；未关闭的 P0、P1 问题不得通过“会议同意”被掩盖。评审通过后形成实施基线，后续调整通过变更单管理。

工程案例：第二次进场比第一次更重要

示例项目第一次勘察后，施工单位完成了 VLAN 调整和摄像头编码整改。第二次进场复核发现网络问题已关闭，但两个高风险工区因施工进度变化更换了围挡和材料堆放位置，原计划的 ROI 已失效。

项目组据此增加“施工阶段复核”门禁：每个 AI 场景上线前，由安全员确认当前工区布局与勘察基线一致。这个机制比一次性勘察更重要，因为现场事实会持续变化。

现场勘察 SOP

准备：确认授权、资料、人员、安全要求和测试工具。

进场：签到、安全教育、确认陪同人员和勘察路线。

网络：绘制边界，测试关键链路、带宽、端口和远程维护。

设备：登记服务器、机房、摄像头、NVR、边缘节点和电源。

场景：核对工序、风险、人员动线、光照、遮挡和 AI 适配。

GIS：确认坐标系、边界、点位和更新责任。

业务：确认告警、工单、整改、复核、升级和验收流程。

收尾：汇总阻断项，现场确认事实，约定补充资料和复核日期。

输出：两日内形成初步问题清单，约定周期内提交正式勘察报告和实施方案。

附录 D 现场勘察记录表

项目名称：

勘察日期：

勘察地点：

BridgeAI 负责人：

建设／施工／监理陪同人员：

现场安全要求：

一、网络与远程维护

网络区域 | 源地址 | 目标地址 | 协议端口 | 测试结果 | 责任人 | 证据编号

二、服务器与机房

设备编号 | 位置 | CPU／内存／GPU | 磁盘 | 操作系统 | 电源 UPS | 温度散热 | 结论

三、视频与摄像头

摄像头编号 | 位置 | 协议 | 分辨率 | 编码 | 取流 | 夜间 | AI 适配 | 整改项

四、GIS 与施工场景

对象 | 坐标系 | 数据来源 | 精度 | 更新人 | 核验结果

五、问题与风险

编号 | 等级 | 问题 | 影响 | 责任单位 | 计划日期 | 验证方式 | 状态

六、现场确认

建设单位：

施工单位：

监理单位：

BridgeAI：

附录 E 摄像头 AI 适配评估表

摄像头编号：

工区与位置：

候选 AI 场景：

典型作业距离：

目标像素范围：

白天画面：合格／有条件／不合格

夜间画面：合格／有条件／不合格

遮挡情况：轻／中／重

取流稳定性：合格／有条件／不合格

目标可见性评分（1～5）：

视角稳定性评分（1～5）：

光照质量评分（1～5）：

取流稳定性评分（1～5）：

业务有效性评分（1～5）：

整改建议：

评估结论：直接上线／整改后上线／更换场景／增设设备／不建议上线

评估人：

审核人：

日期：

第四篇 基础环境、平台与数据底座部署

第 16 章 部署模式与环境基线

16.1 三类部署模式

BridgeAI-Site 常见部署分为中心部署、边缘—中心协同和离线／专网部署。

中心部署适合网络稳定、视频可集中访问、统一运维的项目。平台、数据库、Agent 和主要 BVE 节点部署在中心服务器。

边缘—中心协同适合弱网、多工区或低时延场景。边缘节点负责取流、推理、事件与证据缓存，中心平台负责项目管理、工单、Agent、知识库、报表和统一运维。

离线或专网部署适合数据不能出域的项目。模型、知识库、数据库和运维工具均在现场网络运行，升级通过受控介质和离线包完成。

部署模式由网络、数据安全、视频位置、GPU 资源、运维能力和业务连续性共同决定，不能只按服务器数量选择。

16.2 BridgeAI 本地研发与集成基线

BridgeAI 的主力本地环境采用 Mac Studio、Apple M3 Ultra、512GB 统一内存和本机 PostgreSQL，优先用于系统研发、Agent 编排、RAG、数据处理、模型验证和集成交付包制作。

推荐分层运行：

macOS 宿主机：PostgreSQL、MLX 推理服务、开发工具、模型与数据工作区；

Docker：Redis、MinIO、API、Worker、Web、Nginx 和监控组件；

原生 MLX Runtime：通过本地 HTTP/Unix Socket 向容器服务提供推理能力；

外部边缘节点：通过受控网络接入中心 API 和对象存储。

在 macOS 上，Linux 容器不能直接等同于原生 Metal/MLX 运行环境。因此需要 GPU 加速的 MLX 服务宜在宿主机原生运行，并通过明确的接口与容器化业务服务解耦。容器内不得把 host.docker.internal 等开发连接方式硬编码到业务代码，应通过环境变量配置。

16.3 Linux/NVIDIA 生产基线

现场生产服务器采用 Linux 与 NVIDIA GPU 时，需固定操作系统、内核、驱动、CUDA、cuDNN、TensorRT、Docker 和 NVIDIA Container Runtime 版本。模型导出的 TensorRT Engine 必须在目标 GPU 和目标软件栈上验证，不应把其他设备生成的 Engine 直接视为可移植产物。

生产环境优先使用不可变镜像、版本标签、校验和与发布记录。禁止使用 latest 作为可验收版本。

16.4 边缘设备基线

GPU 工控机应具备 AI Runtime、Media、事件缓存、证据缓存、心跳、远程维护和断网补传能力。DJI Manifold 3 使用目标设备侧 TensorRT Engine，并通过 DPK 管理应用安装和回滚。

边缘设备必须有唯一设备编号，记录硬件、固件、操作系统、驱动、模型、Engine、应用包、配置、安装时间和责任人。

16.5 环境隔离

至少区分开发、测试、预生产和生产环境。小型项目可以共用物理服务器，但数据库、对象存储桶、账号、域名、配置和日志必须逻辑隔离。

生产数据不得未经批准复制到开发环境。模型、Prompt、规则和数据库 Migration 应经过测试环境验证后进入生产。

16.6 版本矩阵

建立版本矩阵：

平台版本；Web/API/Worker/Agent/BVE 镜像；

PostgreSQL、PostGIS、pgvector、Redis、MinIO；

操作系统、Docker、Nginx；

GPU 驱动、CUDA、TensorRT 或 macOS、MLX；

模型、标签、ONNX、Engine、Prompt、Rule 和数据库 Schema；

部署日期、发布人、审核人和回滚版本。

第 17 章 目录、网络、配置与密钥

17.1 标准目录

建议部署目录：

/opt/bridgeai/

— compose/	Docker Compose 与环境文件
— config/	Nginx、服务与监控配置
— data/	持久化挂载点
— models/	模型、ONNX、Engine 与元数据
— prompts/	Prompt 与评测集
— scripts/	部署、备份、恢复与巡检脚本
— logs/	必要的宿主机日志
— releases/	版本包、校验和与回滚包
— docs/	部署记录、端口和运维说明

数据目录和发布目录分离。升级时替换版本与配置，不应覆盖数据库、对象存储和原始证据。

17.2 网络分区

建议划分入口区、应用区、数据区、AI／媒体区、监控区和运维区。小规模 Docker Compose 可以使用独立 Docker Network 实现逻辑分区；生产环境通过防火墙、安全组或 VLAN 强化边界。

只有 Nginx 或 API Gateway 对用户侧开放。数据库和内部服务仅允许必要的访问。边缘节点使用设备身份、令牌或双向证书连接中心平台。

17.3 端口管理

每个端口必须说明用途、绑定地址、是否加密、认证方式和开放范围。优先绑定内网地址或 127.0.0.1；容器端口不需要对宿主机发布时，不应写 ports。

端口变更必须同步更新防火墙、Nginx、监控、部署文档和验收脚本。

17.4 配置分层

配置分为默认配置、环境配置、项目配置和运行时配置。

默认配置随代码管理；环境配置描述数据库、存储、域名和服务地址；项目配置描述工区、摄像头、规则、通知和权限；运行时配置由数据库或配置中心管理，并具备版本与审计。

环境变量只传递部署差异和密钥引用，不应承载大量业务规则。配置发布前进行 Schema 校验，避免拼写错误在运行时才暴露。

17.5 密钥与凭证

数据库密码、JWT 密钥、对象存储密钥、第三方平台令牌、证书私钥和 Agent 外部服务密钥不得写入 Git、镜像、公开文档和日志。

小型现场项目至少使用独立的 secrets 文件并限制文件权限；成熟环境使用 Vault、云密钥管理或容器 Secret。密钥应具备所有者、用途、创建日期、轮换周期和吊销方法。

17.6 时间、命名与编码

所有服务器、摄像头、NVR 和边缘节点统一时间源。事件、视频、工单和审计使用带时区的时间戳；项目界面按项目时区展示。

数据库、对象存储、文件名和 API 统一使用 UTF-8。资源命名应稳定、可读、避免依赖人员姓名和临时 IP。

第 18 章 平台部署与发布控制

18.1 推荐部署顺序

宿主机与时间同步

→ Docker／运行时

→ 目录、网络与 Secrets

→ PostgreSQL

→ Redis

→ MinIO

→ Migration 与初始化数据

→ API

→ Worker

→ Agent Runtime

→ BVE／AI Runtime

→ Media

→ Web

→ Nginx／HTTPS

→ Monitoring／Logging

→ 备份任务

→ 健康检查与冒烟测试

部署顺序的目的不是形式统一，而是让依赖问题尽早暴露。上游服务未健康时，不应通过反复重启下游服务掩盖错误。

18.2 Docker Compose 分组

建议使用 profile 或多文件组合：

core: PostgreSQL、Redis、MinIO；

app: API、Worker、Web；

agent: Agent Runtime 与相关服务；

media: Media 与视频网关；

ai-nvidia: NVIDIA BVE Runtime；

observability: Prometheus、Grafana、日志组件；

backup: 备份和巡检任务。

Mac Studio 本地环境可不启用 ai-nvidia，而连接宿主机原生 MLX 服务。生产环境根据 GPU 和边缘架构启用对应 Runtime。

18.3 镜像与发布包

每个镜像记录仓库、版本、构建时间、Git Commit、基础镜像和校验和。发布包包含 Compose、环境变量模板、Migration、初始化脚本、Nginx、监控、模型元数据、校验和和回滚说明。

发布包应可以在无开发源码的情况下完成标准部署。需要现场修改的参数必须集中在配置文件中，禁止直接进入容器修改代码。

18.4 健康检查

健康检查分为进程、依赖和业务三层。

进程健康：容器或服务是否运行；

依赖健康：数据库、Redis、MinIO、模型和外部接口是否可用；

业务健康：登录、项目查询、事件写入、文件上传、Agent 查询和 BVE 测试任务是否成功。

仅显示容器 Up 不能证明系统健康。关键服务应提供 **readiness** 和 **liveness**；依赖未就绪时拒绝接收生产流量。

18.5 数据库 Migration

Migration 必须可重复、可审计，并在测试环境使用生产同版本数据库验证。上线前备份，执行后核对 **Schema**、基础数据和关键查询。

破坏性变更优先采用扩展—迁移—收缩模式：先增加兼容字段或表，完成数据迁移和应用切换，再在后续版本删除旧结构。避免在同一次发布中直接删除生产数据依赖。

18.6 灰度、回滚与紧急停止

平台升级可按管理端、单项目或单节点灰度。模型、**Prompt**、**Rule** 和应用版本分别记录，避免出现“应用已回滚但规则未回滚”的不一致。

回滚前明确数据库是否兼容、事件是否重复、对象文件是否需要清理。紧急停止应能快速关闭高风险 **Agent** 写操作、**AI** 告警发布或问题模型，同时保持基础查询和证据访问能力。

工程案例：容器都正常，系统却不能登录

示例项目首次部署后，所有容器均显示运行，但 **Web** 登录持续返回 500。排查发现 **API** 已启动，数据库 **Migration** 因 **PostGIS** 扩展缺失而失败；容器重启策略又不断拉起 **API**，使问题看起来像偶发故障。

项目组修正流程：数据库扩展和 **Migration** 成为独立质量门禁，**API readiness** 必须检查 **Schema** 版本。此后“容器 Up”不再作为部署完成的判断标准。

第 19 章 PostgreSQL、Redis 与 MinIO 数据底座

19.1 PostgreSQL 作为系统事实源

PostgreSQL 保存项目、组织、用户、摄像头、空间对象、AI 任务、事件、风险、工单、模型元数据、Agent 审计和配置版本。它是业务状态的事实源，不应把关键状态仅保存在 Redis、日志或 Agent 对话中。

建议为应用、Migration、只读报表、备份和运维分别创建角色，遵循最小权限。应用账号不应拥有创建超级用户、修改系统配置或绕过审计的权限。

19.2 扩展与版本

推荐启用 PostGIS、pgvector、pg_trgm 和 btree_gist。扩展版本纳入环境矩阵，并在备份恢复目标环境中预先验证。

PostGIS 支撑工区、点位、轨迹和空间查询；pgvector 支撑知识与语义检索；pg_trgm 支撑中文名称、设备和文档标题的模糊检索；btree_gist 支撑部分时间与范围约束。

19.3 Schema 分层

可按领域划分 Schema 或清晰的表前缀：

identity：用户、组织、角色和权限；

project：项目、标段、工区和参建单位；

asset：摄像头、NVR、服务器、边缘设备；

gis：点、线、面、坐标与版本；

vision：模型、任务、ROI、规则、检测与事件；

workflow: 工单、整改、复核和通知;

agent: 会话、任务、工具调用、审批和审计;

knowledge: 文档、分块、向量、版本和引用;

ops: 配置、发布、健康、告警和备份记录。

分层是为了边界和治理，不应过度拆分到增加开发复杂度。关键是每个数据对象有明确所有者和生命周期。

19.4 空间数据治理

所有空间字段使用明确 **SRID**; 写入前验证几何有效性; 关键区域保留版本、生效时间和来源。事件落点应记录生成方式: 摄像头固定点、ROI 中心、无人机位置或人工校正。

坐标转换逻辑应由统一 GIS 服务处理, 禁止多个前端和脚本各自实现不同转换。

19.5 向量检索与知识版本

pgvector 中的向量必须关联原文档、版本、页码或段落、权限、有效期和解析模型。文档更新时不能只新增向量而不失效旧版本, 否则 **Agent** 可能同时引用相互冲突的制度。

检索结果应经过权限过滤和版本过滤, 再进行语义排序。无可用资料时返回“未找到依据”, 而不是由大模型补充未授权知识。

19.6 Redis 使用边界

Redis 用于 Session、Cache、Queue、短期 Agent Memory、分布式锁、限流和临时状态。任何需要长期追溯、验收或恢复的记录都应落入 PostgreSQL 或对象存储。

配置内存上限、淘汰策略、持久化方式和重启行为。队列任务应具备幂等键、重试次数、死信处理和可观察状态，避免重启后重复创建工单或事件。

19.7 MinIO 对象存储

建议桶：

bridgeai-media：原始视频、截图与短视频；

bridgeai-events：事件证据包；

bridgeai-models：模型、ONNX、Engine 和元数据；

bridgeai-reports：日报、周报、验收和导出文件；

bridgeai-documents：RAG 原文档与解析产物；

bridgeai-backups：数据库、配置和关键备份。

每个桶配置访问策略、版本、生命周期、容量告警和审计。对象键应包含项目、日期、类型和唯一 ID，但不暴露密码或敏感个人信息。

19.8 初始化数据与一致性

首次部署初始化企业、项目、组织、角色、用户、字典、风险等级、工单状态、Agent 定义、工具权限、Prompt、规则模板和通知策略。

初始化脚本必须可重复执行或能识别已存在数据。完成后生成初始化报告，记录数据版本、执行时间、结果和异常。

第 20 章 入口安全、可观测性与运行基线

20.1 Nginx 与统一入口

Nginx 负责 HTTPS、域名、反向代理、静态资源、WebSocket、SSE、上传限制、视频代理、安全响应头和访问日志。外部用户不应直接访问内部容器端口。

分别配置 Web、API、Agent 流式输出和视频服务的超时。视频和大文件使用与普通 API 不同的缓存和超时策略，避免一个全局配置导致流媒体中断或 API 长时间占用连接。

20.2 HTTPS 与证书

生产系统必须使用 HTTPS。验证证书链、域名、有效期、自动续期、私钥权限和到期告警。内网无公网域名时，可使用企业 CA 或受控证书体系，但客户端必须正确安装信任链。

证书更新应有演练和回滚方案，避免到期后才临时处理。

20.3 身份、权限与审计

初始化超级管理员、企业管理员、项目管理员、安全负责人、安全员、班组负责人、监理、运维和访客。测试菜单权限、数据权限、项目隔离、工单状态权限、Agent 工具权限、下载权限和审计权限。

高权限账号不用于日常操作。临时实施账号设置到期时间，项目移交后回收。关键操作记录人员、时间、对象、旧值、新值、来源 IP 和关联审批。

20.4 日志、指标与追踪

日志至少覆盖 Nginx、API、Worker、Agent、BVE、Media、PostgreSQL、Redis、MinIO 和边缘节点。统一时间、项目 ID、请求 ID、事件 ID 和任务 ID，支持跨服务关联。

核心指标包括：服务健康、请求错误率、响应时间、数据库连接、慢查询、队列长度、对象存储容量、摄像头在线率、取流重连、推理 FPS、GPU／内存／温度、事件量、Agent 调用、工具失败和备份状态。

复杂链路可引入分布式追踪，但不要在基础日志尚不完整时先追求高级平台。最小目标是发生故障后能够回答“哪一层、何时、影响哪些项目、从哪个版本开始”。

20.5 告警分级

P1：核心系统不可用、数据库异常、证据无法保存、数据安全事件；

P2：关键服务异常、多个摄像头离线、AI 节点不可用、队列严重积压；

P3：单路摄像头离线、磁盘容量预警、第三方接口不稳定；

P4：趋势提醒、证书即将到期、模型效果下降和容量规划。

告警必须有接收人、静默规则、升级路径和恢复通知。没有责任人的告警只会制造噪声。

20.6 安全基线

上线前检查：默认密码、端口暴露、操作系统补丁、镜像来源、文件权限、Secrets、HTTPS、RBAC、审计、备份加密、恶意上传、防止目录遍历、API 限流和第三方依赖。

Agent 工具额外检查参数 Schema、资源范围、超时、重试、幂等、审批和审计。模型文件和 DPK 包验证校验和与来源，防止错误或被替换的发布包进入生产。

第 21 章 备份、恢复与部署验收

21.1 先定义 RPO 和 RTO

RPO 表示可接受的数据丢失时间窗口，RTO 表示可接受的恢复时间。不同数据应分别定义：业务数据库、事件证据、模型与配置、知识文档、录像和日志的价值不同，不能采用一条统一口号。

示例：核心业务数据库 RPO 24 小时以内、重大项目可缩短至 1 小时；配置和版本包每次发布备份；事件证据根据合同和容量策略保存；原始连续录像可由既有视频平台承担。

21.2 PostgreSQL 备份

至少配置定期逻辑备份，并根据规模选择物理备份与 WAL 归档。备份文件记录数据库版本、时间、项目范围、校验和、加密和保留周期。

备份成功日志不等于可恢复。必须定期在隔离环境执行恢复，验证扩展、Schema、数据量、关键查询、用户权限和应用连接。

21.3 对象、配置与发布资产备份

MinIO 重要桶启用版本或复制策略；Compose、Nginx、环境模板、Prompt、Rule、模型元数据和发布记录纳入版本库和离线归档。密钥备份应加密并限制访问，不得与明文密码放在同一目录。

模型权重、ONNX、TensorRT Engine 和 DPK 包保存校验和。目标设备上的 Engine 需要与设备型号、TensorRT 和 CUDA 版本关联。

21.4 恢复优先级

推荐恢复顺序：

基础网络与域名

→ PostgreSQL

- MinIO
- Redis／队列必要状态
- API 与 Worker
- 用户和权限验证
- Agent 与知识库
- Media 与 BVE
- 边缘节点重连
- 事件与工单抽样核验

恢复过程中保持写入控制，避免部分服务提前启动造成数据重复或状态不一致。

21.5 恢复演练

演练场景至少包括：数据库误删除、服务器故障、磁盘满、证书失效、错误版本发布、对象文件丢失、边缘节点重装和网络长时间中断。

每次演练记录触发、人员、步骤、耗时、问题、实际 RPO／RTO 和改进项。无法在约定时间内恢复时，应调整架构或验收承诺。

21.6 部署验收清单

基础环境：服务器、系统、时间、网络、DNS、证书和远程维护符合基线。

数据底座：PostgreSQL、扩展、Migration、Redis、MinIO、初始化和备份恢复通过。

应用服务：Web、API、Worker、Agent、Media、BVE 和监控健康。

安全：默认密码修改、端口受控、HTTPS、RBAC、审计和 Secrets 合格。

业务冒烟：登录、项目、GIS、摄像头、事件、工单、Agent 查询和报告生成成功。

运维：日志可查、告警可达、巡检脚本可用、版本和回滚包齐全。

只有上述基线通过，才能进入第五篇的视频、GIS 和现场设备正式接入。

工程案例：第一次恢复演练暴露了真正风险

示例项目部署完成后，数据库每日备份均显示成功。恢复演练时发现备份服务器未安装 PostGIS 扩展，导致空间表恢复失败；同时 MinIO 中的事件截图未包含在原备份计划中。

项目组补充目标环境扩展检查、对象存储版本策略和恢复冒烟脚本。通过演练发现问题的成本远低于事故后才发现“备份无法使用”。

平台部署 SOP

确认实施基线与版本矩阵。

备份现有环境和配置。

准备目录、网络、账号与 Secrets。

部署 PostgreSQL、扩展、Redis 和 MinIO。

执行 Migration 与初始化。

部署 API、Worker、Agent、Media、BVE 与 Web。

配置 Nginx、HTTPS、监控、日志和告警。

执行健康检查、业务冒烟和安全检查。

完成首次备份与恢复验证。

记录版本、结果、问题和回滚包。

由项目经理和运维负责人确认进入设备接入阶段。

附录 F 环境准备确认表

项目：

环境：开发／测试／预生产／生产

服务器编号与位置：

操作系统与版本：

CPU／内存／GPU：

磁盘与可用容量：

网络区域与 IP：

DNS／NTP：

Docker 与运行时：

CUDA／TensorRT 或 macOS／MLX：

PostgreSQL：本机／容器／远程

域名与证书：

远程维护方式：

电源、UPS、散热：

阻断问题：

确认结论：就绪／有条件就绪／未就绪

实施工程师：

客户网络负责人：

日期：

附录 G 部署与发布记录

发布编号：

环境：

发布日期：

变更单：

平台版本：

镜像与校验和：

数据库 Schema 版本：

模型／Prompt／Rule 版本：

部署前备份：

执行人员：

审批人员：

开始时间：

结束时间：

健康检查结果：

业务冒烟结果：

安全检查结果：

遗留问题：

回滚条件：

回滚包位置：

最终结论：成功／有条件成功／回滚

附录 H 备份与恢复演练记录

演练编号：

演练场景：

目标 RPO：

目标 RTO：

备份来源：

恢复环境：

开始时间：

结束时间：

实际数据丢失窗口：

实际恢复耗时：

PostgreSQL 验证：

PostGIS/pgvector 验证：

MinIO 验证：

用户与权限验证：

事件与工单验证：

Agent 与知识库验证：

发现问题：

整改责任人：

计划完成时间：

演练结论：通过／有条件通过／不通过

第 22 章 备份体系深化：迁移与灾难恢复

22.1 备份不是“有一个文件”

项目现场经常把“数据库每天生成一个压缩包”理解为已经具备备份能力。真正可交付的备份体系必须回答四个问题：备份了什么、备份是否完整、备份保存在哪里、发生故障时能否在目标时间内恢复。

BridgeAI-Site 的关键状态分散在不同组件中：PostgreSQL 保存业务数据、空间数据、Agent 审计和模型元数据；MinIO 保存截图、录像、报告、知识文档和模型文件；Redis 可能保存队列、缓存、会话和短期记忆；宿主机目录保存配置、证书、脚本、日志索引和版本清单。只备份数据库，无法恢复证据文件；只备份对象存储，无法重建业务关系；只保留容器镜像，也不能恢复现场配置。

22.2 备份对象分级

建议将数据划分为四级：

A 级核心数据：项目、组织、用户、权限、摄像头、GIS、事件、工单、审计、模型与规则元数据。要求每日全量或基线备份，并结合持续归档或高频增量。

B 级证据数据：事件截图、短视频、整改照片、报告和验收材料。要求按生命周期和容量策略备份，关键事件可设置更长保留期。

C 级工程配置：Docker Compose、Nginx、环境变量模板、Migration、Prompt、Tool Schema、ROI、规则、监控和告警配置。要求进入版本库并形成发布包。

D 级可再生数据：缓存、临时转码文件、推理中间结果和可重新生成的索引。通常不需要长期备份，但必须明确重建步骤和预计耗时。

22.3 RPO 与 RTO

RPO（Recovery Point Objective）表示可接受的数据丢失窗口；RTO（Recovery Time Objective）表示从故障发生到业务恢复的目标时间。

示例项目可以设定：

- PostgreSQL 核心业务数据 RPO 不超过 1 小时，RTO 不超过 4 小时；
 - 高风险事件证据 RPO 不超过 24 小时，关键证据优先异地复制；
- Web、API 和 Agent 服务 RTO 不超过 2 小时；
 - 单个边缘节点故障时，中心平台仍可运行，现场 AI 任务按降级策略恢复；
 - 完整灾难恢复目标以合同和现场基础条件为准。

RPO 和 RTO 不能只写进文档，还必须转化为备份频率、存储位置、脚本、人员和演练计划。

22.4 PostgreSQL 备份策略

小型项目可采用每日 `pg_dump` 全量备份，并定期验证可恢复性。数据量和连续性要求提高后，应使用物理备份、WAL 归档或复制机制，以支持时间点恢复。

备份文件应包含：数据库内容、角色和权限、扩展清单、Migration 版本、Schema 校验结果和校验和。PostGIS、pgvector 等扩展必须在恢复目标环境中提前安装兼容版本。

禁止仅在生产数据库所在磁盘保存备份。至少保留一份独立介质或异地副本，并配置保留周期、加密、访问控制和删除审计。

22.5 MinIO 与证据数据

MinIO 应根据 Bucket 重要性设置版本控制、生命周期和复制策略。`bridgeai-events`、`bridgeai-reports`、`bridgeai-documents`、`bridgeai-models` 和 `bridgeai-backups` 不应使用完全相同的保留周期。

事件证据的生命周期应同时考虑验收、事故追溯、隐私和存储成本。删除策略必须经过项目负责人或数据责任人批准，不能由运维人员临时清理磁盘时自行决定。

22.6 恢复演练

恢复演练至少包含：

1. 在独立环境部署兼容版本；

2. 恢复 PostgreSQL;
3. 恢复 MinIO 对象;
4. 恢复配置、证书和密钥引用;
5. 启动平台服务;
6. 校验用户、项目、摄像头、事件、工单和审计;
7. 抽样打开截图、录像、报告和知识文档;
8. 验证 Agent 查询和工具权限;
9. 记录实际恢复时间、失败点和修正措施。

没有完成恢复演练的备份，只能称为“备份文件”，不能称为“恢复能力”。

22.7 版本迁移与回滚

平台升级应先读取当前版本、数据库 Migration、配置差异、模型和 Prompt 版本，再制定迁移路径。升级包必须包含：

- 发布说明;
- 兼容性说明;
- 数据库变更;
- 配置变更;
- 模型、Prompt 和规则变更;
- 健康检查;
- 回滚条件和步骤;
- 升级后验证用例。

涉及不可逆数据库变更时，应先备份并在副本环境演练。回滚不能只回退容器镜像，还要处理 Schema、数据和配置的兼容性。

第 23 章 容量、性能与资源治理

23.1 容量规划从业务负载出发

BridgeAI-Site 的资源消耗主要来自视频解码、AI 推理、事件录像、数据库查询、对象存储、Agent 调用和报表任务。不能仅按照“摄像头数量”估算服务器，因为相同数量的摄像头可能具有不同分辨率、码率、采样 FPS、模型复杂度和并发任务。

容量规划至少需要以下输入：

- 视频路数、编码、分辨率、帧率和码率；
- 每路采样 FPS、模型和输入尺寸；
- 同时在线的 AI 任务数量；
- 事件发生频率和每个事件保存的录像长度；
- Web 并发用户和视频墙规模；
- Agent 并发、上下文长度、工具调用和模型位置；
- 数据保留周期；
- 报表和批处理窗口；
- 未来 6~12 个月的扩展计划。

23.2 视频与 AI 计算预算

视频链路应分别测量解码吞吐、预处理、推理、跟踪、规则和编码写盘。单纯使用模型 FPS 作为容量依据，会忽略视频重连、缓冲、录像、画面叠加和多任务调度开销。

建议以“单路完整流水线资源基线”作为测量单位：在目标硬件上运行真实视频，记录 CPU、GPU、统一内存或显存、解码占用、端到端延迟、温度和功耗，再按照并发路数逐步扩容，观察资源曲线和稳定性。

在 Mac Studio M3 Ultra 本地研发和中心部署环境中，可优先验证 Apple Silicon、统一内存、MLX 或兼容的视频处理链路；在 NVIDIA 或边缘设备上，则分别建立 CUDA、TensorRT 和设备侧解码的基线。不同硬件平台的指标不得直接互相替代。

23.3 存储容量估算

录像和事件证据是存储增长的主要来源。粗略估算可以使用：

每日原始视频容量 $\approx$ 码率 $\times$ 86400 秒 $\div$ 8。

例如一路 4 Mbps 视频持续录像，每天约产生 43 GB 数据。20 路持续录像约为 860 GB/天，显然不能在没有生命周期策略的情况下长期保存。

因此应区分：

- 原始视频由 NVR 或视频平台保存；
- BridgeAI-Site 保存事件相关短视频和截图；
- 高风险事件延长保留；
- 普通事件按周期归档或删除；
- 报告和验收证据采用长期保留策略。

容量规划应预留索引、版本、临时文件、备份和增长空间，生产磁盘长期使用率不宜逼近满载阈值。

23.4 PostgreSQL 性能基线

数据库上线前应完成：连接池、慢查询、索引、表膨胀、自动清理、备份窗口和磁盘延迟检查。

重点关注的查询包括：

- 项目首页统计；
- GIS 范围内的设备和事件查询；
- 按时间、工区、风险等级检索事件；
- 工单状态和逾期统计；
- Agent 工具查询；
- 报表聚合；
- pgvector 近邻检索。

空间查询应使用合适的 GIST 或 SP-GiST 索引；时间序列和大表可结合分区策略；向量检索索引应根据数据规模、召回要求和更新频率选择。任何索引都要通过真实查询计划验证，而不是机械增加。

23.5 Agent 资源治理

Agent 成本和延迟来自模型推理、上下文构造、RAG 检索、工具调用和重试。实施阶段应设置：

- 并发和速率限制；
- 单次调用超时；
- 工具重试上限；
- 上下文和附件大小限制；
- 大任务异步化；
- 结果缓存；

- 模型降级策略；
- 每个项目和角色的调用配额；
- 调用日志和成本统计。

报告生成、批量风险分析等长任务应进入队列，而不是占用同步请求。涉及外部大模型服务时，还要考虑网络、数据边界和供应商不可用的降级方案。

23.6 性能验收

性能测试应覆盖稳定负载、峰值负载和故障恢复，而不是只执行短时间压测。建议观察：

- 核心 API 的 P50、P95 和 P99 延迟；
- 视频首帧和播放稳定性；
- AI 端到端事件延迟；
- Agent 首字延迟和完整响应时间；
- 数据库连接、锁等待和慢查询；
- CPU、GPU、内存、磁盘和网络；
- 24~72 小时持续运行趋势；
- 单个服务重启、视频断流和网络抖动后的恢复时间。

测试数据、版本、负载模型、脚本和结果必须留档，才能作为后续扩容和故障分析的基线。

第 24 章 示例项目：一次“部署成功但系统不可用”的复盘

24.1 表面上的成功

示例项目完成第一轮部署后，所有容器均显示 **Running**，**Web** 页面可以打开，数据库 **Migration** 执行成功，监控面板也能看到主机指标。实施团队一度认为平台部署已经完成。

进入端到端联调后，问题集中出现：视频墙打开 9 路画面时浏览器频繁卡顿；事件录像偶尔生成空文件；**Agent** 查询当天高风险事件时需要十几秒；**MinIO** 磁盘增长远高于预期；数据库备份虽然每天成功，但从未进行恢复验证。

这说明“容器运行”只是组件状态，不是业务可用性。

24.2 根因分析

问题被拆分为五条根因链：

第一，视频代理和转码参数沿用了开发环境默认值，没有依据现场编码和并发规模调优。

第二，事件录像与实时推理争用同一磁盘和 CPU，峰值时写盘延迟导致录像封装失败。

第三，**Agent** 工具查询缺少时间和项目范围索引，**RAG** 和业务查询还在同步链路串行执行。

第四，**MinIO** 没有生命周期策略，调试截图、重复事件和临时文件持续累积。

第五，备份任务只检查命令退出码，没有检查文件校验和，也没有在隔离环境恢复。

24.3 整改措施

团队采取以下措施：

- 将视频播放、AI 分析和事件录像拆分资源预算，限制单节点并发；

- 调整视频代理缓存和超时，统一现场编码参数；
- 将事件录像写入独立目录并监控磁盘延迟；
- 为事件、工单、空间点位和 Agent 查询增加经过验证的索引；
- 将报告和复杂 Agent 任务改为异步队列；
- 对临时对象和普通事件设置生命周期；
- 建立每日备份、每月抽样恢复和季度完整演练；
- 将业务健康检查加入发布门禁。

24.4 业务健康检查

整改后，部署完成的判断标准变为：

1. 用户能够登录并进入正确项目；
2. GIS、摄像头和视频墙可用；
3. BVE 能产生真实事件和完整证据；
4. 事件可创建工单并完成状态流转；
5. Agent 能在权限范围内查询和生成结果；
6. 数据、日志和监控可追踪；
7. 备份能够恢复；
8. 关键故障有回滚和降级方案。

24.5 复盘结论

平台部署的交付对象不是一组进程，而是一套具有明确数据状态、业务状态和恢复能力的生产系统。部署验收必须从“服务健康”上升到“业务健康”。

附录 I 服务器与部署环境确认表

项目名称:

环境名称: 开发/测试/试运行/生产/灾备

部署位置: 中心机房/现场机房/边缘节点/云环境

一、主机与硬件

主机编号 | 用途 | CPU | GPU/加速器 | 内存 | 系统盘 | 数据盘 | 操作系统 | 责任人

二、网络

主机编号 | IP | VLAN | 网关 | DNS | NTP | 公网访问 | VPN/Tailscale | 防火墙状态

三、软件基线

操作系统版本:

Docker/容器运行时版本:

GPU 驱动/CUDA/TensorRT/MLX 版本:

PostgreSQL/Redis/MinIO 版本:

Nginx 版本:

部署包版本:

四、存储与目录

目录 | 用途 | 挂载点 | 容量 | 权限 | 备份策略 | 告警阈值

五、安全检查

- ☐ 默认密码已修改
- ☐ 数据库未暴露公网
- ☐ 管理端口受控
- ☐ HTTPS 可用
- ☐ 密钥未写入镜像或代码库
- ☐ 运维账号实名且可审计
- ☐ 远程访问具备停用机制

六、确认

实施工程师：

运维负责人：

项目经理：

确认日期：

附录 J 部署发布与回滚记录

发布编号：

项目／环境：

发布日期与窗口：

发布负责人：

批准人：

一、发布内容

组件 | 旧版本 | 新版本 | 变更说明 | 是否涉及数据迁移

二、发布前检查

- ☐ 变更已批准
- ☐ 备份完成且校验通过
- ☐ 发布包校验和一致
- ☐ 数据库 Migration 已演练
- ☐ 回滚包已准备
- ☐ 监控和告警正常
- ☐ 相关人员已通知

三、执行记录

时间 | 步骤 | 执行人 | 结果 | 日志／证据

四、发布后验证

- ☐ Web 与 API 正常
- ☐ GIS 与视频正常
- ☐ BVE 与事件链路正常
- ☐ 工单流程正常
- ☐ Agent 与 RAG 正常
- ☐ 监控、日志、备份正常
- ☐ 无新增 S1／S2 缺陷

五、回滚

回滚触发条件：

回滚步骤：

回滚结果：

数据处理说明：

六、结论

成功／有条件成功／已回滚／需继续观察

附录 K 备份恢复演练记录

演练编号：

演练日期：

演练环境：

演练负责人：

一、演练目标

数据库恢复／对象存储恢复／配置恢复／单服务故障／整站恢复／异地恢复

二、备份来源

备份时间 | 数据范围 | 文件位置 | 大小 | 校验和 | 保留策略

三、执行过程

时间 | 操作 | 执行人 | 结果 | 问题 | 证据

四、恢复验证

- ☐ 用户和权限正确
- ☐ 项目、设备和 GIS 数据正确
- ☐ 事件和工单关系正确
- ☐ 截图、录像和报告可打开
- ☐ Agent 审计和知识文档可用
- ☐ 核心服务健康
- ☐ 监控和告警恢复

实际 RPO:

实际 RTO:

未恢复或异常数据:

五、改进项

编号 | 问题 | 影响 | 整改措施 | 责任人 | 期限 | 验证结果

第二轮完成说明

本轮已完成第三篇“现场勘察与实施方案确认”和第四篇“基础环境、平台与数据底座部署”的出版化扩写。内容从现场事实采集、AI 适配、GIS 与业务流程勘察，延伸到部署模式、配置与密钥、平台发布、PostgreSQL／Redis／MinIO、入口安全、可观测性、备份恢复和容量治理，并

补充了现场勘察表、摄像头 AI 适配表、服务器环境表、发布回滚记录和恢复演练记录。下一轮将进入第五篇“视频、GIS 与现场设备接入”和第六篇“BVE 与 AI 场景工程化实施”。

第五篇 视频、GIS 与现场设备接入

第 25 章 视频接入不是“能播放”，而是建立生产数据源

25.1 视频是系统的第一类生产输入

在 BridgeAI-Site 中，视频不是页面上的装饰组件，而是 BVE、事件证据、风险分析和工单闭环共同依赖的生产数据源。一路视频只有同时满足可访问、可持续、可解析、可追踪和可恢复五个条件，才算完成生产接入。

可访问，指 Media 和 BVE 节点能够从实际部署网络访问视频源，而不是只有项目部电脑或厂商客户端可以观看。

可持续，指播放地址、令牌、账号权限和并发限制能够支持长期运行，不依赖人工每天重新登录或刷新临时地址。

可解析，指编码、分辨率、帧率、时间戳和音视频封装能够被目标解码器稳定处理。

可追踪，指视频源与项目、工区、摄像头编号、GIS 点位、AI 任务和运维责任人存在唯一关系。

可恢复，指断流、设备重启、网络抖动和平台令牌更新后，系统能够自动重连或进入明确的降级状态。

因此，视频接入验收不能以“打开过一次画面”为依据，而应以持续运行、故障恢复和端到端业务验证为依据。

25.2 四层视频接入架构

推荐将视频链路分为四层：

设备源层：摄像头、NVR、无人机、移动终端和第三方视频平台；

接入网关层：RTSP、ONVIF、GB28181、厂商 SDK、萤石云或项目已有视频平台适配器；

Media 层：取流、协议转换、解复用、转码、分发、录像、缓存和重连；

消费层：Web 视频墙、BVE、事件录像、人工回放和第三方系统。

分层的目的，是避免 Web 播放器、BVE 和录像服务分别直接连接摄像头。多个消费者直接取流会增加设备并发压力，使密码和地址散落在多个服务中，也会导致各自实现不同的重连策略。生产系统应尽量由 Media 层建立受控连接，再向不同消费者提供标准化输出。

25.3 接入协议的选择原则

RTSP 适合内网直连、链路简单且需要低延迟的场景。优点是通用、易调试；缺点是浏览器不能直接播放，认证和重连能力依赖实现，跨公网安全性较弱。

ONVIF 适合设备发现、能力查询、配置和云台控制。ONVIF 通常不是最终的浏览器播放协议，但可用于自动发现 RTSP 地址和读取设备信息。

GB28181 适合已有国标平台、设备规模较大、需要统一注册和级联的项目。实施时要验证注册、心跳、目录、点播、回放、设备编码和平台兼容性。

NVR 直连适合摄像头集中接入、录像已由现场系统承担的项目。需要评估 NVR 上行带宽、并发取流、通道映射和回放接口。

萤石云或其他厂商云平台适合快速接入公网设备，但必须重点确认令牌有效期、播放地址类型、并发限制、收费模式、回调能力、SDK 授权和数据边界。

厂商 SDK 适合标准协议无法满足的特殊设备能力，但会增加平台耦合和长期维护成本。使用前应形成 ADR，说明选择原因、版本依赖和替代方案。

协议选择不是互斥的。同一项目可以使用 ONVIF 完成设备发现、RTSP 完成内网取流、GB28181 对接既有平台，并通过统一 Media 层向 Web 和 BVE 提供服务。

25.4 主码流、子码流与用途分离

生产项目应为不同用途选择不同码流：

主码流用于高质量录像、人工复核和需要细节的专项分析；

子码流用于视频墙预览、低带宽远程访问和部分实时 AI；

事件发生时，可根据策略从主码流生成高质量证据，日常推理则使用经过验证的子码流。

不能机械认为主码流一定更适合 AI。高分辨率会增加解码和传输开销，而目标在画面中的有效像素、压缩质量和视角才是识别效果的核心。应在目标硬件上对主辅码流分别测试端到端延迟、准确率和资源占用。

25.5 视频接入出口条件

每路视频完成接入前，应具备：唯一摄像头编号、稳定生产地址或平台通道、受控凭证、时间同步、协议与编码记录、连续取流结果、重连结果、Web 播放结果、BVE 读取结果、录像结果、GIS 点位和责任人。

未达到条件的摄像头应标记为“待整改”“仅预览”“仅录像”或“不适合 AI”，禁止在清单中统一写成“已接入”。

第 26 章 摄像头主数据、凭证与生命周期

26.1 摄像头主数据是跨系统主键

摄像头编号应贯穿设备清单、Media、BVE、GIS、事件、工单、监控和运维文档。推荐使用稳定、可读且不依赖 IP 的编号，例如：BAS-P01-ZGQ-ENT-N-001，表示项目、工区、位置、方向和序号。

IP、通道、地址和名称都可能变化，摄像头唯一 ID 不应随网络调整而变化。设备更换时，应记录旧设备退役和新设备继承关系，避免历史事件失去来源。

摄像头主数据至少包括：

基本信息：编号、名称、项目、工区、位置、品牌、型号、序列号；

网络信息：IP、VLAN、网关、协议、端口、NVR 和平台通道；

视频信息：主辅码流、分辨率、帧率、码率、编码、GOP、音频；

物理信息：安装高度、朝向、焦距、云台、补光、供电和安装日期；

业务信息：GIS 点位、覆盖区域、候选 AI 场景、责任班组和风险等级；

运维信息：在线状态、最近心跳、故障次数、保修、维护人和变更记录。

26.2 凭证集中管理

摄像头、NVR 和第三方平台凭证应由受控配置或密钥系统管理。数据库中尽量保存凭证引用，不保存可直接使用的明文密码。日志、错误页面、导出清单和截图不得暴露完整 RTSP 地址中的用户名与密码。

项目实施期间常见的临时账号必须设置到期时间。终验移交时，客户应现场重置管理密码，回收实施账号，并更新 BridgeAI-Site 的凭证引用。凭证变化后要执行批量连通性测试，不能等待生产断流后逐路发现。

26.3 状态机而不是单一“在线/离线”

建议摄像头状态至少包括：未配置、待验证、在线、质量异常、断流重连中、认证失败、网络不可达、设备停用、施工阶段停用和退役。

“离线”只是结果，不说明原因。Media 层应区分 DNS、连接超时、认证失败、协议错误、无视频帧、时间戳异常和解码失败，使运维人员能够定位责任边界。

26.4 变更与生命周期

摄像头变更包括位置调整、IP 变化、通道变化、编码变化、镜头调整、平台迁移、工区变化和
设备更换。任何变更都应触发影响检查：

视频地址和凭证是否更新；

GIS 点位和朝向是否更新；

ROI 是否仍然有效；

AI 场景是否需要重新标定；

录像和事件关联是否连续；

监控和告警是否覆盖新配置。

施工阶段结束后，摄像头可进入停用或退役状态，但历史事件和证据中的设备身份必须保留。

第 27 章 Media 流水线：取流、解码、分发与重连

27.1 统一媒体流水线

推荐的 Media 流水线为：

Source Adapter → Connection Manager → Demux/Decoder → Timestamp Normalizer →
Frame/ Packet Bus → Playback Distributor/ BVE Consumer/ Recorder → Health
Monitor。

Source Adapter 屏蔽 RTSP、GB28181、云平台 and 厂商 SDK 差异；Connection Manager 管理连接、认证、重试和令牌；Demux/Decoder 负责封装和编码；Timestamp Normalizer 统一时间基准；Frame 或 Packet Bus 向不同消费者分发；Health Monitor 记录完整状态。

27.2 解码与协议转换

浏览器通常通过 WebRTC、HLS、HTTP-FLV、MSE 或厂商播放器访问视频，BVE 则可能直接消费解码帧或标准流。协议转换应根据延迟、并发、浏览器兼容和服务器资源选择。

低延迟监控可优先 WebRTC，但需要处理 NAT、TURN、信令和连接规模；HLS 兼容性好但延迟较高；MSE 或 HTTP-FLV 可在部分场景提供较低延迟，但需要兼容性验证。BridgeAI-Site 不应把浏览器播放协议与摄像头输入协议混为一谈。

能转封装时不应无条件转码。转封装保留原编码，CPU 成本较低；转码可统一编码和码率，但会增加计算、延迟和画质损失。只有浏览器不兼容、码率过高、编码异常或需要叠加处理时才启用转码。

27.3 时间戳与时钟治理

事件证据依赖视频时间、服务器时间和业务时间一致。摄像头、NVR、边缘节点和中心服务器应使用统一 NTP。Media 层应检测时间戳倒退、跳变、重复和长时间无增长。

不能直接把摄像头画面叠加时间当作系统事实时间。事件记录应使用服务器接收时间、源时间和处理时间三个字段；存在明显偏差时产生告警，并在证据中保留说明。

27.4 缓冲与背压

实时系统必须明确缓冲上限。网络抖动时适度缓冲可以保持播放，但无限缓冲会造成“画面仍在播放，实际已经延迟数分钟”。BVE 处理速度低于输入速度时，应丢弃过期帧或降低采样率，而不是不断积压。

建议分别定义：播放缓冲、AI 帧队列、事件前置缓存、录像写盘队列和补传队列。每个队列均配置长度、超时、丢弃策略和监控指标。

27.5 重连状态机

重连流程建议为：快速重试 → 指数退避 → 凭证或令牌刷新 → 设备／平台健康检查 → 告警 → 人工介入。

短时网络抖动不应立即发送大量离线告警；长时间故障也不能永久静默。应配置离线确认时间、重试上限、恢复通知和告警合并。设备恢复后，Media、BVE、录像和 Web 播放都要恢复，不能只确认连接对象重新建立。

27.6 Media 可观测指标

每路流至少监控：连接状态、首帧时间、连续运行时长、输入码率、实际 FPS、解码错误、时间戳异常、重连次数、最后帧时间、播放消费者数、BVE 消费状态、录像写盘和端到端延迟。

指标应按摄像头、项目、工区和接入节点聚合。运维面板要能快速识别“设备离线”“网络不稳”“编码异常”“Media 资源不足”和“BVE 消费停止”等不同故障类型。

第 28 章 录像、事件证据与文件完整性

28.1 连续录像与事件录像的责任边界

连续录像通常由 NVR 或既有视频平台承担；BridgeAI-Site 重点保存事件相关截图、短视频、整改照片和验收报告。若合同要求平台本地连续录像，应单独评估容量、合规、检索、下载和故障恢复，不能把事件录像实现直接扩展为长期录像系统。

28.2 事件前后缓冲

完整证据应包含事件发生前和发生后的上下文。Media 层可维护滚动缓冲，例如保存事件前 5～15 秒的数据包；事件触发后继续录制约定时长，再封装为证据文件。

缓冲应使用受控的内存或临时磁盘，配置容量上限和清理策略。发生多个重叠事件时，应避免重复写入大量相同视频，可通过共享原始片段和事件引用降低存储。

28.3 证据生成状态机

事件证据状态建议包括：待生成、生成中、已完成、部分完成、失败、等待补传和已归档。

事件记录不能在截图和录像尚未生成时直接标记为完整。失败时记录原因，例如源流中断、缓冲不足、封装失败、磁盘满、MinIO 不可用或校验失败，并支持重试和人工补充。

28.4 文件命名、校验和元数据

文件对象使用唯一事件 ID，而不是仅依赖摄像头名称和时间。元数据包括项目、摄像头、事件类型、开始结束时间、源流、模型、规则、ROI、生成节点、文件大小、时长、编码、校验和和对象存储位置。

上传完成后验证文件大小、容器可解析、时长合理和校验和一致。只有数据库记录存在、对象可访问且校验通过，证据才算完成。

28.5 隐私与导出

事件视频可能包含人员、车辆和施工细节。应控制预览、下载、外发和保留权限。导出证据包时记录导出人、用途、时间、文件清单和校验和。需要脱敏时，应生成派生版本并保留原始证据权限，不直接覆盖原文件。

第 29 章 视频墙、浏览器播放与现场操作体验

29.1 视频墙是运行控制面

2×2 和 4×4 视频墙不仅用于观看，还应显示摄像头名称、工区、在线状态、AI 任务、延迟、告警和最后更新时间。断流时显示明确原因和重试状态，禁止长期保留最后一帧让用户误以为仍是实时画面。

29.2 分组与轮巡

支持按项目、工区、高风险区域、AI 场景、设备状态和自定义收藏分组。轮巡应记录组、间隔和失败跳过策略。高风险事件发生时，可将相关画面置顶或弹出，但应避免频繁切换影响值守人员判断。

29.3 并发与资源控制

浏览器同时播放 16 路视频会消耗网络、解码和显卡资源。系统应提供默认子码流、可见区域播放、后台暂停、按需加载和最大并发限制。用户切换到单画面全屏时，再加载主码流或高质量流。

不能只在高性能开发电脑上验证视频墙。验收应使用客户实际浏览器、办公电脑、网络 and 显示终端，并覆盖移动端或大屏终端需要。

29.4 AI 叠加与原始画面

AI 叠加可以由服务端生成，也可以由前端根据结构化检测结果绘制。前端绘制减少转码开销，便于开关和交互，但要求时间同步和坐标映射准确；服务端叠加适合固定输出和录像，但增加计算与编码成本。

界面必须允许切换原始画面与叠加画面。验收证据应同时保存原图和叠加图，避免检测框遮挡细节或无法判断模型是否修改了原始内容。

第 30 章 GIS 数据接入与坐标治理

30.1 底图、业务图层与工程图层

BridgeAI-Site 支持天地图矢量和卫星底图，并叠加项目业务图层。底图提供空间背景，业务图层描述工区、危险区、摄像头、出入口、设备和事件，工程图层可来自设计图、施工总平面图、BIM 投影或无人机成果。

不同图层必须记录来源、坐标系、版本、生效时间和更新人。前端显示正确不代表数据库空间数据正确，所有关键对象应在 PostGIS 中使用明确 SRID 保存。

30.2 坐标转换服务

WGS84、GCJ-02、CGCS2000 和本地工程坐标的转换，应由统一 GIS 服务实现。转换函数需要版本、参数和测试点，禁止在前端、导入脚本和无人机模块中分别维护不同实现。

本地工程坐标转换通常需要控制点、原点、旋转、尺度和高程说明。没有可靠参数时，应明确标记“仅示意定位”，不能把近似结果用于精确航线或安全边界控制。

30.3 数据导入流程

GIS 导入流程建议为：文件接收 → 格式识别 → 坐标和单位确认 → 字段映射 → 几何有效性检查 → 预览 → 抽样核验 → 导入临时区 → 审核 → 发布为正式版本。

支持的输入可包括 GeoJSON、Shapefile、KML、CSV 点位、CAD 转换成果和人工绘制。任何导入都要保留原文件、导入日志和错误清单。

30.4 几何与属性质量

检查空几何、自相交、多边形方向、重复对象、异常坐标、单位错误和越界点。摄像头点位至少包含编号、名称、工区、经纬度或工程坐标、朝向和状态；危险区包含风险类型、责任人、有效期和规则关联。

30.5 图层版本与发布

施工区域和危险区具有时间属性。每次调整应生成新版本，记录生效时间和审批人。发布新 GIS 版本前，系统自动列出受影响的摄像头、ROI、规则、事件统计和 Agent 查询。

旧版本不应物理删除，以便历史事件在当时的空间环境中复现。

第 31 章 GIS、视频与事件的时空联动

31.1 摄像头点位与视场

摄像头在地图上不仅是一个点。条件允许时，应记录朝向、水平视场角、覆盖距离和安装高度，生成近似视锥，帮助用户理解画面覆盖范围。

视场是辅助信息，不应替代实测。云台摄像头方向变化、镜头变焦和遮挡会使静态视锥失真，系统应标记固定或动态状态。

31.2 事件落点策略

固定摄像头事件可落在摄像头点位、ROI 中心或人工标定的风险位置。不同策略应明确展示，避免用户把摄像头安装位置误认为事件精确发生位置。

无人机或移动设备事件可使用实时位置、航迹插值或视觉定位结果。每个事件保存定位来源、坐标系、精度和时间差。定位不可靠时，应降低可信等级而不是生成看似精确的坐标。

31.3 地图驱动的视频操作

用户点击摄像头点位可打开实时视频、最近事件、在线状态和工单；点击危险区可查看关联摄像头、规则、责任人和历史风险；点击事件可回放视频并查看证据和处置流程。

GIS 与视频联动应通过稳定 ID 和 API 实现，不使用名称模糊匹配。删除或更名设备时，历史事件仍能定位到原对象版本。

31.4 时空一致性

事件、视频帧、GIS 图层版本和工区状态必须使用同一时间轴。复盘某次事件时，应加载事件发生时生效的危险区和摄像头配置，而不是当前最新配置。

Agent 查询“昨天 A 工区发生了哪些高风险事件”时，也应使用事件时间、工区版本和权限范围，不应只按当前组织结构过滤。

第 32 章 现场设备、边缘网关与离线协同

32.1 设备接入统一模型

除了摄像头，现场还可能接入 NVR、门禁、环境传感器、车辆设备、定位基站、边缘工控机、无人机和 DJI Manifold 3。应使用统一资产模型记录设备身份、类型、项目、位置、固件、网络、能力、健康、配置和责任。

32.2 边缘网关职责

边缘网关可承担协议适配、视频汇聚、AI 推理、事件缓存、证据缓存、设备心跳和断网补传。它不应复制中心平台的全部业务逻辑。中心平台仍负责组织、权限、工单、Agent、报表和长期数据治理。

32.3 设备身份与认证

每个边缘节点使用独立设备身份，不共享全项目通用令牌。设备注册包含编号、证书或密钥、允许项目、允许 API、有效期和吊销状态。设备丢失或退役后可单独吊销，不影响其他节点。

32.4 离线状态机

断网时边缘节点应继续执行允许的本地任务：取流、推理、事件生成和证据保存。需要中心审批的操作进入等待队列，不得在离线状态自行扩大权限。

网络恢复后按顺序同步：设备心跳与时间 → 配置版本比对 → 事件元数据 → 证据文件 → 状态确认。使用幂等键避免重复事件和重复工单。

32.5 配置冲突

边缘节点离线期间，中心可能更新模型、ROI 或规则。恢复连接后不能直接双向覆盖，应根据配置版本和生效时间判断。生产配置通常以中心批准版本为准，边缘本地紧急调整必须形成变更记录并等待合并。

32.6 设备运维

监控在线、CPU、GPU、内存、磁盘、温度、网络、应用版本、模型版本、缓存数量和最后同步时间。支持远程日志、受控重启、升级、回滚和现场恢复包。远程控制操作必须审计，并保留紧急停用方法。

第 33 章 视频与 GIS 接入联调、验收和复盘

33.1 端到端联调链路

联调不应按页面逐项点击，而应按价值链验证：

摄像头／平台 → Media → Web 播放；

摄像头／平台 → Media → BVE → 事件；

事件 → 截图／录像 → MinIO → 页面回放；

摄像头 → GIS 点位 → 事件落点 → 工区与危险区；

边缘节点 → 离线缓存 → 网络恢复 → 中心同步。

每条链路均记录版本、输入、预期、结果、日志和证据。

33.2 视频验收指标

建议按项目约定：接入成功率、连续在线率、首帧时间、播放延迟、重连恢复时间、录像成功率、证据可打开率、时间偏差和多画面并发稳定性。

指标应按摄像头分层。关键工区和高风险场景可以采用更严格要求，临时摄像头或第三方网络受限设备则明确责任边界。

33.3 GIS 验收指标

抽样核验项目边界、工区、危险区、摄像头点位、事件落点和坐标转换。验证矢量／卫星切换、图层权限、版本切换、缩放、GeoJSON 导入和空间查询。

对工程坐标数据，应使用已知控制点或现场实测点检查，不以视觉重合替代精度说明。

33.4 故障注入

至少测试：拔网线、摄像头重启、密码修改、令牌过期、NVR 重启、Media 重启、MinIO 暂时不可用、磁盘容量预警、边缘节点断网和 GIS 发布错误。

故障注入的目标不是证明系统永不失败，而是验证失败能够被发现、影响可控、数据不乱、恢复有序。

33.5 示例项目复盘：地图正确，事件却落错工区

示例项目中，摄像头在天地图卫星图上显示位置基本正确，但危险区域入侵事件被统计到相邻工区。排查发现，摄像头点位由 WGS84 转换为 GCJ-02，而工区边界来自本地工程坐标转换成果；两个转换脚本使用了不同的控制点版本。地图缩放较小时肉眼难以发现约十余米偏差，但空间包含查询已经产生错误。

项目组统一坐标转换服务，重新发布 GIS 版本，并建立三个控制点自动校验。事件落点新增“定位来源”和“精度等级”，Agent 和报表只在精度满足要求时进行工区自动归属。

这个案例说明，空间系统的错误往往不会表现为页面崩溃，而会悄悄污染统计、工单和管理决策。

33.6 视频与 GIS 接入 SOP

确认设备清单、网络和协议基线。

创建摄像头主数据和受控凭证。

从实际 Media/BVE 节点验证生产取流。

配置主辅码流、播放协议、重连和监控。

验证 Web、BVE、录像和证据链路。

导入 GIS 数据，确认坐标、字段和版本。

关联摄像头、工区、危险区和事件落点。

执行并发、持续运行和故障注入测试。

关闭 P0/P1 问题，形成接入验收记录。

由项目经理、安全负责人和运维负责人确认进入 BVE 与 AI 场景上线阶段。

第六篇 BVE 与 AI 场景工程化实施

第 34 章 BridgeAI Vision Engine 的生产架构

34.1 BVE 的定位

BridgeAI Vision Engine (BVE) 不是单一模型推理服务，而是连接视频输入、视觉模型、规则、事件、风险和 Agent 的生产视觉引擎。模型负责从帧中产生检测、分割或分类结果，BVE 负责把这些结果转化为可理解、可去重、可追踪和可处置的业务事件。

一个高精度模型如果缺少稳定解码、跟踪、ROI、规则、证据和监控，无法独立构成生产系统；反之，一个工程链路成熟的 BVE 可以通过场景配置、跟踪和规则减少模型局限带来的误报。

34.2 核心流水线

推荐流水线为：

Video Decoder → Frame Scheduler → Preprocessor → AI Runtime → Postprocessor → Tracker → ROI Engine → Rule Engine → Event Aggregator → Risk Engine → Evidence Generator → Event Publisher → Agent Adapter。

Video Decoder 接收标准化视频；Frame Scheduler 决定采样、节流和优先级；Preprocessor 完成缩放、色彩和批处理；AI Runtime 调用 MLX、PyTorch、ONNX Runtime 或 TensorRT；Postprocessor 统一标签和坐标；Tracker 建立跨帧对象；ROI 与 Rule 将视觉结果映射为场景条件；Event Aggregator 把帧级命中聚合为事件；Risk Engine 结合场景和上下文分级；Evidence Generator 生成截图、短视频和元数据；Event Publisher 写入平台并触发业务流程；Agent Adapter 向 Vision、Risk 或 Workflow Agent 提供受控工具。

34.3 领域对象分离

BVE 应区分五类对象：

Detection：单帧模型结果；

Track：同一目标的跨帧轨迹；

Rule Hit：轨迹或检测满足某个规则的一次命中；

Event：经过持续时间、合并、冷却和去重后的业务事件；

Risk：事件结合工区、时段、人员和历史后的风险判断。

禁止直接把每个检测框写成事件。否则一分钟连续未戴安全帽可能生成数百条告警，既浪费存储，也使安全员无法处置。

34.4 插件化与接口边界

AI Runtime、Tracker、Rule、Evidence 和 Publisher 应通过稳定接口解耦。新增模型不应修改整个事件系统；新增规则也不应重新训练模型。模型输出统一为标准 Schema，包括类别、置信度、边界框或掩膜、时间戳、帧号、模型版本和附加属性。

平台业务服务只消费正式事件，不直接依赖某个 YOLO 版本的原始输出字段。这样可以在 YOLO26、分割模型、VLM 或多模型融合之间迭代，而不破坏工单和报表。

34.5 任务与场景的关系

一个 BVE Task 表示某个运行节点对一路或多路视频执行的计算任务；一个 Scene 表示业务场景。单个任务可以运行多个场景，共享人员、车辆或烟火模型；单个场景也可以部署在多路摄像头上，但具有不同 ROI、阈值和时段。

任务配置和场景配置应分别版本化。任务解决“在哪里、用什么资源运行”，场景解决“什么条件构成风险”。

34.6 故障隔离

单路视频、单个模型或单个场景故障不应拖垮整个 BVE 节点。使用任务级超时、独立队列、资源配额和熔断。模型加载失败时，节点保持健康但任务进入失败状态；事件发布失败时先本地持久化，不阻塞视频解码。

第 35 章 模型资产、格式与发布治理

35.1 模型不是一个权重文件

可交付的模型资产包至少包含：模型权重、格式、标签、输入尺寸、归一化、后处理、版本、训练数据摘要、评测结果、适用场景、硬件兼容、运行时版本、校验和、许可证、负责人和回滚版本。

只有 pt、onnx、engine 或 safetensors 文件，没有元数据和测试记录，不能作为正式生产模型。

35.2 BridgeAI 模型链路

研发和部署可能使用多种链路：

YOLO26 .pt：训练与基准评测；

ONNX：跨运行时中间格式；

TensorRT Engine：NVIDIA 和 DJI Manifold 3 目标设备优化格式；

MLX/safetensors：Apple Silicon 本地推理格式；

其他格式：根据 VLM、分割或跟踪组件确定。

转换必须在发布记录中保留源模型、导出参数、工具版本和校验和。TensorRT Engine 与 GPU 架构、TensorRT、CUDA 和精度模式强关联，应在目标设备生成或验证。

DJI Manifold 3 的固定交付链路为：开发环境训练 YOLO26 .pt → Windows WSL 导出 ONNX → SSH 到 Manifold 3 → 设备侧转换 TensorRT Engine → 打包 DPK → 安装和现场验证。

35.3 模型注册表

模型注册表保存模型 ID、名称、任务类型、标签集、语义版本、状态、文件位置、运行时、硬件、数据集版本、评测集、指标、发布日期和审批人。

状态建议包括：实验、候选、已批准、灰度、生产、已弃用和已撤回。只有“已批准”或“生产”状态可被正式场景引用。

35.4 标签与语义兼容

标签名称、顺序和业务语义必须固定。模型输出 `class=0` 的含义不能仅存在于训练代码。发布包提供 `labels.json` 或等价文件，并与场景规则引用一致。

合并多病害、多 PPE 或多行为模型时，需处理同名异义、近义类别和版本变更。标签删除或重命名属于破坏性变更，应通过新模型版本和场景迁移处理。

35.5 精度与数值格式

模型可使用 FP32、FP16、BF16 或 INT8。更低精度可能提升吞吐，但必须在目标硬件和现场验收集上比较精度、延迟、显存和稳定性。不能仅因 Engine 成功生成就认为量化可用。

INT8 校准数据应覆盖真实现场光照、目标尺寸和类别分布，并保存校准集版本。量化后对小目标、烟雾和边界类别的影响要单独检查。

35.6 发布与回滚

模型发布流程为：资产完整性检查 → 离线评测 → 目标硬件基准 → 场景回放 → 安全审核 → 灰度 → 生产 → 持续监控。

回滚必须同时恢复模型、标签、后处理、阈值默认值和兼容规则。新模型已经产生的事件不应因回滚被删除，但要保留其模型版本以便复盘。

第 36 章 场景卡：把业务风险编译为 AI 配置

36.1 场景卡是最小上线单元

场景卡连接安全管理、算法和实施。每个场景必须回答：为什么识别、在哪里识别、识别什么、何时生效、满足什么条件产生事件、如何排除误报、谁处置、如何验收和如何回滚。

场景卡至少包含：场景 ID、名称、业务目标、风险等级、项目、工区、摄像头、模型、标签、ROI、时段、置信度、持续时间、冷却、最小目标、跟踪要求、排除条件、证据、通知、工单策略、验收集、负责人、版本和生效时间。

36.2 从自然语言到可执行条件

“识别危险区域入侵”并不完整。可执行定义可能是：在工作日 06:00~22:00，指定摄像头的危险区多边形内出现 person 轨迹，目标高度不少于 40 像素，连续存在超过 2 秒，且不属于授权人员白名单，产生 P2 风险事件；同一轨迹 60 秒内不重复告警。

场景卡必须把模糊需求转化为结构化条件，并让安全负责人确认。算法工程师不能替现场管理者决定什么是“危险”或“超时”。

36.3 场景模板与项目实例

平台可提供安全帽、反光衣、区域入侵、烟火、人员聚集、车辆违停等模板。模板包含推荐模型、规则字段和默认值，但项目实例必须重新选择摄像头、ROI、时段和验收标准。

复制模板不等于完成配置。现场光照、视角、工序和责任流程不同，任何默认阈值都只是初始值。

36.4 依赖和前置条件

场景上线前确认：摄像头 AI 适配合格、视频稳定、模型已批准、标签兼容、GIS/ROI 基线已确认、责任人存在、证据存储可用、通知和工单流程可用、验收集已准备。

依赖不满足时，场景状态为“阻塞”或“待整改”，不得通过降低指标绕过。

36.5 场景版本

每次修改 ROI、阈值、时段、规则、模型或处置流程，都生成新版本。事件保存发生时的完整场景版本。场景发布支持生效时间和回滚，避免施工阶段切换时人工临时修改后无法追溯。

第 37 章 ROI、空间规则与时段规则

37.1 ROI 坐标规范

ROI 可使用归一化坐标 0~1 保存，使其适配不同分辨率；运行时转换到实际帧坐标。保存 ROI 时同时记录基准分辨率、摄像头配置版本和截图，防止画面裁剪或镜头变化后坐标仍合法但语义失效。

37.2 ROI 类型

检测区：仅在区域内分析；

屏蔽区：排除固定误报区域；

危险区：目标进入或停留触发规则；

越线：判断跨越方向和次数；

统计区：人员、车辆或设备计数；

动火区：与烟火、人员和审批时段组合；

构件区：桥梁、道路或设备病害分析的目标构件范围。

37.3 点、框、中心与覆盖率

判断目标是否在 ROI 内可以使用框中心、底部中心、关键点或掩膜覆盖率。人员区域入侵通常使用脚点或底部中心更符合地面位置；安全帽规则需要头部与人员关联；车辆违停可使用框中心或与停车区的交并比。

规则必须明确使用哪种几何关系。不同实现产生的结果差异很大，不能只写“目标在区域内”。

37.4 越线与方向

越线规则需要线段方向、允许方向、最小轨迹长度和去抖。单帧框跨线容易受抖动影响，应基于轨迹连续位置判断。摄像头镜像、方向变更或云台旋转后需重新验证。

37.5 时段与施工阶段

规则支持周历、班次、节假日、停工、临时审批和施工阶段。动火场景可以在已批准作业窗口降低告警等级，在非审批时段提高等级；人员聚集规则在班前会时段可暂停。

时段配置必须有时区，边缘节点离线时仍能正确执行。临时停用要记录申请人、原因、开始结束和恢复确认。

37.6 ROI 失效检测

画面发生明显变化时，系统可通过特征、结构相似度或人工巡检提示 ROI 可能失效。以下变化必须人工复核：摄像头移动、变焦、分辨率或裁剪变化、围挡和工区布局改变、云台预置位切换。

第 38 章 阈值、跟踪与事件聚合

38.1 置信度不是业务风险概率

模型 confidence 反映模型对当前类别的输出，不等于事故发生概率，也不直接等于事件可信度。场景事件可信度还受到目标尺寸、持续时间、轨迹稳定、ROI 关系、多帧一致性和 VLM 复核影响。

因此，阈值应按场景和摄像头标定。统一把所有模型 confidence 设置为 0.5，通常既不科学也不可维护。

38.2 多级阈值

可设置检测阈值、轨迹确认阈值和事件阈值。较低检测阈值用于保持轨迹，较高事件阈值用于正式告警；对烟雾等渐变目标，可结合连续增长和区域稳定性。

阈值调整必须使用固定回放集比较误报和漏报，不凭单个现场片段临时修改。

38.3 跟踪的工程作用

Tracker 负责目标身份、轨迹、停留时间和跨帧平滑。其价值不仅是画框带 ID，更重要的是支撑持续时间、越线、进入离开、重复事件合并和人员—安全帽关联。

跟踪参数包括匹配阈值、失踪容忍、轨迹确认帧数和最大年龄。人员密集、遮挡和低 FPS 场景需要单独评估。

38.4 从帧命中到事件

事件聚合典型流程：

候选检测 → 轨迹确认 → 规则连续命中 → 达到持续时间 → 建立事件 → 更新持续状态 → 结束条件满足 → 完成事件 → 进入冷却。

事件开始和结束应记录。持续事件可以更新最大人数、最高置信度、持续时间和证据片段，而不是不断创建新事件。

38.5 去重与冷却

去重维度可包括项目、摄像头、场景、轨迹、ROI 和时间窗口。同一人员在相邻危险区移动时，是否合并取决于业务定义。冷却时间用于控制重复通知，不应阻止系统记录风险持续状态。

38.6 多模型和关系规则

未戴安全帽可能需要 **person**、**helmet** 和头部区域关系；动火风险可能组合 **flame/smoke**、**person**、审批时段和动火区；车辆违停组合 **vehicle**、停车区、速度和持续时间。

组合规则应明确输入模型、时间窗口和缺失数据策略。任一模型暂时不可用时，系统进入降级状态并提示，不得把缺失当作“无风险”。

第 39 章 风险分级、证据与 VLM 复核

39.1 风险分级模型

风险等级可由场景基础等级、工区等级、时间、持续时长、目标数量、重复次数和历史整改状态共同决定。例如同样的人员入侵，在普通材料区可能为 P3，在高空临边区可能为 P1。

风险分级规则应透明、可解释和可版本化。Agent 可以总结原因，但不得修改原始风险计算结果。

39.2 证据包

正式事件证据包建议包含：

原始截图；

AI 叠加截图；

事件前后短视频；

摄像头、工区和 GIS 位置；

模型、标签、场景、ROI、规则和阈值版本；

检测、轨迹和事件摘要；

风险等级与计算依据；

人工确认、工单和整改记录；

Agent 或 VLM 参与时的输入、输出和版本。

39.3 VLM 复核的定位

视觉语言模型可用于二次描述、场景理解和误报过滤，例如区分真实烟雾与蒸汽、解释人员是否位于危险区、生成事件摘要。但 VLM 不能作为无审计的黑盒替代基础检测和规则。

高风险场景使用 VLM 复核时，应设置超时、结果 Schema、模型版本、提示词版本和失败降级。VLM 不可用时，原始 BVE 事件仍按预设策略处理。

39.4 人工确认

人工确认状态包括待确认、有效、误报、无法判断和已忽略。确认人需要选择原因，例如模型误检、ROI 错误、规则不适用、现场已授权或证据不足。

结构化原因是后续数据闭环的关键。只允许输入自由文本，会难以统计误报根因。

第 40 章 性能、资源调度与降级

40.1 完整流水线基准

性能测试必须使用真实视频和完整 BVE 流水线，测量解码、预处理、推理、跟踪、规则、证据和发布。模型裸 FPS 不能代表生产容量。

记录单路和多路情况下的输入 FPS、处理 FPS、事件延迟、CPU、GPU、统一内存或显存、磁盘、网络、温度和功耗。

40.2 帧调度

不同场景需要不同采样率。安全帽和反光衣可使用较低 FPS；越线和快速车辆需要更高 FPS；烟火可使用动态采样。Frame Scheduler 按场景优先级、视频变化和资源状态分配帧。

多场景共享同一基础模型时，尽量一次推理后复用结果，避免每个场景独立解码和推理。

40.3 Batch 与延迟

Batch 可提升 GPU 吞吐，但会增加等待和端到端延迟。实时高风险场景使用小 Batch 或动态 Batch；离线回放和批量分析可使用更大 Batch。

Mac Studio 的统一内存和 MLX、NVIDIA 显存和 TensorRT、Manifold 3 的设备资源特性不同，应分别建立配置模板。

40.4 优先级与隔离

任务按高风险实时、普通实时、低优先级和离线回放分级。资源紧张时，优先保证高风险场景和证据生成，降低普通场景采样率，暂停离线任务。

单个异常视频不能无限消耗解码重试；单个高事件量场景不能占满事件队列。配置每任务和每项目资源上限。

40.5 背压与丢帧

BVE 实时处理应以“处理最新有效信息”为目标。队列积压时优先丢弃过期帧，保留关键帧和事件上下文。丢帧策略要形成指标，避免系统表面在线但实际长期滞后。

40.6 降级策略

常见降级包括：

主码流切子码流；

降低采样 FPS 或输入尺寸；

暂停低优先级场景；

关闭 VLM 复核；

只生成截图，延后视频证据；

边缘本地缓存，暂停中心实时推送；

模型切换到轻量版本。

降级必须可见、可审计并具备恢复条件。用户应知道当前结果处于正常还是降级模式。

第 41 章 AI 评测、验收集与指标解释

41.1 评测层次

BridgeAI-Site 的 AI 评测分为模型级、流水线级、事件级和业务级。

模型级评测 Precision、Recall、mAP、分割指标和类别混淆；

流水线级评测解码、推理、跟踪、规则和延迟；

事件级评测一个真实风险是否形成正确事件，是否重复或漏报；

业务级评测事件是否可处置、工单是否闭环和用户是否认可。

项目验收不能只引用训练报告中的 mAP。

41.2 验收集结构

每个场景建立现场验收集，包括：正样本、空样本、相似负样本、夜间、逆光、遮挡、小目标、多人、施工阶段变化和边界条件。视频场景要包含完整时间段，以验证持续、跟踪和去重。

验收集与训练集隔离，记录采集来源、授权、标注人、审核人和版本。样本数量根据场景和合同确定，但必须覆盖主要失败模式。

41.3 事件统计口径

事件级 TP：真实风险在允许时间内生成一个有效事件；

事件级 FP：无真实风险却生成正式事件；

事件级 FN：真实风险未形成事件；

重复事件：同一风险被错误拆分为多个事件；

延迟：真实风险开始到事件可见的时间。

连续 30 秒的未戴安全帽不应按数百帧分别统计。验收前由各方确认事件边界和容忍窗口。

41.4 Precision 与 Recall 的取舍

高风险场景通常更重视 Recall，但误报过高会使用户关闭告警。应通过模型、ROI、持续时间、跟踪、VLM 和人工确认共同达到平衡。

不同场景分别设定目标。不能用全项目平均值掩盖某个关键场景失败，也不能只挑选容易样本展示高指标。

41.5 置信区间与样本不足

样本量很小时，单个错误会显著改变比例。验收报告应同时给出样本数、事件数和原始计数，不只给百分比。样本不足的稀有场景可采用模拟演练、历史回放和延长试运行，并明确结论置信程度。

41.6 误报漏报复核

每个 FP 和 FN 至少标注根因：模型、标签、目标像素、光照、遮挡、取流、ROI、规则、跟踪、时间配置、证据或人工口径。只有根因清晰，才能决定调整设备、数据、模型还是规则。

第 42 章 灰度上线、在线监控与回滚

42.1 灰度层级

推荐顺序：离线回放 → 影子运行 → 单摄像头 → 单工区 → 单项目 → 全项目。

影子运行期间生成事件但不正式通知或创建工单，用于比较真实事件量和误报。单摄像头通过后再扩展，避免错误配置一次影响几十路视频。

42.2 灰度对照

新模型或新规则可以与旧版本并行运行，比较事件差异、延迟和资源。对照结果必须使用相同视频和时间窗口。正式切换后保留旧版本一段时间作为快速回滚。

42.3 在线质量指标

除了系统指标，还应监控质量代理指标：每日事件量、每路事件分布、人工有效率、误报原因、目标尺寸分布、置信度分布、夜间与白天差异、摄像头画面变化和场景长期无事件。

事件突然为零可能是现场安全改善，也可能是视频、模型或规则失效。需要结合设备健康和抽样回放判断。

42.4 漂移与失效

常见漂移包括季节和光照变化、工服变化、施工阶段变化、摄像头移动、镜头污染、背景新增、设备编码变化和人员行为变化。

建立定期抽样：关键场景每日或每周检查，普通场景按风险和事件量检查。发现漂移后先判断设备与配置，再决定是否重新训练。

42.5 回滚触发

触发条件可包括：误报量超过阈值、关键 FN、延迟或资源超标、模型加载不稳定、标签映射错误、证据链失败、用户无法处置或安全负责人要求暂停。

回滚操作应在分钟级完成，并通知相关人员。回滚后继续保留问题版本的日志、事件和样本，供根因分析。

第 43 章 数据闭环、再训练与持续改进

43.1 反馈不是一堆截图

有效反馈需要关联事件 ID、摄像头、场景、模型、规则、时间和人工结论。用户标记误报或漏报时，系统自动收集相关帧、前后视频和配置版本，形成候选样本。

43.2 难例分类

建议分类：

模型误检或漏检；

小目标或遮挡；

光照、雨雾、粉尘；

相似负样本；

标签定义冲突；

ROI 或规则错误；

跟踪和事件聚合错误；

设备、编码或时间问题；

业务口径变化。

分类决定处理路径。ROI 错误不应通过重新训练模型解决；摄像头目标过小也不应无限增加样本期待模型突破物理限制。

43.3 样本治理

候选样本经过权限确认、去重、脱敏、标注和审核进入项目数据集。保存原始来源、事件 ID、标注版本、类别定义和使用授权。空样本和相似负样本与正样本同等重要。

训练、验证、测试和现场验收集保持隔离，避免把验收失败样本直接加入训练后仍用同一批样本证明效果。

43.4 训练与评测流水线

再训练应固定数据集版本、代码、基础模型、超参数、环境和随机种子。输出训练报告、类别指标、错误分析、模型卡和候选发布包。

新模型必须与生产版本在固定离线集和现场回放集上对比，说明改善和退化。若某类提升但另一关键类下降，需要由场景负责人决策是否拆分模型或继续优化。

43.5 模型与规则协同优化

模型优化解决视觉识别能力，规则优化解决业务时空条件。优先选择成本最低、风险最小的改进：调整 ROI、时段、持续时间或设备视角可能比重新训练更快；当视觉特征本身无法区分时，再考虑新增数据或多模型融合。

43.6 跨项目复用

跨项目复用模型和样本必须遵守数据权属和隐私。可复用的是通用模型、标注规范、规则模板和匿名化难例模式；项目专有视频、人员和设施数据未经授权不得进入公共训练集。

第 44 章 示例项目：从“框很多”到“事件可用”

44.1 首次上线的问题

示例项目完成 10 路摄像头和安全帽场景的影子运行后，模型在画面中能够识别人员和安全帽，但系统每天生成两千多条候选告警。安全员抽样发现，大量事件来自人员短暂经过画面边缘、远处小目标、车辆反光和同一人员连续重复。

单看模型截图，许多框似乎合理；从业务角度看，事件无法使用。

44.2 根因拆分

团队将问题分为：

摄像头问题：两路画面中人员头部平均不足 12 像素；

模型问题：黄色机械部件被误识别为安全帽；

ROI 问题：画面外道路和生活区被纳入检测；

规则问题：没有最小目标和持续时间；

跟踪问题：遮挡后轨迹 ID 频繁切换；

事件问题：每次命中都创建事件，没有冷却和合并。

44.3 工程整改

项目组采取分层措施：

将两路不适合安全帽的摄像头改为人员聚集场景；

收集机械部件和远处人员作为负样本；

重新绘制作业区 ROI，排除道路和生活区；

设置人员最小高度、连续 2 秒命中和轨迹确认；

优化跟踪失踪容忍；

同一轨迹 60 秒内合并事件；

事件生成后由 VLM 对近似场景进行可选复核；

影子运行一周后再正式通知。

44.4 结果与启示

整改后，日均正式事件下降到安全员可以逐条确认的范围，关键演练样本仍能稳定触发。改进并非来自单一模型指标大幅提升，而是设备、ROI、规则、跟踪和事件聚合共同作用。

BVE 工程化的核心，就是把“模型看到了什么”转化为“现场需要处理什么”，并使这个过程可解释、可评测和可持续改进。

44.5 BVE 与 AI 场景上线 SOP

确认视频、GIS、设备和数据底座已通过门禁。

建立场景卡和现场验收集。

选择已批准模型，核对标签和硬件兼容。

配置任务、ROI、规则、阈值、跟踪、时段和证据。

执行离线回放与性能基准。

影子运行，统计事件、误报、漏报和资源。

完成安全负责人和算法负责人评审。

按单摄像头、单工区和单项目灰度。

正式上线并监控质量代理指标。

保留生产版本、回滚版本、样本和发布记录。

附录 L 摄像头生产接入登记表

摄像头编号：

项目／工区：

位置与方向：

品牌／型号／序列号：

安装高度／焦距／补光：

GIS 点位／坐标系：

NVR／平台／通道：

输入协议：RTSP／ONVIF／GB28181／厂商 SDK／云平台

主码流：分辨率 | 帧率 | 码率 | 编码 | GOP

子码流：分辨率 | 帧率 | 码率 | 编码 | GOP

凭证引用：

时间同步结果：

连续取流测试：

断流重连测试：

Web 播放测试：

BVE 读取测试：

录像与证据测试：

适用 AI 场景：

状态：待验证／在线／质量异常／停用／退役

整改问题：

设备责任人：

实施工程师：

审核人：

日期：

附录 M 视频流稳定性测试记录

测试编号：

项目／环境：

Media 节点：

测试日期与时长：

摄像头编号 | 协议 | 首帧时间 | 平均码率 | 实际 FPS | 解码错误 | 重连次数 | 最长中断 | 录像结果 | 结论

故障注入：

- ☐ 摄像头重启
- ☐ NVR 重启
- ☐ 网络中断
- ☐ 密码或令牌变化
- ☐ Media 服务重启
- ☐ MinIO 暂时不可用

恢复时间：

数据或证据丢失情况：

告警与恢复通知：

发现问题：

整改措施:

验证人:

结论: 通过/有条件通过/不通过

附录 N GIS 数据导入与发布记录

导入编号:

项目:

数据类型: 项目边界/工区/危险区/摄像头/设备/航迹/其他

源文件与版本:

数据来源与责任人:

源坐标系/单位:

目标坐标系/SRID:

转换方法与参数版本:

字段映射:

几何有效性检查:

重复与异常坐标检查:

控制点核验:

临时区导入结果:

抽样核验人:

正式版本号:

生效时间:

受影响摄像头/ROI/规则:

回滚版本:

发布结论: 成功/有条件成功/已回滚

附录 O AI 场景卡

场景 ID:

场景名称:

业务目标:

风险等级:

项目／工区:

摄像头编号:

模型 ID／版本:

目标标签:

ROI 类型与版本:

生效时段／施工阶段:

检测阈值:

最小目标:

跟踪要求:

持续时间:

冷却时间:

数量条件:

排除条件:

关系规则:

证据要求: 截图／短视频／原图／叠加图／GIS

VLM 复核: 启用／不启用

通知策略:

工单策略:

责任人:

验收集版本:

验收指标:

回滚场景版本：

算法负责人：

安全负责人：

批准日期：

附录 P 模型资产与发布记录

模型 ID：

模型名称：

任务类型：检测／分割／分类／VLM／跟踪

语义版本：

源模型与校验和：

发布格式：PT／ONNX／TensorRT Engine／MLX／其他

标签文件与版本：

输入尺寸与预处理：

后处理与 NMS／无 NMS 说明：

训练数据集版本：

评测集版本：

主要指标：

适用场景：

已知限制：

运行时与硬件：

CUDA／TensorRT／MLX 版本：

导出参数：

目标设备验证：

性能基准：

量化精度：FP32／FP16／BF16／INT8

灰度范围：

回滚模型：

发布人：

审核人：

状态：实验／候选／已批准／灰度／生产／弃用／撤回

发布日期：

附录 Q BVE 场景灰度与验收记录

灰度编号：

项目／工区：

场景与版本：

模型与版本：

摄像头范围：

BVE 节点与版本：

开始／结束时间：

运行模式：离线回放／影子／正式灰度

一、运行指标

视频在线率：

处理 FPS：

端到端事件延迟：

CPU／GPU／内存峰值：

证据生成成功率：

事件发布成功率：

二、质量指标

真实事件数：

TP：

FP：

FN：

重复事件：

Precision：

Recall：

人工有效率：

主要误报原因：

主要漏报原因：

三、故障与降级

发生的故障：

降级策略：

恢复时间：

数据一致性：

四、结论

☐ 扩大灰度

☐ 保持观察

☐ 调整参数后复测

☐ 回滚

☐ 不建议上线

算法负责人：

安全负责人：

项目经理：

日期：

第七篇 Agent、RAG 与业务闭环上线

第 45 章 从聊天助手到受控生产 Agent

45.1 Agent 上线的本质

BridgeAI-Site 中的 Agent 不是一个悬浮在业务系统之外的聊天窗口，而是连接项目数据、知识文档、业务流程和人员决策的受控执行层。它的生产价值不在于回答得像人，而在于能够在正确的项目、正确的时间范围和正确的权限边界内，读取可信数据、调用经过登记的工具、生成可复核结果，并把每一步写入审计记录。

生产 Agent 必须同时满足六个条件：身份明确、上下文正确、数据可追溯、工具受控、失败可恢复、结果可审计。任何一个条件缺失，Agent 都可能从效率工具变成新的风险源。

45.2 先定义任务，再选择模型

实施团队应从任务清单出发，而不是从大模型能力清单出发。典型任务包括：

- 查询某工区当天高风险事件；
- 汇总摄像头离线和 BVE 任务异常；
- 根据制度和现场记录解释风险处置依据；
- 生成日报、周报和专项检查报告草稿；
- 形成工单草稿并推荐责任班组；

- 对逾期工单进行归因和升级建议；
- 比较两个时段、两个工区或两个施工阶段的风险变化；
- 协助运维人员定位视频、数据库、模型或网络问题。

每项任务都应说明输入、数据源、工具、输出格式、权限、超时、异常处理、人工确认和验收样例。任务定义完成后，再决定使用本地模型、外部模型、规则引擎、SQL 查询、RAG 或多种能力组合。

45.3 生产 Agent 的四层架构

建议采用四层结构：

第一层是交互层，包括 Web 对话、移动端、事件触发、定时任务和第三方系统调用。

第二层是编排层，包括 Supervisor Agent、任务状态机、意图识别、计划生成、路由、重试、超时和人工确认。

第三层是专业能力层，包括 Vision、Risk、Workflow、Knowledge、Report、Operations 等专业 Agent，以及结构化工具和 RAG 检索。

第四层是治理层，包括身份、权限、审计、评测、Prompt 和模型版本、成本、监控、数据边界、紧急停止和发布回滚。

治理层必须横切其他三层。不能在功能完成后再补权限和审计，因为权限会影响工具设计、状态机和验收方式。

45.4 Agent 的完成定义

一个 Agent 功能不能以“能够回答问题”为完成标准。完整定义至少包括：

- 在指定账号和项目权限下得到正确结果；
- 数据和知识引用能够回到原始记录；
- 无权限、无数据和工具失败时能够明确拒绝或降级；
- 高风险动作经过人工确认；
- 工具调用具备幂等、超时和重试边界；
- 输入、计划、调用、结果、确认和错误全部可审计；
- Prompt、模型、工具和评测集均有版本；
- 可以灰度启用、快速停用和回滚。

第 46 章 Supervisor 与专业 Agent 编排

46.1 Supervisor 不等于超级权限

Supervisor Agent 负责理解任务、拆解步骤、选择专业 Agent 和汇总结果，但不应自动继承所有工具权限。它调用专业 Agent 时，仍应受到当前用户、项目、角色和任务授权的限制。

一个常见错误是为方便开发，给 Supervisor 配置数据库管理员、工单发布和通知发送等全部权限。这样一旦意图识别错误或 Prompt 被诱导，系统就可能执行超出用户权限的动作。正确方式是把权限绑定到工具和资源范围，而不是绑定到“聪明程度”。

46.2 专业 Agent 边界

建议至少划分：

Vision Agent: 查询摄像头、BVE 任务、检测、事件和证据；可解释模型、规则和 ROI，但不能直接修改生产模型。

Risk Agent: 汇总风险、比较趋势、识别异常集中区域和逾期事项；默认只读。

Workflow Agent: 生成工单草稿、建议责任人和期限；正式发布、升级和销项按权限确认。

Knowledge Agent: 检索制度、规范、施工方案、交底、会议纪要和历史案例；必须返回引用和版本。

Report Agent: 组织日报、周报、月报和专项报告；输出草稿或受控文件，不得未经批准自动外发。

Operations Agent: 查询服务健康、摄像头在线、队列、磁盘、备份和发布状态；高风险运维动作必须由专用审批流程控制。

专业 Agent 的边界应稳定。项目差异优先通过工具参数、权限、Prompt 和配置处理，避免每个项目重新设计一套不可维护的 Agent。

46.3 任务状态机

复杂任务应显式保存状态，而不是只依赖大模型上下文。建议状态包括：

CREATED：任务已创建；

PLANNED：计划已生成并通过基本校验；

RUNNING：工具调用或检索进行中；

WAITING_CONFIRMATION：等待人工确认；

WAITING_EXTERNAL：等待第三方系统或异步任务；

SUCCEEDED: 结果完成;

PARTIAL_SUCCESS: 部分结果完成并标明缺失;

FAILED: 执行失败;

CANCELLED: 被用户或系统取消;

EXPIRED: 超过有效时间。

每次状态变更记录原因、执行者、输入摘要、输出摘要和时间。长任务应支持恢复执行，避免浏览器断开后任务完全丢失。

46.4 编排策略

优先采用确定性流程处理已知业务闭环，例如“查询事件—生成工单草稿—人工确认—发布工单”。大模型用于理解自然语言、提取参数、生成解释和组织文本，而不是替代所有业务状态机。

对于开放式分析，可采用“计划—执行—校验—汇总”结构。计划生成后先校验工具是否合法、参数是否完整、数据范围是否过大、是否需要确认。任何工具返回空结果或异常时，编排层必须决定重试、替代、降级或结束，不能让模型假设调用成功。

46.5 并行与串行

相互独立的查询可以并行，例如同时获取风险事件、工单和摄像头状态；存在依赖的步骤必须串行，例如先确定项目和时间范围，再查询数据。并行任务必须有总超时和部分失败策略。

报告生成不应因为一个非关键图表失败而全部中断。系统可以返回“部分成功”，列出缺失项、原因和补充建议，但不能把缺失数据填成看似完整的结论。

第 47 章 Tool Contract、权限与人工确认

47.1 工具是生产边界

Agent 对业务系统的每一次操作都应通过登记工具完成。禁止让模型自由拼接 SQL、Shell、URL 或内部管理命令直接执行。工具是连接自然语言与确定性系统的契约，也是权限、审计、测试和回滚的最小单元。

每个 Tool Contract 至少包含：

工具标识与版本；

业务目的；

输入 Schema；

输出 Schema；

允许角色；

项目和资源范围；

只读或写入属性；

超时与重试；

幂等键；

错误码；

审计字段；

是否需要人工确认；

回滚或补偿方式；

负责人和下线日期。

47.2 参数 Schema 与资源范围

输入参数应尽量结构化，例如 `project_id`、`work_zone_id`、`camera_id`、`time_range`、`risk_level`、`limit`。不要把“查询今天这个项目的高风险事件”作为一段不受约束的字符串交给后端。

资源范围必须由服务端根据用户身份再次校验，不能只相信模型传入的 `project_id`。对列表查询设置最大时间跨度、最大返回量和分页；对文件、报告和视频设置大小限制；对空间查询限制范围和坐标系。

47.3 幂等、重试与补偿

创建工单、发送通知、更新状态等写操作必须支持幂等。推荐由编排层生成 `operation_id` 或 `idempotency_key`，同一操作重复提交时返回原结果，而不是产生多条工单或多次通知。

重试只适用于可安全重试的错误，例如临时网络失败。参数错误、权限拒绝和业务冲突不应盲目重试。跨系统操作无法使用单一数据库事务时，应设计补偿，例如通知发送失败不回滚已确认事件，但要记录待补发状态。

47.4 人工确认分级

L0 只读查询：可自动执行。

L1 分析与草稿：可自动生成，用户查看后使用。

L2 低风险写入：需要明确授权，可采用一次确认或岗位授权。

L3 高风险业务动作：发布重大工单、升级风险、修改规则、批量通知，必须展示动作摘要、影响范围、依据和回滚方式，由授权人员确认。

L4 设备控制与生产安全动作：涉及摄像头控制、边缘节点系统命令、无人机或飞控，只能进入专用控制流程，使用更严格的审批、实时状态校验、紧急停止和人工接管。

确认页面不得只显示“是否继续”。应展示将调用的工具、对象、数量、关键参数、预期影响和不可逆部分。

47.5 权限验证

权限测试必须覆盖：

同一角色访问不同项目；

同一项目的不同角色；

已离职或已停用账号；

临时授权到期；

跨项目资源 ID 注入；

通过 Agent 访问本来在页面上不可见的的数据；

导出、下载和分享；

写操作和审批操作；

审计日志的查看权限。

Agent 不能成为绕过原业务权限的旁路。页面、API、工具和数据库行级范围应形成一致控制。

第 48 章 RAG 知识工程与引用治理

48.1 RAG 的目标是提供依据

BridgeAI-Site 的 RAG 不是为了让回答显得更长，而是为了让制度解释、施工方案查询、风险处置和报告结论有可核验依据。检索质量的核心不是向量数量，而是文档权威性、版本、权限、有效期、分块结构和引用定位。

48.2 知识源分级

建议将知识源分为：

A 级权威文件：现行法律法规、标准规范、批准的施工组织设计、专项方案、应急预案和正式制度。

B 级项目文件：技术交底、会议纪要、监理通知、整改记录、检查记录和验收文件。

C 级经验资料：历史案例、内部手册、培训资料和常见问题。

D 级临时资料：草稿、个人笔记、未批准方案和即时消息。

回答时优先使用 A、B 级；C 级用于补充经验；D 级必须明确标识，原则上不作为高风险决策依据。

48.3 文档入库流水线

文档入库应经过：

上传与病毒、格式检查；

文件指纹和重复检测；

项目、类型、密级、所有者和有效期登记；

文本与版面解析；

表格、标题、页码和附件保留；

分块；

Embedding;

权限索引;

抽样校验;

发布;

旧版本失效或保留历史访问。

扫描件在 OCR 质量不足时不得直接作为权威知识发布。关键表格和条款应人工抽样检查。无法可靠解析的文件可以保留原件并标为“仅原文查看”。

48.4 分块与元数据

分块应尽量沿标题、条款、表格和语义边界进行，而不是固定字符数机械切割。每个 Chunk 关联：

document_id、document_version、项目、标题层级、页码或段落、文件日期、生效日期、失效日期、权限标签、来源单位、解析器版本和内容哈希。

表格不得丢失表头；跨页条款应保留上下文。分块过小会失去条件，过大则降低检索精度并增加上下文成本。

48.5 混合检索与过滤

推荐流程：

先按用户、项目、文档状态、有效期和密级过滤；

再进行关键词、字段和向量混合召回；

使用标题、权威等级、时间和语义相关性重排；

进行去重和相邻块合并；

将有限数量的高质量证据送入模型。

权限过滤必须发生在生成前。不能先检索全部内容，再要求模型“不要引用无权限资料”。

48.6 引用和无依据处理

回答应包含文档名称、版本、页码或条款位置。生成报告时，引用应能够回到原文件或受控预览页面。

当知识库没有依据、资料已过期、不同文件相互冲突或问题超出授权范围时，Agent 应明确说明。对于冲突资料，应列出各自版本和来源，提示由责任人确认，不能自行选择更“像答案”的一条。

48.7 知识发布与撤回

知识文档采用草稿、待审核、已发布、已失效、已撤回状态。文档更新时应建立新版本，并在新版本发布后失效旧版本的默认检索资格。撤回不能只删除向量，还要处理缓存、引用和已经生成的长期报告。

第 49 章 上下文、记忆与结构化状态

49.1 上下文不是越长越好

Agent 上下文应包含完成当前任务所需的最小信息。把全部历史对话、全部项目文档和大量数据库结果塞入上下文，不仅增加延迟和成本，也会让过期信息、错误信息和无权限信息混入推理。

49.2 上下文组成

建议区分：

身份上下文：用户、组织、角色、项目和权限；

任务上下文：目标、参数、时间范围、输出格式和状态；

业务上下文：结构化查询结果、事件、工单和设备状态；

知识上下文：经过权限和版本过滤的引用；

对话上下文：与当前任务直接相关的历史；

系统上下文：Agent、工具和安全规则版本。

每类上下文都有来源、生成时间和有效期。

49.3 短期记忆和长期记忆

短期记忆用于当前会话或任务，例如用户刚确认的时间范围。长期记忆只保存明确有价值且经过授权的信息，例如项目常用报告格式、用户偏好的统计维度或已经批准的业务配置。

不得把模型推测、一次性错误输入、敏感个人信息或未经确认的结论写入长期记忆。长期记忆应可查看、修改、删除和审计。

49.4 结构化状态优先

关键状态保存在 PostgreSQL，而不是只保存在对话文本。报告任务、工单草稿、审批、工具调用、文件生成和异步进度都应使用结构化记录。

对话可以引用这些状态，但不能成为唯一事实源。这样即使模型更换、会话丢失或任务跨设备继续，也能恢复业务过程。

49.5 上下文压缩与过期

长会话可以生成结构化摘要，但摘要必须标明生成时间和来源，不得覆盖原始审计。项目阶段、人员、规则和知识版本发生变化后，相关上下文应失效并重新查询。

第 50 章 事件、风险、工单与报告闭环

50.1 Agent 必须进入真实流程

Agent 的价值应体现在缩短确认时间、提高信息完整性、降低报告编制成本和增强风险追踪，而不是增加一个独立入口。实施时应把 Agent 嵌入事件列表、工单详情、GIS、视频证据和报表页面。

50.2 事件分析

针对 BVE 事件，Risk Agent 可执行：

合并同一人员或区域的重复事件；

汇总摄像头、工区、班组、时段和风险类型；

识别短期异常增长；

比较整改前后变化；

关联摄像头离线、规则变化和施工阶段；

生成需要人工关注的优先列表。

Agent 的分析应基于结构化事件和证据，不应仅根据截图描述进行风险统计。

50.3 工单草稿与发布

Workflow Agent 生成工单草稿时，应填充事件、工区、风险等级、责任单位建议、整改期限、依据和证据链接。责任人推荐可以参考工区、班组、专业和历史分派规则，但最终仍需业务规则或授权人员确认。

正式发布后，工单状态由 workflow 服务管理。Agent 不得通过文字回答假装工单已经创建。每次写操作必须返回业务 ID 和状态。

50.4 逾期与升级

系统按规则识别即将逾期和已逾期工单。Agent 可生成原因分类、影响评估和升级建议。升级动作应考虑风险等级、逾期时长、重复次数和责任链，并由授权人员确认。

通知失败、负责人变更或班组停用时，应形成异常状态，而不是静默丢失。

50.5 报告生成

Report Agent 生成日报、周报和专项报告时，建议采用“数据快照 + 模板 + 解释”的方式：

数据快照固定统计截止时间和查询条件；

模板固定章节、指标、表格和口径；

Agent 负责解释变化、总结重点和生成行动建议；

所有数字从结构化数据生成；

所有重要结论关联事件、工单或知识引用。

报告发布前进行数字一致性校验。标题中的事件数、正文统计和附件明细必须来自同一快照。

50.6 通知渠道

通知可以通过站内、短信、邮件、企业协同工具或其他渠道发送。渠道接入需记录供应商、模板、签名、频率、失败重试、费用和数据边界。

高频 AI 事件不应逐条轰炸用户。应通过事件合并、风险分级、摘要和静默策略控制噪声。

第 51 章 Agent 评测、护栏与可观测性

51.1 评测必须覆盖任务

Agent 评测不是泛化的聊天评分。每个生产任务建立评测集，包括正常、无数据、无权限、数据冲突、工具失败、超时、恶意输入和高风险动作。

主要指标包括：

任务完成率；

结构化参数正确率；

工具选择与调用成功率；

引用正确率；

数字一致性；

越权率；

应确认动作的确认覆盖率；

虚构率；

首字延迟和总耗时；

人工修改量；

用户采纳率。

51.2 离线评测与在线观察

离线评测用于发布前回归，使用固定数据快照和期望结果。在线观察用于发现真实任务分布、失败模式和用户行为变化。在线数据进入评测集前需脱敏和授权。

模型、Prompt、工具、RAG、Schema 或权限发生变化时，都应触发相关评测回归。

51.3 护栏

护栏至少包括：

输入长度、文件类型和恶意内容检查；

Prompt 注入防护和外部文本隔离；

工具白名单；

参数 Schema；

权限与资源范围校验；

查询和导出限额；

敏感数据脱敏；

高风险动作确认；

输出结构校验；

数字和引用校验；

超时、熔断和降级；

紧急停用。

护栏应尽量由确定性代码实现，而不是仅靠系统 Prompt 提醒模型。

51.4 可观测性

每个 Agent 任务至少记录：

trace_id、task_id、user_id、project_id；

Agent、模型、Prompt 和工具版本；

输入摘要与敏感字段掩码；

计划与状态变化；

检索文档与 Chunk；

工具调用参数摘要、耗时、结果和错误；

Token、推理耗时或本地资源；

人工确认；

最终结果；

用户反馈和后续业务结果。

运维面板应展示成功率、失败类型、延迟、工具异常、确认等待、成本或资源、引用缺失和越权拦截。

51.5 故障处理

Agent 故障分为：

模型不可用；

RAG 无结果或索引异常；

工具失败；

权限配置错误；

上下文过期；

输出格式错误；

任务超时；

重复写入；

错误建议被用户采纳；

数据泄露或越权。

严重故障应支持关闭单个 Agent、单个工具、单个项目写操作或全部智能功能，同时保留基础业务系统运行。

第 52 章 示例项目：从“很聪明”到“可以上线”

52.1 演示阶段

示例项目的 Agent 可以回答制度问题、总结风险并生成日报。演示时，团队输入“帮我处理今天的问题”，Agent 自动查询事件、生成工单和报告，看起来非常高效。

52.2 生产测试暴露的问题

测试发现：

同一句话在不同项目中可能查询到错误范围；

知识库同时存在旧版和新版动火制度；

Agent 在工具超时后仍回答“工单已创建”；

重复点击产生两条工单；

普通安全员可以通过自然语言请求导出全部项目数据；

报告中的事件总数与附件明细不一致；

高风险升级没有明确确认页面。

这些问题与模型语言能力无关，而是身份、版本、工具契约、幂等、权限和数据快照没有工程化。

52.3 整改

团队完成以下整改：

所有任务绑定 user_id、project_id 和权限快照；

知识检索增加有效期和文档状态过滤；

工具返回结构化业务 ID，失败时禁止生成成功表述；

写操作增加幂等键；

导出工具按项目和角色限制；

报告使用固定数据快照；

高风险动作进入 WAITING_CONFIRMATION；

建立离线评测集和越权测试；

上线初期只开放只读查询和草稿生成。

52.4 上线结论

Agent 的成熟度不是“能否自主完成更多动作”，而是“在多大范围内能够稳定、可解释、可恢复地完成授权任务”。自动化等级应随着证据逐步提升，而不是一次性打开全部权限。

Agent 与 RAG 上线 SOP

1. 冻结 Agent、模型、Prompt、工具和知识版本。

2. 核对用户、项目、角色和资源权限。

3. 发布并抽检知识文档，验证引用和冲突处理。

4. 对每个工具执行正常、异常、越权、超时和重复调用测试。

5. 运行任务级离线评测。

6. 配置人工确认、降级和紧急停用。

7. 在测试项目影子运行。

8. 开放只读和草稿能力。

9. 小范围开放低风险写入。

10. 监控失败、越权拦截、引用缺失和用户修改量。

11. 形成上线记录与回滚包。

12. 经项目负责人、安全负责人和运维负责人确认后进入业务联调。

附录 R Agent 与工具登记表

Agent 名称：

Agent 版本：

负责人：

适用项目：

主要任务：

允许角色：

模型与版本：

Prompt 版本：

可用工具：

数据范围：

是否包含写操作：

是否需要人工确认：

超时与降级：

日志与审计位置：

离线评测结果：

灰度范围：

回滚版本：

批准人：

生效日期：

附录 S Tool Contract 记录表

工具标识：

工具版本：

业务目的：

输入 Schema：

输出 Schema：

允许角色：

项目与资源范围：

只读／写入：

最大查询范围：

超时：

重试：

幂等键：

错误码：

人工确认级别：

补偿／回滚：

审计字段：

负责人：

测试用例：

上线日期：

下线日期：

附录 T RAG 文档发布记录

文档名称：

文档版本：

项目：

来源单位：

权威等级：A／B／C／D

文件日期：

生效日期：

失效日期：

密级与权限：

文件指纹：

解析器版本：

分块策略：

Chunk 数量：

Embedding 版本：

表格抽检结果：

页码／条款定位结果：

冲突文档：

审核人：

发布人：

发布状态：

撤回方式：

附录 U Agent 评测与灰度记录

评测编号：

Agent／任务：

模型／Prompt／工具版本：

数据快照：

用例数量：

正常用例通过率：

无数据处理：

无权限处理：

工具失败处理：

引用正确率：

数字一致性：

越权次数：

需确认动作覆盖率：

平均响应时间：

人工修改量：

已知限制：

灰度项目与角色：

观察周期：

回滚条件：

评测人：

批准人：

第八篇 联调、培训、试运行与验收

第 53 章 联调策略与测试基线

53.1 联调不是最后一次总测试

联调应从基础服务部署开始持续进行。每完成一条链路，就建立可重复测试：登录与权限、GIS、视频、BVE、事件、工单、Agent、RAG、报告、通知、备份和监控。最终联调是在已有模块测试之上验证端到端行为，而不是第一次发现模块是否可用。

53.2 测试环境与版本冻结

联调前形成测试基线：

平台、数据库、BVE、Agent、模型、Prompt、Rule 和知识版本；

服务器、边缘设备和网络拓扑；

摄像头、GIS、工区和用户数据；

测试账号与权限；

验收样本与数据快照；

第三方接口；

监控和日志；

已知问题。

联调期间原则上冻结非必要变更。必须变更时记录影响并执行回归。

53.3 测试分层

单组件测试：每个服务、数据库、模型、工具和接口。

链路测试：视频链路、事件链路、工单链路、Agent 工具链路、知识检索链路。

端到端测试：从现场输入到业务结果和证据。

非功能测试：性能、稳定性、安全、恢复和可运维性。

用户验收测试：由真实角色按实际场景执行。

53.4 测试数据

测试数据应包含正常、边界、异常和历史状态。AI 场景使用现场正样本、空样本、相似负样本、夜间和遮挡样本。Agent 测试使用固定项目、时间范围和期望查询结果。

禁止在生产项目中随意制造高风险事件或批量工单。需要模拟时使用测试项目、回放视频、影子模式或专用标识，并在测试后清理。

第 54 章 端到端场景与故障注入

54.1 核心端到端场景

至少验证：

摄像头在线 → Media 取流 → BVE 推理 → 规则命中 → 事件聚合 → 证据保存 → 风险确认 → 工单 → 整改 → 复核 → 销项 → 报表。

用户提问 → Supervisor → Risk/Knowledge/Workflow Agent → 工具与 RAG → 引用结果 → 工单草稿 → 人工确认 → 发布 → 审计。

GIS 工区调整 → 版本发布 → ROI 复核 → 事件落点 → Agent 查询和报表口径一致。

54.2 异常场景

联调必须主动制造可控故障：

摄像头断流和恢复；

视频地址失效；

网络延迟、丢包和短时中断；

BVE 节点重启；

GPU 或统一内存接近上限；

PostgreSQL 连接耗尽；

Redis 队列积压；

MinIO 写入失败或容量预警；

第三方通知失败；

知识文档撤回；

Agent 工具超时；

重复提交；

权限撤销；

证书临近或模拟失效；

边缘节点离线和补传。

观察系统是否告警、降级、恢复、去重和保留证据。

54.3 故障注入安全

故障注入必须有批准、窗口、对象、停止条件、恢复步骤和负责人。生产试运行环境只能执行经过评审的低风险注入。数据库误删除、证书替换等高风险场景应在隔离环境演练。

54.4 恢复验证

故障恢复后不能只确认服务重新运行，还要验证：

视频时间线连续性；

事件是否重复或丢失；

工单状态；

对象证据；

Agent 任务状态；

边缘补传顺序；

监控恢复通知；

审计完整性。

第 55 章 性能、安全与数据一致性测试

55.1 性能负载模型

基于实际项目建立负载模型：

视频路数、编码和预览并发；

BVE 任务、采样 FPS 和模型；

事件峰值；

工单和报表并发；

Agent 并发、工具数量和上下文；

对象上传与下载；

数据库查询；

边缘补传。

测试稳态、峰值和持续运行。短时间峰值通过不代表 14 天试运行稳定。

55.2 关键性能指标

核心 API P50、P95、P99；

视频首帧、卡顿和断流恢复；

BVE 端到端告警延迟；

事件证据生成耗时；

工单发布与通知耗时；

Agent 首字和完整响应；

RAG 检索耗时；

报告生成时间；

数据库慢查询和锁等待；

CPU、GPU、内存、磁盘、网络 and 温度；

队列长度和积压恢复时间。

验收值以项目方案为准，并记录测试硬件、数据和脚本。

55.3 安全测试

安全测试至少包括：

默认账号和弱密码；

RBAC 与数据隔离；

跨项目资源访问；

未授权下载；

接口鉴权；

Token 过期与吊销；

文件上传；

注入和参数边界；

敏感日志；

Secrets 暴露；

HTTPS 和证书；

远程维护；

Agent Prompt 注入；

工具越权；

批量导出；

审计不可抵赖性。

发现数据泄露、越权写入或高风险工具绕过时，属于阻断缺陷。

55.4 数据一致性

检查 PostgreSQL 业务记录与 MinIO 对象、GIS 点位、事件统计、工单、报表和 Agent 结果的一致性。重点验证：

事件记录存在但证据缺失；

对象存在但无业务引用；

工单关联错误项目或事件；

报表汇总与明细不一致；

时间时区错误；

GIS 与 ROI 版本不一致；

边缘补传重复；

删除或撤回后缓存未失效。

对关键对象建立定期一致性巡检和修复流程。

第 56 章 用户培训与运行方式改变

56.1 培训目标

培训不是演示功能，而是让不同角色能够独立完成日常任务和异常处理。培训结束后，应能够证明：

管理员会创建用户、配置权限和维护基础数据；

安全委员会确认事件、发起工单和反馈误报漏报；

班组负责人会接收、整改和提交证据；

监理会复核、抽查和查看审计；

运维人员会检查服务、视频、日志、告警、备份和恢复；

管理者会查看报表和风险趋势；

Agent 用户理解引用、确认和权限边界。

56.2 分角色课程

管理员课程：组织、角色、项目、字典、摄像头、GIS、配置和审计。

安全业务课程：事件、风险、工单、整改、复核、销项和报告。

AI 运营课程：场景卡、ROI、阈值、误报漏报、样本反馈和灰度。

Agent 课程：提问边界、数据范围、知识引用、草稿、确认和错误反馈。

运维课程：部署、日志、监控、告警、备份、升级、回滚和边缘节点。

56.3 培训方式

采用“讲解—演示—学员操作—异常演练—考核”。每个关键角色至少完成一个真实场景闭环。

只观看演示不能视为培训通过。

培训环境和账号应接近生产，但使用可控数据。培训产生的测试工单和通知应明确标识。

56.4 培训材料

交付用户手册、管理员手册、运维手册、快速操作卡、常见问题、故障升级路径和培训录像。材料中的页面、版本和权限必须与交付系统一致。

56.5 组织变更

系统上线会改变告警、整改、统计和汇报方式。项目负责人应明确：

哪些原有纸面或群聊流程被替代；

哪些仍然保留；

谁每日登录；

谁处理误报；

谁维护摄像头和工区；

谁审核 Agent 结果；

谁对逾期负责；

指标如何进入例会。

没有运行责任的系统会在培训后迅速失去使用。

第 57 章 试运行与日常运营机制

57.1 试运行目标

试运行用于验证系统在真实人员、真实网络、真实工序和真实数据下能否持续运行。它不是延长的开发期，也不是只等待时间结束。

建议试运行周期为 14 天或按合同约定。期间保持版本受控，重大修改需重新计算稳定运行周期。

57.2 试运行启动条件

核心功能与端到端链路通过；

S1 缺陷为 0；

S2 缺陷有明确临时措施；

用户和权限就绪；

关键人员培训通过；

监控、告警和备份正常；

AI 场景完成灰度；

Agent 写操作权限受控；

试运行指标、日报和问题机制确认；

运维值班和升级路径确认。

57.3 每日运行

每日检查：

核心服务和资源；

摄像头在线和取流；

BVE 任务、事件量和异常；

证据文件；

工单新增、逾期和关闭；

Agent 失败、等待确认和越权拦截；

知识文档变更；

存储容量；

备份；

用户活跃和问题反馈。

形成试运行日报，重大问题即时升级。

57.4 AI 运营

每日抽样确认误报和漏报，记录摄像头、场景、时间、模型、规则、ROI 和原因。参数调整必须通过变更记录，不得边试运行边随意修改而无法比较指标。

当施工阶段、摄像头视角或补光变化时，暂停受影响场景并重新评估。

57.5 Agent 运营

观察任务成功率、引用、工具失败、响应时间、人工修改量和确认等待。发现高风险错误时，先降低自动化等级或关闭写工具，再分析根因。

新文档发布、人员权限变化和业务流程变化应触发相应回归。

57.6 用户采用

试运行不仅看系统在线率，还要看真实使用：

安全员是否每日处理事件；

班组是否通过系统整改；

监理是否复核；

管理者是否查看报告；

Agent 结果是否被采纳；

纸面或群聊旁路是否仍是主要流程。

低使用率应分析流程、培训、权限、告警噪声和页面体验，不能只归因于用户“不愿意使用”。

第 58 章 缺陷、指标与验收证据

58.1 单一缺陷清单

所有联调和试运行问题进入统一清单。字段包括：

缺陷 ID、发现时间、环境、版本、模块、步骤、期望、实际、影响、等级、责任人、修复版本、验证人、证据和状态。

同一根因导致的多个现象可关联问题簇，但不能为了降低数量而合并到无法验证。

58.2 缺陷等级

S1：系统不可用、严重数据错误、安全风险、证据丢失或关键业务阻断。

S2：关键功能异常，有临时替代但明显影响运行。

S3：一般功能、性能或体验问题。

S4：优化建议或范围外需求。

终验前 S1 必须为 0。S2 的关闭要求和遗留条件由验收基线确定。

58.3 验收证据包

每个验收项至少包含：

验收编号；

需求或合同条款；

环境和版本；

测试账号与权限；

操作步骤；

输入数据；

预期结果；

实际结果；

截图、视频、日志或报告；

测试人；

见证人；

日期；

缺陷关联；

结论。

AI 和 Agent 验收还要保存样本集、统计脚本、模型／Prompt／工具版本和计算口径。

58.4 指标冻结

验收统计使用固定周期、固定项目、固定摄像头、固定场景和固定版本。不得在结果不理想时临时更换样本、排除困难时段或修改统计单位。

对不可控的第三方故障、客户网络中断或施工停工，可按约定从统计中标记，但必须保留证据和双方确认。

58.5 验收流程

内部预验收；
客户测试准备会；
正式初验；
问题整改；
回归与复测；
遗留问题确认；
终验；
签署验收文件；
运维移交。

每一步都有输入、输出、责任人和退出条件。会议纪要不能替代测试证据。

第 59 章 移交、质保与持续改进

59.1 移交对象

移交不只包括系统地址和管理员密码。完整交付包括：

运行系统与版本；
服务器和边缘设备清单；
网络、域名、证书和端口；
数据库、对象存储和备份；
摄像头和 GIS 主数据；
BVE 模型、场景、ROI 和规则；
Agent、工具、Prompt、知识库和评测；

用户、角色和权限；
监控、日志和告警；
发布、回滚和恢复包；
用户、管理员和运维文档；
培训和考核记录；
试运行和验收证据；
遗留问题和路线图。

59.2 账号与密钥移交

高权限账号采用安全方式交接，要求首次登录修改密码。实施临时账号、测试 Token 和远程访问在移交后回收或设置到期。

密钥移交记录所有者、用途、保管位置、轮换和吊销方式。不得在普通交付文档中附明文密码。

59.3 运维责任

明确 L1、L2、L3 支持：

L1 现场管理员：用户操作、基础数据和常见问题。

L2 BridgeAI 运维：服务、视频、配置、日志、备份和一般故障。

L3 研发与算法：代码缺陷、复杂性能、模型、Agent 和数据问题。

每级定义响应时间、升级条件、工作时间、远程和现场边界。

59.4 质保与变更

质保范围应区分产品缺陷、配置调整、模型效果迭代、新场景、新接口、现场设备改造和第三方服务问题。施工阶段变化导致 ROI、摄像头或规则重配时，按合同或变更机制处理。

所有生产变更继续使用发布、评测、灰度和回滚流程，不能因为项目已验收而降低控制。

59.5 持续改进

建议每月或每季度复盘：

风险发现和闭环；

误报漏报；

摄像头和网络质量；

用户采用；

工单逾期；

Agent 成功率和采纳；

知识库更新；

容量和性能；

故障与恢复；

新增业务需求。

形成改进 Backlog，按价值、风险和成本排序，避免系统在验收后停止演进。

第 60 章 示例项目：从试运行混乱到可验收

60.1 第一周的问题

示例项目进入试运行后，系统在线，但现场运行混乱：

安全员仍在微信群处理告警；

班组未及时登录工单；

部分 AI 事件重复；

Agent 日报数字与人工台账不同；

夜间摄像头画面变化导致误报；

用户遇到问题直接找开发人员；

日报只记录“系统正常”，没有指标。

60.2 建立运行机制

项目组没有立即增加功能，而是重建运营规则：

确定系统为正式事件和工单事实源；

每日 8:30 由安全员处理前一日事件；

班组负责人在规定时间内更新工单；

监理每日抽样复核；

统一试运行日报；

重复事件按规则合并；

夜间不适用场景暂停；

报告使用固定数据快照；

问题进入单一缺陷清单；

运维采用 L1-L3 升级。

60.3 第二周结果

第二周用户活跃、工单闭环和数据一致性明显改善。仍有两个场景需要后续模型优化，但通过限定摄像头、时段和风险等级，已能在当前范围稳定使用。遗留项被写入验收文件和后续计划，没有通过口头承诺模糊处理。

60.4 验收结论

系统验收的核心不是证明“没有任何问题”，而是证明约定范围内的功能、性能、AI、Agent、数据、安全、恢复和组织运行均有证据；已知问题具有清晰影响、临时措施、责任和期限。

联调与试运行 SOP

1. 冻结测试基线和验收口径。
2. 完成组件、链路和端到端测试。
3. 执行性能、安全、数据一致性和恢复测试。
4. 关闭 S1，控制 S2。
5. 完成分角色培训和实操考核。
6. 确认值班、告警和问题机制。
7. 启动真实试运行。
8. 每日记录服务、视频、AI、Agent、工单、容量和备份。
9. 每周评审指标、缺陷、风险和变更。
10. 固定验收数据快照和版本。
11. 完成内部预验收、初验、整改和复测。
12. 签署终验与移交文件。
13. 回收临时权限并启动质保运维。
14. 形成项目复盘和持续改进清单。

附录 V 端到端联调测试记录

测试编号:

场景名称:

需求／合同条款:

环境与版本:

测试账号与角色:

摄像头／工区／项目:

前置条件:

测试步骤:

输入数据:

预期结果:

实际结果:

事件／工单／任务 ID:

截图／视频／日志:

性能结果:

安全与权限结果:

缺陷 ID:

测试人:

见证人:

测试日期:

结论: 通过／有条件通过／不通过

附录 W 培训与实操考核记录

项目：

培训日期：

培训环境：

讲师：

角色：管理员／安全员／班组／监理／运维／管理者

课程内容：

学员名单：

实操任务：

异常演练：

考核结果：

未通过项：

补训计划：

培训材料版本：

录像／签到位置：

学员确认：

项目经理确认：

附录 X 试运行日报

日期：

试运行第几天：

平台版本：

模型／Prompt／Rule 版本：

核心服务健康：

摄像头在线数／总数：

BVE 任务正常数／总数：

新增事件：

高风险事件：

确认误报：

发现漏报：

新增工单：

已关闭工单：

逾期工单：

Agent 任务数：

Agent 失败数：

等待确认数：

知识更新：

存储使用率：

备份结果：

P1／P2 告警：

用户活跃情况：

当日变更：

主要问题：

次日计划：

值班人：

审核人：

附录 Y 缺陷与整改记录

缺陷 ID：

发现日期：

环境与版本：

模块：

问题描述：

复现步骤：

期望结果：

实际结果：

影响范围：

等级：S1／S2／S3／S4

临时措施：

根因：

修复方案：

责任人：

计划版本：

计划日期：

修复证据：

回归范围：

验证人：

验证日期：

状态：

遗留说明：

附录 Z 终验与运维移交清单

一、验收

☐ 合同功能完成

☐ 视频与 GIS 验收通过

☐ BVE 与 AI 场景验收通过

☐ Agent 与 RAG 验收通过

☐ 工单与报表闭环通过

☐ 性能、安全和恢复通过

☐ S1 为 0

☐ 遗留问题已确认

二、系统与数据

☐ 平台、数据库和对象存储

☐ 摄像头、GIS 和项目主数据

☐ 模型、ROI、规则和场景卡

☐ Agent、工具、Prompt 和知识

☐ 用户、角色和权限

☐ 监控、日志和告警

☐ 备份、恢复和回滚包

三、文档与能力

☐ 用户手册

☐ 管理员手册

☐ 运维手册

☐ 部署与架构文档

☐ 培训和考核记录

☐ 试运行报告

☐ 验收证据包

☐ 项目复盘

四、账号与责任

☐ 高权限账号安全交接

- ☐ 临时账号回收
- ☐ 远程维护方式确认
- ☐ L1/L2/L3 联系人
- ☐ SLA 与升级路径
- ☐ 质保范围
- ☐ 变更流程

建设单位：

施工单位：

监理单位：

BridgeAI：

移交日期：

第四轮完成说明

本轮已完成第七篇“Agent、RAG 与业务闭环上线”和第八篇“联调、培训、试运行与验收”的出版化扩写。内容覆盖生产 Agent 架构、Supervisor 与专业 Agent 编排、Tool Contract、权限与人工确认、RAG 知识工程、上下文和记忆、事件工单报告闭环、Agent 评测与护栏，以及分层联调、故障注入、性能安全测试、角色培训、试运行运营、验收证据和运维移交。新增 Agent 工具登记、RAG 发布、Agent 评测、端到端联调、培训考核、试运行日报、缺陷整改和终验移交八套工程模板。下一轮将进入第九篇“边缘节点、无人机与 DJI Manifold 3 交付”和第十篇“案例复盘、SOP、表单与检查清单”。

第九篇 边缘节点、无人机与 DJI Manifold 3 交付

第 61 章 把边缘节点定义为独立生产单元

61.1 边缘节点不是“放在现场的小服务器”

BridgeAI-Site 的边缘节点承担视频接入、实时推理、事件聚合、证据缓存、设备控制协同和断网运行等任务。它不是中心平台的简单缩小版，而是具有独立状态、独立故障域和明确安全边界的生产单元。

边缘交付必须回答六个问题：节点在断网时继续做什么；恢复联网后同步什么；中心与边缘谁拥有最终事实；模型、规则和配置如何发布；设备异常时如何降级；涉及无人机或飞控时如何立即停止。

建议将边缘能力划分为四层：

设备层：摄像头、无人机、云台、传感器、激光雷达、定位与飞控接口。

运行层：Media、BVE Runtime、TensorRT Engine、任务调度、缓存、日志和健康检查。

协同层：设备身份、配置下发、事件同步、文件补传、远程诊断和版本管理。

安全层：控制权仲裁、权限、签名、审批、紧急停止、物理安全和审计。

只有四层均形成交付物，边缘节点才具备长期生产属性。

61.2 中心与边缘的事实边界

中心平台保存项目、用户、工区、任务、模型版本、规则版本、事件主记录、工单和审计，是全局事实源。边缘节点保存本地运行状态、短期任务、缓存证据、设备遥测和待同步事件，是现场执行事实源。

断网期间，边缘节点可以继续执行已授权的只读采集、视觉推理、低风险事件生成和本地证据保存；不得在缺少中心审批或现场确认时自动扩大控制范围、修改安全边界或执行新的高风险飞控任务。

恢复联网后，采用事件唯一 ID、设备 ID、任务版本和幂等键进行同步。中心不得仅按上传时间覆盖边缘记录；冲突时应依据事件发生时间、版本、审批状态和人工确认进行合并。

61.3 边缘状态机

推荐状态：

PROVISIONING：设备初始化、注册与基线检查。

READY：设备健康、配置完整，尚未执行任务。

RUNNING：正在执行视频、AI 或无人机任务。

DEGRADED：部分能力不可用，但核心安全功能仍在运行。

OFFLINE：与中心失联，进入本地策略。

MAINTENANCE：升级、校准或人工维护。

SAFE_STOP：高风险能力被停止，仅保留安全监测和日志。

FAULT：关键硬件、运行时或控制链故障。

每次状态变化应记录触发原因、时间、操作者、任务、版本和恢复条件。中心页面不得只显示“在线／离线”，而应展示节点是否具备执行当前任务的能力。

61.4 边缘交付的最小数据合同

节点注册数据：设备编号、项目、硬件、序列号、网络、固件、运行时和责任人。

配置数据：任务、视频源、模型、阈值、ROI、规则、缓存、同步和降级策略。

遥测数据：CPU、GPU、内存、温度、磁盘、网络、帧率、推理延迟、队列和飞控状态。

事件数据：事件 ID、设备、任务、时间、位置、模型、规则、证据、同步状态和确认结果。

发布数据：应用包、模型、Engine、配置、校验和、目标环境、安装结果和回滚版本。

控制数据：控制请求、授权人、有效期、控制模式、控制权状态、执行结果和紧急停止记录。

第 62 章 边缘硬件、环境与设备身份基线

62.1 硬件基线必须面向持续负载

边缘硬件选型不能只验证“模型可以运行”。应在真实视频、目标分辨率、连续推理、证据写盘和网络同步同时开启时，测量 CPU、GPU、内存、温度、功耗和降频。

GPU 工控机重点检查：GPU 型号与显存、硬件解码能力、系统盘与数据盘、网络接口、USB／串口／CAN 等外设接口、看门狗、远程开关机和宽温能力。

DJI Manifold 3 重点记录：设备序列号、固件、系统镜像、TensorRT 运行环境、DPK 应用版本、存储余量、供电、散热、网络、与飞行平台的连接状态以及远程维护方式。

验收记录不得只写“配置符合”。必须附硬件信息、运行时版本、持续负载曲线和现场安装照片。

62.2 供电、散热与安装

无人机边缘计算的供电和散热直接影响飞行安全。任何新增计算负载都应评估电源预算、峰值功耗、热量、安装位置、线缆固定和对机体重心的影响。

现场固定边缘节点还应检查 UPS、接地、防尘、防水、振动、阳光直射、机柜风道和维护空间。设备温度达到预警阈值时，系统应优先降低非关键 AI 任务、减少采样率或停止录像转码，而不是继续满负载运行直至异常退出。

62.3 网络与时间

边缘节点至少配置管理链路和业务链路的逻辑边界。视频、遥测、证据上传和远程维护应分别评估带宽和优先级。弱网下优先保障控制状态、告警摘要和关键证据，普通录像可以延迟补传。

中心、边缘、摄像头、遥控器、飞控日志和传感器应使用可对齐的时间基准。无法持续访问统一时间源时，记录本地单调时钟、启动时间和时间偏差，使后续能够重建事件序列。

62.4 设备身份与可信注册

每个边缘节点使用唯一设备身份。首次注册应由项目管理员批准，并绑定项目、设备类型和允许能力。设备令牌或证书不得复制到其他节点。

设备身份用于：

验证配置下发对象；

限制可访问的项目和任务；

签名遥测和事件；

控制模型与 DPK 包下载；

审计远程维护；

在设备丢失或退役时快速吊销。

更换主板、系统重装或设备转移项目时，应重新执行身份审核，而不是继续沿用旧凭证。

62.5 边缘基线检查

交付前至少验证：

硬件与设备编号一致；

系统、驱动、TensorRT 和应用版本在支持矩阵内；

磁盘、温度、供电和网络满足持续运行；

设备时间可与中心对齐；

远程维护可用且能够停用；

日志、遥测和告警能够上报；

断网时本地任务按策略运行；

恢复联网后事件与文件能够补传；

紧急停止能够立即生效；

设备配置、模型和应用均有回滚版本。

第 63 章 DJI Manifold 3 软件与 DPK 工程基线

63.1 软件资产必须绑定目标设备

DJI Manifold 3 上运行的应用不是一个孤立可执行文件，而是一组强依赖目标设备环境的工程资产，包括 DPK 包、TensorRT Engine、配置、依赖、启动脚本、权限声明、模型元数据和校验和。

每个发布包必须记录：

项目和设备编号；

DPK 应用版本；

源代码 Commit 或构建编号；

目标系统与固件基线；

TensorRT、CUDA 或相关运行环境；

模型、标签和输入输出定义；

配置 Schema；

包文件校验和；

安装、升级和回滚说明；

已验证的飞行平台和测试记录。

63.2 配置与应用分离

应用包包含稳定运行逻辑，项目配置包含航线、任务、模型选择、阈值、坐标原点、控制参数和中心地址。禁止每次调整 ROI、服务器地址或航线都重新修改代码和打包。

配置加载应具备：

Schema 校验；

缺失项与非法值拒绝启动；

默认值明确；

敏感信息独立存储；

版本和生效时间；

配置回滚；

启动日志打印非敏感摘要。

涉及飞控、坐标转换和控制权的参数不得允许运行中无审批热修改。

63.3 启动、守护与安全停止

DPK 应用启动后先完成自检，再声明 **READY**。自检至少包括模型文件、**Engine** 兼容性、传感器连接、中心配置、存储空间、时间、控制接口和日志目录。

应用异常退出时可以由守护机制重启，但飞控相关模块必须区分“计算服务重启”和“控制任务恢复”。未经重新确认，不应在重启后自动恢复上一条飞行控制命令。

安全停止时：

撤销或释放控制权；

停止发送速度、位置或姿态指令；

保留必要的状态上报；

完成缓存刷盘；

记录停止原因；

向遥控端和中心平台发送状态；

允许现场人员恢复人工控制。

63.4 日志分层

运行日志：应用启动、配置、模块状态和异常。

推理日志：帧时间、模型、延迟、目标数量和资源状态。

控制日志：控制权请求、状态、命令、反馈和超时。

定位日志：GPS、视觉定位、IMU、姿态、坐标系和融合状态。

任务日志：航线点、当前阶段、完成度和失败原因。

审计日志：安装、升级、配置、远程操作、审批和紧急停止。

日志必须具有统一任务 ID 和时间轴，使一次飞行可以从中心任务追踪到设备、模型、控制命令和证据。

第 64 章 YOLO26 从 .pt 到 ONNX 再到 TensorRT 的发布链

64.1 固定转换链路

BridgeAI-UAV 的目标发布链路为：

开发环境训练 YOLO26，生成 .pt；

在 Windows WSL 环境将 .pt 导出为 ONNX；

通过 SSH 将 ONNX、标签和元数据传输到 DJI Manifold 3；

在目标设备上将 ONNX 转换为 TensorRT Engine；

在 Manifold 3 上执行推理、性能和稳定性验证；

将 Engine 与应用配置一同纳入 DPK 发布或设备模型目录。

选择在目标设备生成 TensorRT Engine，是为了让 Engine 与目标硬件、TensorRT 版本、算子支持和精度策略保持一致。其他机器生成的 Engine 不应直接作为最终交付物。

64.2 .pt 导出前检查

训练权重发布前应冻结：

模型结构与权重版本；

类别名称和顺序；

输入尺寸；

预处理与归一化；

输出张量定义；

置信度与后处理策略；

训练数据版本；

验证集结果；

权重校验和。

YOLO26 的端到端输出、是否包含后处理以及部署侧解析逻辑必须明确。ONNX 导出成功并不等于语义一致，必须使用同一批样本比较 .pt 与 ONNX 的输出。

64.3 ONNX 合规检查

检查模型格式、Opset、动态或静态输入、算子兼容、输入输出名称、输出维度和数值精度。部署链路优先采用可预测的固定输入规格；确需动态尺寸时，应明确优化 Profile 和允许范围。

建议保存三组验证样本：

典型正样本；

空样本与相似负样本；

小目标、遮挡、逆光和边界条件样本。

每次导出生成 Model Manifest，记录导出命令、环境、依赖、输入输出和校验结果。

64.4 设备侧 TensorRT 构建

在 Manifold 3 上构建 Engine 前确认：

目标设备运行时版本；

可用内存与存储；

ONNX 校验和；

支持的精度模式；

输入 Profile；

工作空间限制；

不支持算子与插件；

构建日志保存位置。

构建完成后，Engine 文件必须关联设备类型、TensorRT 版本、输入规格、精度和源 ONNX 校验和。文件名应可读，例如包含模型、输入尺寸、精度、目标设备和版本。

64.5 精度策略

FP32 用于基线验证；FP16 通常用于平衡性能和精度；INT8 需要具有代表性的校准数据和更严格的精度复核。不能只依据构建成功选择低精度。

对于裂缝、病害和安全帽等小目标任务，应特别关注量化后置信度、边界框、小目标召回和类别混淆变化。验收以事件和业务效果为主，不仅比较单帧平均指标。

64.6 跨运行时一致性

同一测试集分别在 .pt、ONNX 和 TensorRT 上运行，比较：

预处理结果；

检测数量；

类别；

置信度；

边界框偏差；

空样本误检；

端到端延迟；

内存与温度；

连续运行稳定性。

允许存在小范围数值差异，但不得出现类别顺序错误、尺度转换错误、输出解析错误或持续业务指标明显下降。

第 65 章 TensorRT Engine 与设备运行时验收

65.1 Engine 的交付单位

Engine 不应单独交付。一个完整 Engine 资产包包括：

Engine 文件；

源 ONNX 与校验和；

标签文件；

输入输出说明；

预处理与后处理说明；

目标设备和运行时版本；

精度模式和 Profile；

构建日志；

验证集结果；

性能基线；

回滚 Engine。

缺少任何关键元数据时，后续无法判断 Engine 是否适合某台设备，也无法追踪效果变化。

65.2 性能验收

设备侧性能测试采用真实视频和完整 BVE 流水线。至少记录：

解码 FPS；

推理 FPS；

端到端延迟；

CPU、GPU、内存和温度；

连续运行时间；

录像和事件写盘并发；

网络上传并发；

高温或低电量条件下的降级。

短时间单图 **Benchmark** 不足以支持飞行任务。应完成持续运行和多阶段负载测试。

65.3 稳定性与异常测试

测试模型文件损坏、配置错误、输入尺寸不匹配、视频断流、磁盘不足、中心失联、应用重启和 Engine 加载失败。系统应拒绝进入 RUNNING，或进入明确的 DEGRADED/SAFE_STOP 状态。

Engine 加载失败时不得静默切换到未知模型。允许配置受控的备用 Engine，但切换必须上报版本和原因。

65.4 业务验收

无人机病害识别需要同时验证：

遥控端或中心端能看到正确的识别结果；

检测框与原始画面时间对齐；

事件包含飞行任务、时间、位置或相对位置、模型和证据；

弱网时本地保存，恢复后补传；

同一病害不会因连续帧产生不可控的重复事件；

飞行和识别任务互不阻塞；

模型异常不会影响安全飞控链。

第 66 章 DPK 打包、安装、升级与回滚

66.1 发布前冻结

DPK 发布前冻结代码、依赖、模型、Engine、配置 Schema、权限和启动方式。每个包使用唯一版本号，不使用“final”“new”或日期覆盖同名文件。

发布包目录建议包含：

package/：DPK 主包；

manifest/：版本、硬件、依赖、校验和；

models/：Engine、标签和模型说明；

config/：配置模板与 Schema；

scripts/：安装后检查、日志导出和回滚辅助；

docs/：发布说明、已知问题、安装和验收步骤；

evidence/：构建、测试和批准记录。

66.2 安装前检查

确认无人机处于安全状态、螺旋桨风险受控、设备供电稳定、存储充足、当前版本已备份、远程连接可靠、回滚包可用，并通知飞手和现场安全员。

禁止在即将执行飞行任务前直接安装未经验证的新包。现场安装后先进行地面自检和静态测试，再进入飞行验证。

66.3 安装后验证

安装完成后验证：

应用版本与校验和；

启动与自检；

Engine 加载；

视频输入；

推理输出；

中心通信；

日志与遥测；

控制权接口；

安全停止；

重启后状态；

配置持久化。

只有地面验证通过，才允许进入低风险飞行测试。

66.4 升级策略

升级分为应用升级、模型升级、配置升级和系统基线升级。四类变更应独立记录，避免无法定位问题。

应用升级必须说明兼容的 Engine 和配置 Schema；模型升级必须说明类别和输出变化；配置升级必须说明控制参数和坐标变化；系统基线升级必须重新验证 TensorRT 和飞控接口。

66.5 回滚

回滚触发条件包括：

应用无法稳定启动；

Engine 无法加载；

推理结果异常；

控制权状态不明确；

飞行行为偏离计划；

日志或遥测缺失；

资源温度或负载异常；

紧急停止不可用。

回滚后重新执行地面自检，不得把“恢复旧版本”视为自动恢复生产。

第 67 章 边缘视频、事件、遥测与离线同步

67.1 单一任务时间轴

一次无人机或边缘巡检任务必须使用统一 Task ID。视频帧、推理、事件、飞行状态、位置、控制命令、证据文件和中心工单均关联该 ID。

时间轴至少包含：

任务创建；

设备接单；

起飞或任务开始；

控制权变化；

航线阶段；

检测与事件；

网络变化；

异常与人工干预；

任务结束；

文件同步；

人工复核。

没有统一时间轴时，出现偏航或漏检后很难区分是视频、模型、定位、控制还是同步问题。

67.2 事件唯一性

边缘事件 ID 在本地生成，不能依赖中心在线。建议包含设备 ID、任务 ID、时间和随机因子。中心使用幂等键防止补传时重复创建事件。

证据文件先在本地完成写入和校验，再更新事件为 `READY_TO_SYNC`。上传完成后验证对象大小和校验和，最后标记 `SYNCED`。不得在文件尚未完成时提前上报“同步成功”。

67.3 离线策略

离线时继续执行的能力必须预先授权。建议：

继续：视频采集、视觉推理、低风险事件、本地日志和安全状态监测。

降级：降低上传频率、只保存关键证据、暂停长录像和大模型复核。

停止：需要中心审批的新任务、远程配置修改、高风险自动处置和超出本地安全边界的飞控动作。

网络恢复后先同步状态和事件索引，再补传关键证据，最后传普通文件。避免大量视频补传占满链路，阻塞实时控制与告警。

67.4 遥测质量

遥测不仅是曲线展示，还用于判断任务是否可信。至少保存：

定位状态与质量；

控制权状态；

飞行模式；

高度、速度、姿态与航向；

CPU、GPU、内存、温度与功耗；

视频 FPS 与丢帧；

推理延迟；

队列和磁盘；

网络时延、丢包和信号；

应用与 Engine 版本。

关键遥测缺失时，任务结果应标记为“证据不完整”，不能直接用于高等级验收。

第 68 章 GPS-Denied 环境下的控制权、定位与坐标体系

68.1 先解决“谁在控制”，再解决“飞到哪里”

桥下 GPS-Denied 任务包含两个不同问题：控制权接管和相对导航。控制权接管成功，只能证明 DJI Manifold 3 可以发送并执行飞控指令；它不代表航线坐标已经正确，也不代表定位质量足以完成自动飞行。

控制权状态建议明确表示：

U=0：遥控器或原控制链拥有控制权，边缘应用只监测。

REQUESTING：边缘应用请求接管。

U=1：边缘应用拥有控制权，遥控器普通摇杆不再直接控制。

RELEASING：正在释放控制权。

EMERGENCY_OVERRIDE：人工或安全机制强制恢复控制。

任何时刻必须能够从日志和界面确认当前控制权所有者。

68.2 坐标系必须显式建模

GPS 航线通常使用经纬度或地理坐标；桥下视觉定位使用局部坐标。两者之间不能只做简单经纬度差值。至少区分：

地理坐标系 G：WGS84／CGCS2000 等；

地图或工程坐标系 M：项目平面坐标；

桥梁局部坐标系 B：沿桥向、横桥向、竖向；

视觉定位坐标系 V：视觉里程计或双目系统输出；

机体坐标系 Body：前、右、下或设备定义方向；

相机坐标系 C；

飞控局部坐标系 F。

每个坐标系必须记录原点、轴方向、单位、右手／左手约定、姿态表示和时间。转换链应通过矩阵或四元数统一实现，禁止在不同模块中分别交换 X／Y、取负号或使用未记录的航向补偿。

68.3 经纬度航线转局部航线

推荐流程：

选择桥外 GPS 良好、视觉定位稳定的共同观测区域；

确定地理坐标与桥梁局部坐标的控制点；

估计平移、旋转、尺度和必要的高度基准；

验证多个非共线控制点；

将原始航点转换到桥梁局部坐标；

根据飞控局部坐标系再转换；

在地面或仿真中可视化检查；

先执行短距离、低速度、单方向航段；

通过后再扩展完整路线。

转换结果必须检查航点顺序、距离、方向、航向、速度和高度。一个符号或轴顺序错误，就可能表现为“高度稳定但水平乱飞”。

68.4 定位质量与模式切换

进入桥下前记录 GPS、视觉定位、IMU 和高度来源。切换条件不能只使用“GPS 是否为零”，还应考虑卫星质量、定位协方差、视觉跟踪质量、纹理、光照、速度和传感器时间同步。

视觉定位失效时，系统应进入预定义降级：减速、悬停、释放控制或执行安全退出。不得在定位质量未知时继续追踪航点。

后续引入激光雷达时，应明确雷达坐标系、外参、时间同步和融合状态。传感器增加不会自动修复坐标逻辑错误，必须先建立统一坐标模型。

68.5 高度与水平控制分离诊断

如果无人机能保持初始高度，但未按规划路线飞行，可以初步判断高度控制链相对稳定，问题更可能位于水平位置、航向、坐标转换、定位尺度、控制指令语义或航点状态机。

诊断时分别绘制：

期望与实际 X；

期望与实际 Y；

期望与实际 Z；

期望与实际航向；

定位质量；

控制命令；

控制权状态。

不要只看三维轨迹总图。分轴误差更容易暴露交换轴、符号、尺度或延迟问题。

第 69 章 无人机飞行测试的分级验证方法

69.1 测试不是一次完整航线尝试

高风险飞行功能必须采用逐级放行。推荐级别：

T0 静态测试：不上桨或受控条件下验证应用、模型、传感器、日志和控制接口。

T1 地面动态测试：验证坐标、姿态、方向、控制量和紧急停止，不执行自主飞行。

T2 开阔区低高度测试：GPS 良好环境验证控制权接管、悬停、短距离移动和释放。

T3 GPS-Denied 边界测试：在可快速退出的位置验证模式切换与短时悬停。

T4 桥下短航段：只执行一条短直线，例如横穿桥底两侧，低速、低距离、明确终点。

T5 多航点测试：增加转向、航向和不同速度。

T6 任务联动：同时运行 BVE、事件记录和中心同步。

T7 生产试运行：在批准区域、时段和人员配置下执行受控任务。

上一等级未通过，不得通过增加测试次数“碰运气”进入下一等级。

69.2 飞行测试组织

至少明确：

任务负责人；

飞手与安全飞手；

边缘应用工程师；

观察员；

桥面或桥下警戒人员；

设备与电池负责人；

紧急联系人；

批准人。

飞手始终拥有中止任务的权力。测试成功标准和中止条件在起飞前宣读并确认。

69.3 中止条件

包括但不限于：

控制权状态不明；

定位质量下降；

实际轨迹超过安全走廊；

高度、速度或姿态异常；

通信中断超过阈值；

应用或飞控日志停止；

温度或电量异常；

人员、车辆或船舶进入测试区域；

安全飞手提出中止；

现场环境与计划不一致。

中止后先确保飞行安全，再保存数据。不得为保留日志而延迟人工接管。

69.4 短航线优先

GPS-Denied 初期验证采用“短、直、慢、可观察”的航线。横穿桥底两侧的短路线适合作为第一阶段，因为可明显判断横桥向方向、距离、航向和终点是否正确。

短航线通过后，再逐步扩展沿桥向、转弯、不同高度和病害巡检任务。每次只增加一个主要变量，使失败原因可定位。

69.5 测试数据包

每次飞行保存：

测试计划与批准；

天气、光照和环境；

设备、固件、DPK、Engine 和配置版本；

航线与坐标定义；

起飞前检查；

飞控、定位、应用、BVE 和遥控端日志；

视频与屏幕录像；

控制权时间轴；

期望与实际轨迹；

异常与人工操作；

结论、问题和下一步。

没有完整数据包的“飞过一次”不能作为工程验证结论。

第 70 章 工程案例：接管成功、高度稳定，但航线失效

70.1 已验证的进展

BridgeAI-UAV GPS-Denied 研发已完成一次关键突破：修正控制逻辑后重新构建 DPK，并成功安装到 DJI Manifold 3；现场测试中无人机进入桥下后可以继续飞行，Manifold 3 接管成功，控制权状态达到 $U=1$ ，遥控器普通摇杆不再直接生效。

同时，无人机能够基本保持进入桥下时的初始高度，说明高度控制和部分状态链路已具备基础稳定性。

70.2 尚未通过的能力

无人机未按规划航线飞行，表现为水平运动方向和路径失控或无序。该结果不能定义为“GPS-Denied 自动航线成功”，只能定义为：

控制权接管通过；

高度保持初步通过；

局部导航与航线跟踪未通过；

飞控安全与人工接管机制需要持续验证。

将部分成功和整体成功分开，是工程复盘的基本要求。

70.3 优先假设

当前优先排查的假设包括：

经纬度航点转换为桥下局部坐标时轴顺序错误；

横桥向或沿桥向符号相反；

地理北向、机头方向与桥梁轴线之间的航向补偿错误；

视觉定位坐标系与飞控局部坐标系定义不同；

位置单位或尺度错误；

航点原点在进入桥下前后发生变化；

位置指令被错误解释为速度指令，或相反；

命令时间戳、坐标数据和姿态数据未对齐；

控制权接管后航点状态机跳过或重复；

视觉定位质量不足造成漂移。

70.4 诊断顺序

第一步，禁止直接复飞完整航线。导出上次测试全部日志，重建控制权、期望轨迹、实际轨迹、位置、姿态和定位质量。

第二步，在不飞行条件下向系统输入已知局部坐标点，检查转换后的 X、Y、Z 和航向是否符合桥梁现场方向。

第三步，建立三个单位命令：沿桥向正方向 1 米、横桥向正方向 1 米、竖向安全小幅变化，分别验证输出符号和飞控响应。实际飞行时只验证安全允许的轴和距离。

第四步，选择短直线航段，以低速度执行，设置严格的横向偏差和时间中止阈值。

第五步，短航段稳定后再验证多点路线和模式切换。

70.5 激光雷达融合的正确位置

激光雷达可增强桥下几何约束和弱纹理区域定位，但应在坐标体系、时间同步、外参和航线转换逻辑明确后引入。否则多传感器融合会使问题更难定位。

建议把研发分为两条独立基线：

基线 A：双目视觉定位下，短直线航段可重复通过。

基线 B：加入激光雷达后，对遮挡、弱纹理和长距离漂移进行改进。

只有基线 A 清晰，才能客观评价雷达融合带来的增益。

70.6 复盘结论

这次测试证明了边缘计算平台接管飞控的可行性，同时也暴露了“控制权”和“导航正确性”之间的边界。下一阶段最重要的工作不是继续扩大航线，而是把坐标转换、定位质量、控制命令和飞行轨迹建立为一条可验证的数据链。

第 71 章 边缘节点与无人机交付验收

71.1 分层验收

边缘基础验收：硬件、供电、散热、网络、时间、身份和远程维护。

软件验收：DPK、服务、Engine、配置、日志、遥测、升级和回滚。

AI 验收：输入、输出、性能、事件、证据和模型版本。

离线验收：断网运行、缓存、补传、冲突和容量。

飞控接口验收：控制权状态、请求、释放、人工覆盖和安全停止。

导航验收：定位质量、坐标、短航段、轨迹偏差和模式切换。

任务验收：航线、BVE、事件、中心同步和报告完整闭环。

71.2 不可替代的安全条件

以下条件未通过，不得进行生产交付：

人工紧急接管不可用；

控制权状态无法确认；

定位失效没有降级策略；

应用重启会自动恢复危险控制；

DPK 和 Engine 无回滚；

飞行日志和控制日志无法对齐；

实际轨迹超过安全边界但系统不停止；

设备版本、配置和航线无法追踪。

71.3 交付资产

边缘节点清单；

硬件与系统基线；

设备身份和权限；

网络与端口；

DPK、Engine、模型和配置；

安装、升级和回滚记录；

离线和补传测试；

飞行测试数据包；

坐标与航线说明；

安全机制与中止条件；

故障处理 SOP；

远程维护与账号移交；

未关闭问题和限制条件。

71.4 限制条件必须写入验收结论

若 GPS-Denied 仅完成控制权接管和高度保持，而航线跟踪尚未通过，验收结论必须明确为“研发验证阶段”，不能写成“桥下自主巡检能力已交付”。

工程文件应同时记录已通过、未通过、暂不适用和后续计划。透明的限制说明比模糊承诺更能保护项目和现场安全。

第十篇 案例复盘、SOP、表单与检查清单

第 72 章 复盘不是总结成绩，而是修正系统

72.1 复盘的对象是系统

项目复盘不应停留在“团队努力、客户配合、按期完成”。真正有价值的复盘要解释：事实发生了什么，预期是什么，差异为什么出现，哪些控制没有发挥作用，如何让下一项目更早发现或自动避免。

BridgeAI-Site 的问题通常跨越软件、AI、视频、GIS、网络、现场组织和供应商。复盘必须观察完整链路，而不是把故障归结为某个人“没有注意”。

72.2 复盘触发条件

建议以下情况必须复盘：

S1/S2 级生产故障；

高风险误报或漏报；

数据、证据或审计丢失；

发布回滚；

飞行中止或控制异常；

验收延期；

客户重大投诉；

重复发生的同类问题；

现场安全边界被突破；

关键里程碑严重偏差；

成功解决具有复用价值的复杂问题。

72.3 时间线优先

复盘第一步是建立时间线，内容包括版本、告警、操作、沟通、决策和现场事件。时间线只记录可验证事实，不先判断责任。

建议使用统一时间、请求 ID、事件 ID、任务 ID、设备 ID 和变更单号关联证据。对无人机任务还应加入控制权、定位状态、航线阶段和人工接管。

72.4 根因分层

直接原因：导致当前故障的技术或操作条件。

促成因素：使故障更容易发生或影响扩大的环境。

系统原因：流程、架构、责任、测试或门禁为何未阻止故障。

检测缺口：为什么没有更早发现。

恢复缺口：为什么恢复时间超过预期。

一个有效复盘至少提出一个系统性改进，而不是只要求人员“以后注意”。

72.5 无责但有责任

无责复盘不等于无人负责。讨论聚焦系统机制，行动项仍需有明确责任人、期限和验证方式。故意违规、隐瞒或绕过安全流程的行为，另按管理制度处理，不应借“无责”掩盖。

第 73 章 典型失败模式与工程对策

73.1 部署成功幻觉

症状：容器均为 Running，页面可打开，但视频、事件、Agent 或备份不可用。

根因：用进程健康替代业务健康。

对策：发布门禁必须执行端到端冒烟、真实事件、工单、Agent 查询和恢复验证。

73.2 视频可播但 AI 不可用

症状：视频墙正常，模型漏报严重。

根因：目标像素不足、夜间过曝、云台变化、AI 使用了不同码流或时间戳。

对策：摄像头 AI 适配评分、主辅码流一致性、目标像素测量和场景卡门禁。

73.3 模型指标高但告警无价值

症状：检测框很多，安全员仍不使用。

根因：逐帧告警、重复事件、无 ROI、无时段、无风险分级和无处置流程。

对策：跟踪、持续时间、聚合、冷却、事件级验收和业务闭环。

73.4 RAG 有资料但回答引用错误

症状：Agent 引用过期制度或跨项目文档。

根因：版本、权限、有效期和文档权威等级未治理。

对策：检索前权限过滤、有效版本、来源引用和撤回机制。

73.5 Agent 能调用工具但不可上线

症状：工具调用偶尔重复、越权或长时间无响应。

根因：Tool Contract、幂等、审批、超时和补偿不完整。

对策：L0～L4 权限、Schema、幂等键、状态机、人工确认和审计。

73.6 备份每天成功但无法恢复

症状：备份文件存在，恢复时缺扩展、权限或对象文件。

根因：只检查命令退出码，未执行恢复演练。

对策：隔离恢复、业务冒烟、校验和和 RPO／RTO 实测。

73.7 飞控接管成功但航线失效

症状：U=1、高度稳定，水平航线混乱。

根因：把控制权成功误判为导航成功，坐标和定位链未验证。

对策：分轴分析、短航段、坐标控制点、模式状态机和逐级飞行测试。

第 74 章 SOP 体系设计

74.1 SOP 的作用

SOP 将最佳实践转化为在压力、人员变化和现场不确定性下仍可执行的标准步骤。SOP 不是解释产品功能，而是明确触发条件、责任、输入、操作、验证、异常和记录。

74.2 SOP 标准结构

编号与名称；

目的与适用范围；

触发条件；

角色与权限；

前置条件；

输入与工具；

标准步骤；

每步验证；

异常分支；

中止与升级条件；

输出与证据；

关联表单；

版本、批准人与生效日期；

复审周期。

涉及飞控、生产发布、数据恢复和高风险 Agent 的 SOP 必须包含不可跳过的安全检查。

74.3 SOP 分级

L1 日常操作：账号、摄像头、工单、知识文档和常规巡检。

L2 专业维护：模型发布、ROI 调整、数据库维护、边缘升级和问题诊断。

L3 高风险操作：生产发布、数据恢复、控制权接管、飞行测试和安全边界修改。

L3 SOP 应采用双人复核或批准，并保留完整执行记录。

74.4 SOP 生命周期

提出需求；

编写草案；

桌面评审；

测试环境演练；

现场试用；

批准发布；

培训；

执行与收集问题；

定期复审；

修订或废止。

SOP 不能长期停留在共享文件夹。平台应记录当前有效版本，旧版本归档并停止使用。

74.5 推荐 SOP 目录

SOP-001 项目启动与范围确认；

SOP-002 现场勘察；

SOP-003 平台首次部署；

SOP-004 生产发布与回滚；

SOP-005 数据库备份与恢复；

SOP-006 摄像头接入与流测试；

SOP-007 GIS 数据导入与发布；

SOP-008 BVE 模型发布；

SOP-009 AI 场景灰度；

SOP-010 RAG 文档发布与撤回；

SOP-011 Agent 工具上线；

SOP-012 试运行日报与问题闭环；

SOP-013 边缘节点注册与升级；

SOP-014 TensorRT Engine 构建与验证；

SOP-015 DPK 安装与回滚；

SOP-016 GPS-Denied 飞行测试；

SOP-017 重大故障响应；

SOP-018 项目终验与移交。

第 75 章 检查清单体系与质量门禁

75.1 清单不是记忆替代品，而是风险控制器

检查清单用于防止已知且高代价的遗漏。它不替代专业判断，而是保证关键判断发生。

好的清单条目应可回答“是／否／不适用”，并能关联责任人和证据。含糊条目如“检查网络正常”应改为“从 BVE 节点连续拉取目标视频 30 分钟，无不可恢复断流”。

75.2 三类清单

准备清单：在开始活动前确认人员、环境、授权、版本和回滚。

执行清单：控制步骤顺序和关键验证。

退出清单：确认结果、证据、问题、恢复和移交。

每个高风险活动至少具有准备和退出清单。

75.3 清单设计原则

控制在一页或一个明确阶段；

优先列高风险和高频遗漏；

使用动作语言；

避免重复 SOP 全文；

允许标记不适用，但需说明；

记录执行人、复核人和时间；

版本化；

根据复盘持续更新。

75.4 全生命周期门禁

G1 项目启动；

G2 现场条件；

G3 平台与数据底座；

G4 视频与 GIS；

G5 BVE 与 AI；

G6 Agent 与 RAG；

G7 联调与安全；

G8 试运行；

G9 边缘与无人机；

G10 终验与运维移交。

每个门禁形成签字或电子批准记录。未通过项必须进入问题清单，不得以会议口头同意代替。

第 76 章 表单、记录与证据的工程化管理

76.1 表单必须支持决策

表单不是为了增加文档数量。每张表应服务一个决策，例如是否具备上线条件、是否允许飞行、是否接受模型版本、是否关闭缺陷。

无法影响决策、没有责任人或无法追踪证据的字段应删除。

76.2 主记录与附件

主记录保存结构化结论、状态、责任和版本；附件保存截图、日志、视频、配置、测试结果和签字材料。附件使用稳定链接和校验和，避免在多个群聊中分散。

例如一次 DPK 发布的主记录包含包版本、设备、执行人、结论和回滚状态；附件包含 DPK 文件、校验和、安装日志、设备截图和测试视频。

76.3 编号体系

建议编号：

PRJ：项目；

SUR：勘察；

ADR: 架构决策;

REL: 发布;

MOD: 模型;

SCN: AI 场景;

AGT: Agent;

KNO: 知识文档;

TST: 测试;

INC: 事件或故障;

FLT: 飞行测试;

ACC: 验收;

SOP: 标准作业程序。

编号应跨系统稳定，能够从报告反查原始记录。

76.4 证据完整性

关键证据包含：

生成时间和来源；

关联项目、任务和设备；

版本；

操作者；

原始文件；

必要的校验和；

访问权限；

保留周期；

是否经过人工确认。

截图只能作为辅助，不能替代原始日志、视频或结构化记录。

76.5 敏感信息

表单和证据中不得包含明文密码、完整令牌、私钥和不必要的个人信息。需要证明配置时，可展示脱敏值、密钥引用或权限结果。

无人机飞行数据、项目坐标和桥梁结构影像按项目数据等级管理，跨项目复用前必须确认授权。

第 77 章 项目收尾、知识移交与长期运营

77.1 收尾不是停止实施人员驻场

项目收尾必须确认交付物、数据、账号、权限、培训、问题、运维责任和商业边界。实施人员离场只是一个时间点，不代表责任自动转移。

77.2 四类移交

系统移交：环境、服务、版本、配置、模型、Agent 和监控。

数据移交：数据库、对象存储、知识文档、备份、保留和导出。

运维移交：账号、SOP、告警、联系人、升级、回滚和 SLA。

业务移交：安全员、班组、监理和管理者能真实使用闭环。

边缘与无人机项目还需移交设备、DPK、Engine、航线、飞行限制和安全检查。

77.3 未关闭事项

终验时允许保留的事项必须明确：

等级；

影响；

临时措施；

责任人；

完成日期；

验证人；

是否影响付款、生产或安全；

逾期升级机制。

S1 和安全阻断项不得作为普通遗留问题移交。

77.4 运营节奏

建议：

每日：核心健康、摄像头、事件和高风险工单。

每周：AI 误报漏报、Agent 失败、容量、问题和知识更新。

每月：版本、权限、备份恢复抽查、模型漂移和 SLA。

每季度：完整恢复演练、安全复核、SOP 复审和产品改进。

施工阶段变化时：复核 GIS、摄像头、ROI、规则和验收基线。

77.5 知识回流

项目结束后，将可复用经验转化为：

标准场景卡；

摄像头适配规则；

模型和负样本集；

部署模板；

ADR；

Tool Contract；

故障模式；

SOP；

检查清单；

培训案例；

报价和工期估算依据。

客户敏感数据不得直接进入公共资产；复用前进行脱敏、授权和项目边界检查。

第 78 章 从项目资产到产品化交付包

78.1 可重复交付能力

一个成熟产品不能依赖原开发者记忆。BridgeAI-Site 应把项目经验沉淀为可以由不同团队执行、在不同环境验证并可审计的交付包。

标准交付包建议分为：

Platform Pack：Web、API、Worker、Agent、Media 和数据底座。

BVE Pack：Runtime、模型、规则、场景模板和评测集。

Edge Pack：边缘服务、设备注册、离线同步和运维。

UAV Pack：DPK、Engine、航线接口、遥测和飞行测试模板。

Ops Pack：监控、日志、备份、恢复、发布和回滚。

Delivery Pack：方案、SOP、清单、表单、培训和验收。

78.2 兼容矩阵

每个包维护兼容矩阵，包括平台版本、Schema、模型、Engine、DPK、设备、操作系统、TensorRT、MLX、PostgreSQL 和第三方接口。

兼容矩阵必须来源于实际验证。未经测试的组合标记为“未知”，不能默认兼容。

78.3 项目差异最小化

项目差异优先通过配置、场景卡、GIS 数据、权限和工作流表达。只有真正需要新能力时才修改产品代码。

如果每个项目都维护独立分支、独立数据库结构和独立模型解析逻辑，后续升级和运维成本会快速失控。

78.4 发布列车

建议采用固定发布节奏：

产品版本按计划发布；

紧急修复使用补丁版本；

模型、Prompt、Rule 和知识文档可独立发布；

边缘 DPK 与中心平台保持兼容窗口；

项目升级先在测试或影子环境验证；

长期不升级项目明确支持期限。

78.5 成熟度指标

可观察的产品化指标包括：

新项目部署时间；

标准配置覆盖率；

现场问题重复率；

回滚成功率；

恢复演练通过率；

模型和 Agent 灰度成功率；

SOP 使用率；

验收一次通过率；

项目资产复用率；

单项目长期运维成本。

第 79 章 综合案例：从售前承诺到可持续生产系统

79.1 项目起点

某交通基础设施建设项目计划接入 20 路摄像头、天地图、四类 AI 场景、Agent、RAG、工单闭环和一套无人机边缘能力。售前阶段产品演示顺利，团队最初认为主要工作是安装平台和配置模型。

79.2 第一阶段：现场事实重塑方案

勘察发现部分摄像头无法稳定取流，网络存在 VLAN 隔离，两个高风险工区目标像素不足。团队将首期范围调整为 10 路合格视频、两个 AI 场景和一个完整工单闭环。

这一调整没有降低项目价值，反而使第一阶段具备明确的验证对象。

79.3 第二阶段：平台上线暴露业务健康问题

平台容器全部运行，但视频墙卡顿、事件录像为空、Agent 查询慢。通过业务健康检查，团队拆分视频、AI、录像和 Agent 资源，增加索引、生命周期和异步任务。

系统从“页面可打开”进入“链路可持续”。

79.4 第三阶段：AI 从检测框进入事件

安全帽模型单帧表现尚可，但重复告警严重。团队引入跟踪、持续时间、ROI、冷却和人工复核，以事件为单位验收。安全员开始使用工单闭环，AI 指标与业务指标建立联系。

79.5 第四阶段：Agent 从回答问题进入受控动作

Agent 能够查询制度和事件，但工具调用存在参数不稳定。通过 Tool Contract、权限、幂等、人工确认和审计，系统只允许 Agent 自动执行低风险操作，高风险工单由人员批准。

79.6 第五阶段：边缘与无人机验证

YOLO26 由 .pt 导出 ONNX，在 Manifold 3 上转换 TensorRT Engine，并通过 DPK 部署。无人机桥下测试完成控制权接管和高度保持，但局部航线未通过。

团队没有将其包装为完整成功，而是建立坐标转换诊断和短航段验证计划，并把激光雷达融合放在清晰基线之后。

79.7 最终交付

项目最终交付的不只是软件，还包括：

系统与数据底座；

视频、GIS、AI 和 Agent 配置；

模型、Engine、DPK 和版本矩阵；

事件与工单闭环；

备份恢复和监控；

SOP、表单和检查清单；

培训和实操考核；

边缘限制条件与后续研发计划；

完整的证据与复盘资产。

综合案例说明，复杂 AI 项目的成功不是一次“大上线”，而是一系列可验证、可回退和可移交的小成功。

第 80 章 全书最终质量审查与出版交付

80.1 内容一致性审查

正式发布前统一检查：

产品名称、公司名称和作者；

BVE、Agent、RAG、Edge 和 UAV 术语；

章节编号与附录编号；

角色、权限和风险等级；

设备、模型和运行时名称；

流程、门禁和验收口径；

示例项目数据；

已通过或未通过的研发状态。

不得在不同章节对同一能力做相互矛盾的承诺。

80.2 技术一致性审查

确认架构图、目录、端口、数据对象、部署顺序、模型链路、坐标体系、状态机、备份和回滚逻辑一致。

代码、命令和配置示例进入正式版前必须在目标环境复测。无法验证的示例标记为伪代码或方法说明，不伪装成可直接运行命令。

80.3 安全与合规审查

删除密码、令牌、真实内网地址、未授权个人信息和敏感坐标。检查无人机、飞控、数据采集和远程维护章节是否明确人工接管、审批和安全边界。

80.4 版式与文件审查

DOCX、PDF、Markdown 和开发 ZIP 保持相同版本号和发布日期。检查目录、标题层级、页眉页脚、表格跨页、图片清晰度、链接、书签和中文字体兼容。

PDF 用于发布和审阅；DOCX 用于正式编辑；Markdown 用于版本管理和知识库；开发 ZIP 包含正文、媒体、模板和资产说明。

80.5 版本发布

正式版发布包建议包含：

BridgeAI-Site_项目实施与现场交付方案_v2.0.docx;

BridgeAI-Site_项目实施与现场交付方案_v2.0.pdf;

BridgeAI-Site_项目实施与现场交付方案_v2.0.md;

BridgeAI-Site_项目实施与现场交付方案_v2.0_Development.zip;

CHANGELOG;

文件校验和;

版本批准记录。

出版增强版工作稿经过技术、业务、实施和管理四类评审后，转为正式发布版。

附录 AA 边缘节点资产与验收记录

项目名称：

设备编号：

设备类型：GPU 工控机／DJI Manifold 3／其他

安装位置：

设备序列号：

硬件配置：

系统与固件：

运行时：

网络与 IP：

设备身份：

中心项目绑定：

供电与散热：

磁盘与容量：

远程维护：

应用版本：

模型／Engine：

配置版本：

连续运行测试：

离线运行测试：

补传测试：

日志与遥测：

紧急停止：

回滚版本：

限制条件：

实施工程师：

设备负责人：

验收结论：通过／有条件通过／不通过

日期：

附录 AB 模型转换与 TensorRT 发布记录

发布编号：

模型名称:

训练权重版本:

源 .pt 校验和:

训练环境:

类别与顺序:

输入尺寸:

ONNX 导出环境: Windows WSL

导出命令或脚本版本:

ONNX Opset:

动态/静态输入:

ONNX 校验和:

目标设备:

TensorRT 版本:

精度: FP32/FP16/INT8

Profile:

Engine 文件:

Engine 校验和:

构建日志:

.pt 与 ONNX 一致性:

ONNX 与 Engine 一致性:

真实视频性能:

连续运行时间:

温度与资源:

异常测试:

回滚 Engine:

发布人:

审核人:

结论：

附录 AC DPK 发布、安装与回滚记录

DPK 发布编号：

应用名称：

DPK 版本：

目标设备：

源代码 Commit：

构建环境：

依赖与系统基线：

包含的 Engine：

配置 Schema：

包校验和：

当前设备版本：

备份位置：

安装前检查：

安装时间：

执行人：

安装日志：

启动自检：

视频与推理：

中心通信：

控制权接口：

安全停止：

重启验证：

飞行前地面验证:

遗留问题:

回滚触发:

回滚包:

回滚结果:

批准人:

结论:

附录 AD GPS-Denied 飞行测试计划与记录

测试编号:

项目与桥梁:

测试日期:

天气与光照:

测试区域:

测试等级: T0/T1/T2/T3/T4/T5/T6/T7

任务负责人:

飞手:

安全飞手:

边缘工程师:

观察员:

警戒人员:

无人机与电池:

Manifold 3:

DPK:

Engine:

定位方式:

坐标系:

航线版本:

速度与高度限制:

安全走廊:

控制权策略:

紧急接管:

中止条件:

起飞前检查:

实际开始与结束:

控制权结果:

定位质量:

期望与实际轨迹:

BVE 与事件:

异常与人工干预:

日志与视频位置:

结论: 通过 / 有条件通过 / 不通过

下一阶段:

附录 AE 坐标体系与航线转换验证表

项目:

桥梁局部坐标定义:

地理坐标系:

工程坐标系:

视觉定位坐标系:

飞控局部坐标系:

机体坐标系:

相机坐标系:

坐标原点:

X 轴方向:

Y 轴方向:

Z 轴方向:

单位:

手性约定:

姿态表示:

时间基准:

控制点 1:

控制点 2:

控制点 3:

平移参数:

旋转参数:

尺度:

高度基准:

航向补偿:

转换脚本版本:

单元测试:

地面可视化:

沿桥向 1 米验证:

横桥向 1 米验证:

高度验证:

误差:

审核人:

结论：

附录 AF 边缘断网与恢复同步测试

测试编号：

设备：

中心版本：

边缘版本：

断网开始：

断网持续：

断网期间任务：

本地事件数量：

本地证据数量与容量：

是否触发降级：

是否停止高风险动作：

网络恢复：

状态同步耗时：

事件同步结果：

文件补传结果：

重复事件：

冲突记录：

实时链路是否受补传影响：

最终一致性：

问题与整改：

结论：

附录 AG 重大问题复盘模板

复盘编号：

事件名称：

项目：

日期：

影响范围：

等级：

复盘主持人：

参与人员：

一、事件摘要

二、预期行为

三、事实时间线

四、直接原因

五、促成因素

六、系统原因

七、检测缺口

八、恢复过程

九、做得好的地方

十、需要改进的地方

十一、行动项

行动项编号 | 措施 | 类型 | 责任人 | 期限 | 验证方式 | 状态

十二、SOP／清单／架构是否需要更新

十三、经验如何进入产品与培训

十四、批准与关闭

附录 AH SOP 总目录与版本台账

SOP 编号 | 名称 | 风险等级 | 适用角色 | 当前版本 | 批准人 | 生效日期 | 复审日期 | 状态

状态：草案／试用／有效／修订中／废止

附录 AI 全生命周期质量门禁总表

- G1 项目启动： ☐ 通过 ☐ 有条件通过 ☐ 不通过
- G2 现场条件： ☐ 通过 ☐ 有条件通过 ☐ 不通过
- G3 平台与数据底座： ☐ 通过 ☐ 有条件通过 ☐ 不通过
- G4 视频与 GIS： ☐ 通过 ☐ 有条件通过 ☐ 不通过
- G5 BVE 与 AI： ☐ 通过 ☐ 有条件通过 ☐ 不通过
- G6 Agent 与 RAG： ☐ 通过 ☐ 有条件通过 ☐ 不通过
- G7 联调与安全： ☐ 通过 ☐ 有条件通过 ☐ 不通过
- G8 试运行： ☐ 通过 ☐ 有条件通过 ☐ 不通过
- G9 边缘与无人机： ☐ 通过 ☐ 有条件通过 ☐ 不通过
- G10 终验与移交： ☐ 通过 ☐ 有条件通过 ☐ 不通过

每个门禁记录：

负责人：

批准人：

证据：

未通过项：

限制条件:

关闭日期:

附录 AJ 终验交付包总清单

- ☐ 合同与范围基线
- ☐ 项目章程与组织
- ☐ 现场勘察和实施方案
- ☐ 架构决策记录
- ☐ 环境与版本矩阵
- ☐ 部署、发布和回滚记录
- ☐ 数据库、对象存储和备份恢复
- ☐ 摄像头与视频测试
- ☐ GIS 数据与发布记录
- ☐ BVE 模型、场景和验收
- ☐ Agent、工具、Prompt 和评测
- ☐ RAG 文档、版本和权限
- ☐ 事件、工单和报表闭环
- ☐ 联调、性能和安全测试
- ☐ 培训、签到和实操考核
- ☐ 试运行日报和指标
- ☐ 缺陷、整改和复测
- ☐ 边缘节点资产
- ☐ Engine 与 DPK 资产
- ☐ 飞行测试与限制条件
- ☐ SOP、检查清单和表单

☐ 账号、密钥和远程维护

☐ 运维联系人与 SLA

☐ 未关闭问题

☐ 项目总结与复盘

☐ 验收签字

附录 AK 项目关闭报告模板

项目名称：

合同编号：

建设单位：

施工单位：

监理单位：

BridgeAI 项目经理：

实施周期：

终验日期：

一、建设目标与完成情况

二、最终交付范围

三、系统与版本

四、关键指标

五、AI 与 Agent 效果

六、边缘与无人机状态

七、培训与使用情况

八、缺陷与遗留问题

九、运维与 SLA

十、数据和账号移交

十一、项目风险关闭情况

十二、经验与产品改进

十三、商业和合同收尾

十四、各方确认

第五轮完成说明

本轮已完成第九篇“边缘节点、无人机与 DJI Manifold 3 交付”和第十篇“案例复盘、SOP、表单与检查清单”的出版化扩写。内容覆盖边缘生产单元、设备身份、Manifold 3 软件基线、YOLO26 的 .pt→ONNX→TensorRT 链路、Engine 验收、DPK 安装回滚、离线同步、GPS-Denied 控制权与坐标体系、分级飞行测试、当前桥下试飞复盘，以及复盘方法、典型失败模式、SOP、质量门禁、证据管理、项目收尾和产品化交付包。新增边缘资产、模型转换、DPK、飞行测试、坐标转换、断网同步、重大复盘、SOP 台账、全生命周期门禁、终验总清单和项目关闭报告十一套工程模板。至此，全书十篇主体已完成。